

MASARYKOVA UNIVERZITA
PŘÍRODOVĚDECKÁ FAKULTA
ÚSTAV MATEMATIKY A STATISTIKY

Diplomová práce

BRNO 2023

KAROL JURÍK

Segmentace klientů v neživotním pojištění

Diplomová práce

Karol Jurík

Bibliografický záznam

Autor:	Bc. Karol Jurík Přírodovědecká fakulta, Masarykova univerzita Ústav matematiky a statistiky
Název práce:	Segmentace klientů v neživotním pojištění
Studijní program:	Aplikovaná matematika
Studijní obor:	Finanční a pojistná matematika
Vedoucí práce:	Mgr. Silvie Zlatošová, Ph. D.
Akademický rok:	2022/2023
Počet stran:	xiii + 98
Klíčová slova:	segmentace klientů, neživotní pojištění, frekvence nehodovosti, zobecněné lineární modely, Poissonův model, negativní binomický model, gradient boosting modely, vysvětlovací techniky, Shapleyho hodnoty

Bibliografický záznam

Autor:	Bc. Karol Jurík Prírodovedecká fakulta, Masarykova univerzita Ústav matematiky a štatistiky
Názov práce:	Segmentácia klientov v neživotnom poistení
Študijný program:	Aplikovaná matematika
Študijný odbor:	Finančná a poistná matematika
Vedúci práce:	Mgr. Silvie Zlatošová, Ph. D.
Akademický rok:	2022/2023
Počet strán:	xiii + 98
Kľúčové slová:	segmentácia klientov, neživotné poistenie, frekvencia nehodovosti, zovšeobecnené lineárne modely, Poissonov model, negatívne binomický model, gradient boosting modely, vysvetľovacie techniky, Shapleyho hodnoty

Bibliographic Entry

Author:	Bc. Karol Jurík Faculty of Science, Masaryk University Department of Mathematics and Statistics
Title of Thesis:	Client segmentation in non-life insurance
Degree Programme:	Applied Mathematics
Field of Study:	Financial and Insurance Mathematics
Supervisor:	Mgr. Silvie Zlatošová, Ph. D.
Academic Year:	2022/2023
Number of Pages:	xiii + 98
Keywords:	client segmentation, non-life insurance, claim frequency, generalized linear models, Poisson model, negative binomial model, gradient boosting models, explanatory techniques, Shapley values

Abstrakt

V této diplomové práci se věnujeme apriorní segmentaci klientů v neživotním pojištění. Segmentace klientů do rizikových skupin provádíme na základě očekávané roční frekvence nehodovosti. K modelování očekávané frekvence nehodovosti jsou nejprve použity zobecněné lineární modely, konkrétně se věnujeme převážně Poissonovu regresnímu modelu a negativnímu binomickému modelu. Později se zaměříme na gradient boosting metody a možnosti interpretace modelů tohoto typu. Představeny jsou vysvětlovací techniky, které mohou být použity k interpretaci různých typů modelů strojového učení. V závěrečné diplomové práci jsou zmíněné metody a techniky aplikované na reálná data z pojišťovny. Tato data odpovídají pojištění odpovědnosti za újmu způsobenou provozem motorového vozidla. Postupně sestrojíme Poissonův model, negativně binomický model a gradient boosting model, který se následně pokusíme interpretovat pomocí představených vysvětlovacích technik. Jednotlivé modely jsou porovnávány z hlediska možností použití, interpretace a predikční kvality. Predikční schopnost modelů je měřena na testovacím vzorku dat a porovnávána pomocí střední kvadratické chyby.

Abstrakt

V tejto diplomovej práci sa venujeme apriórnej segmentácii klientov v neživotnom poistení. Segmentáciu klientov do rizikových skupín vykonávame na základe očakávanej ročnej frekvencie nehodovosti. K modelovaniu očakávanej ročnej frekvencie nehodovosti sú najskôr použité zovšeobecnené lineárne modely, konkrétne sa venujeme prevažne Poissonovmu regresnému modelu a negatívne binomickému modelu. Neskôr sa zaoberáme gradient boosting metódami a možnostiam interpretácie modelov tohto typu. Predstavené sú vysvetľovacie techniky, ktoré môžu byť použité k interpretácii rôznych typov modelov strojového učenia. V závere diplomovej práce sú predstavené metódy a techniky aplikované na reálne dáta z poisťovne zodpovedajúce poisteniu zodpovednosti za škodu spôsobenú vedením motorového vozidla. Postupne zostrojíme Poissonov model, negatívne binomický model a gradient boosting model, ktorý sa pokúsime interpretovať pomocou predstavených vysvetľovacích techník. Jednotlivé modely sú porovnávané z hľadiska možnosti použitia, interpretovateľnosti a predikčnej kvality. Predikčná schopnosť modelov je meraná na testovacej vzorke dát a porovnávaná pomocou strednej kvadratickej chyby.

Abstract

In this thesis, we study the a priori segmentation of clients in non-life insurance. We classify clients according to their expected annual frequency of reported claims. First, generalized linear models are used to model the expected annual frequency of claims. We focus mainly on Poisson regression model and negative binomial model. Later, we focus on gradient boosting methods. We present explanatory techniques that can be used for interpretation different types of machine learning models. Eventually, the introduced methods and techniques are applied to real data from an insurance company. The data corresponds to motor third-party liability insurance. We construct a Poisson model, a negative binomial model, and a gradient boosting model. The gradient boosting model is then interpreted using all presented explanatory techniques. Individual models are compared in terms of usability, interpretability and predictive quality. The quality of prediction is measured on an unseen data and then compared using the mean squared error.

ZADÁNÍ
DIPLOMOVÉ PRÁCE

Akademický rok: 2022/2023

Ústav:	Přírodovědecká fakulta
Student:	Bc. Karol Jurík
Program:	Aplikovaná matematika
Specializace:	Finanční a pojistná matematika

Ředitel ústavu PřF MU Vám ve smyslu Studijního a zkušebního řádu MU určuje diplomovou práci s názvem:

Název práce:	Segmentace klientů v neživotním pojištění
Název práce anglicky:	Client segmentation in non-life insurance
Jazyk závěrečné práce:	slovenština

Oficiální zadání:

Student nastuduje vybrané způsoby segmentace klientů do tarifních skupin a jejich následnou homogenizaci. Nabyté znalosti aplikuje na datech.

Literatura:

DOBSON, Annette J. *An introduction to generalized linear models*. 2nd ed. Boca Raton: Chapman & Hall, 2002. vii, 225. ISBN 1584881658.

KLUGMAN, Stuart A., Harry H. PANJER a Gordon E. WILLMOT. *Loss models : from data to decisions*. 4th ed. Hoboken, N.J.: John Wiley & Sons, 2012. xiv, 511 s. ISBN 9781118315323.

Vedoucí práce:	Mgr. Silvie Zlatošová, Ph.D.
Datum zadání práce:	15. 9. 2020
V Brně dne:	25. 4. 2023

Zadání bylo schváleno prostřednictvím IS MU.

Bc. Karol Jurík, 19. 11. 2020

Mgr. Silvie Zlatošová, Ph.D., 10. 11. 2020

RNDr. Jan Vondra, Ph.D., 19. 11. 2020

Pod'akovanie

Na tomto mieste by som sa chcel poďakovať vedúcej svojej práce Mgr. Silvii Zlatošovej, Ph. D. za rady, pripomienky a čas venovaný konzultáciám.

Prohlášení

Prohlašuji, že jsem svoji diplomovou práci vypracoval samostatně s využitím informatických zdrojů, které jsou v práci citovány.

Brno 25. dubna 2023

.....
Karol Jurík

Obsah

Prehľad použitého značenia	xii
Úvod	1
Kapitola 1. Neživotné poistenie	3
Kapitola 2. Pravdepodobnostné rozdelenia počtu poistných nárokov	6
2.1 Binomické rozdelenie	8
2.2 Poissonovo rozdelenie	10
2.3 Negatívne binomické rozdelenie	11
2.4 Modifikované rozdelenia	15
2.4.1 Trieda rozdelení $(a, b, 0)$	15
2.4.2 Trieda rozdelení $(a, b, 1)$	16
2.4.3 Rozdelenia modifikované v 0	16
Kapitola 3. Modelovanie počtu poistných nárokov	19
3.1 Lineárny regresný model	19
3.2 Zovšeobecnený lineárny model	23
3.3 Odhady parametrov modelu	26
3.3.1 Metóda vážených najmenších štvorcov	26
3.3.2 Metóda maximálnej vierohodnosti	26
3.4 Výber vhodného modelu	29
3.4.1 Presnosť modelu	29
3.4.2 Krížová validácia	31
3.4.3 Analýza deviácie	32
3.4.4 Informačné kritéria	34
Kapitola 4. Modely strojového učenia v poisťovníctve	36
4.1 GLM versus metódy strojového učenia	37
4.2 Riadené učenie	38
4.2.1 Trieda modelu (priestor hypotéz)	39
4.2.2 Model problému	39
4.2.3 Učiaci algoritmus	39
4.3 Gradientný zostup	40
4.4 Rozhodovacie stromy	41

4.4.1 Algoritmus CART	42
4.4.2 Algoritmus CHAID	44
4.4.3 Bagging	45
4.4.4 Boosting	45
4.5 Gradient boosting model	46
4.6 Vysvetľovacie techniky	48
4.6.1 Shapleyho hodnoty (Tree SHAP)	48
4.6.2 Lokálne interpretovateľné modelovo-agnostické vysvetlenia	52
4.6.3 Grafy parciálnej závislosti a individuálnych podmienených očakávaní	53
Kapitola 5. Tvorba modelu	56
5.1 Predstavenie dát	56
5.2 Tvorba GLM	58
5.2.1 Počítacie procesy	59
5.2.2 Dopredná selekcia regresných parametrov	63
5.2.3 Výber vhodného modelu	67
5.2.4 Zhodnotenie GLM	71
5.3 Tvorba GBM	73
5.3.1 Zhodnotenie GBM	79
5.3.2 Porovnanie GLM a GBM	80
Záver	83
Príloha A	85
Príloha B	88
Zoznam použitej literatúry	96

Prehľad použitého značenia

Pre jednoduchšiu orientáciu v texte na tomto mieste uvádzame prehľad použitého značenia, ktoré sa v celej práci vyskytuje.

$\mathbb{N}_0$	množina všetkých prirodzených čísel vrátane 0
$\mathbb{R}^+$	množina všetkých kladných reálnych čísel
$\mathbb{R}_0^+$	množina všetkých kladných reálnych čísel vrátane 0
N	náhodná veličina označujúca počet poistných nárokov
$P(\cdot)$	pravdepodobnosť
$p(\cdot)$	pravdepodobnostná funkcia
$p_N^M(\cdot)$	pravdepodobnostná funkcia pre rozdelenie modifikované v 0
$p_N^T(\cdot)$	pravdepodobnostná funkcia pre rozdelenie odseknuté v 0
$f(\cdot)$	pravdepodobnostná hustota
$F(\cdot)$	distribučná funkcia
$E(\cdot)$	stredná hodnota
$E(\cdot \cdot)$	podmienená stredná hodnota
$\text{Var}(\cdot)$	rozptyl
$\ln(\cdot)$	prirodzený logaritmus
$Bi(v, p)$	binomické rozdelenie s parametrami v a p
$Pois(\lambda)$	Poissonovo rozdelenie s parametrom λ
$NeBi(r, p)$	negatívne binomické rozdelenie s parametrami r a p
$\chi^2(q)$	χ^2 rozdelenie s q stupňami voľnosti
df	stupne voľnosti
$\mathcal{L}(\cdot)$	vierohodná funkcia
$\ell(\cdot)$	logaritmická vierohodná funkcia
CV	krížová validácia
D	deviácia
ΔD	zmena deviácie
AIC	Akaikeho informačné kritérium
BIC	Bayesovo informačné kritérium
AIC_c	korigované Akaikeho informačné kritérium
GLM	zovšeobecnený lineárny model

GBM	gradient boosting model
$\mathcal{H}$	priestor hypotéz
$\mathcal{L}(\cdot)$	stratová funkcia
ϕ_j	Shapleyho hodnota pre j -ty atribút
LIME	lokálne interpretovateľné modelovo-agnostické vysvetlenia
PDP	grafy parciálnej závislosti
ALE	grafy akumulovaného lokálneho efektu
ICE	grafy individuálnych podmienených očakávaní

Úvod

Jednou z hlavných úloh poistnej matematiky je nastavenie spravodlivej tarifnej štruktúry, ktorá sa čo najviac zhoduje s rizikovosťou klientov poisťovne. Segmentácia klientov do rizikových skupín je jednou z častí procesu tvorby takejto tarifnej štruktúry. V odvetví neživotných poistení má poisťiteľ pred uzavretím poistnej zmluvy k dispozícii základné charakteristiky klienta. Pri poistení motorových vozidiel sú to informácie o samotnom klientovi, a takisto informácie o vozidle. Môže sa jednať o údaje ako napríklad vek klienta, bydlisko, typ vozidla, výkon vozidla, vek vozidla a podobne. Na základe týchto apriórnych informácií je potom klient zaradený do určitej rizikovej skupiny, ktorá najlepšie zodpovedá jeho rizikovému faktoru. Pre každú rizikovú skupinu je stanovená určitá výška základného poistného. Poisťiteľa zaujíma hlavne očakávaný počet nehôd, ktoré daný klient počas doby trvania poistenia ohlásí, a potom samozrejme aj výška vzniknutých škôd. Znalosť týchto informácií je pre poisťiteľa nevyhnutá, aby vedel zabezpečiť riadne fungovanie poisťovne. Poisťiteľ musí teda vytvoriť mechanizmy, pomocou ktorých bude tieto informácie vedieť odhadnúť.

Cieľom tejto diplomovej práce bude práve segmentácia klientov na základe odhadnutej ročnej frekvencie nehodovosti. Na začiatok si v krátkosti predstavíme odvetvie neživotných poistení a povieme si o ňom pár štatistických údajov. V ďalšej kapitole sa zameriame na pravdepodobnostné rozdelenia, ktoré môžu byť v poistení použité na popísanie počtu poistných nárokov. Predstavíme si všeobecne známe rozdelenia, akými sú binomické rozdelenie, Poissonovo rozdelenie a negatívne binomické rozdelenie. Ukážeme si vzájomné vzťahy medzi týmito pravdepodobnostnými rozdeleniami a pozrieme sa aj na menej typické modifikované pravdepodobnostné rozdelenia. Tretia kapitola je venovaná samotnému modelovaniu počtu poistných nárokov. Predstavíme si zovšeobecnené lineárne modely, ukážeme si, akým spôsobom je možné odhadnúť parametre takýchto modelov, a tiež si povieme, akým spôsobom môžeme vybrať vhodný model a na čo sa máme pri procese tvorby modelu zamerať. Nasledujúca kapitola je cielená na modely strojového učenia v poisťovníctve a ich potenciálne využitie v tejto oblasti. Najskôr si porovnáme klasické zovšeobecnené lineárne modely so zložitejšími modelmi strojového učenia a uvedieme si základné rozdiely. Potom si povieme pár informácií o procese riadeného učenia, predstavíme si metódu gradient descent, a ďalej sa budeme v krátkosti venovať rozhodovacím stromom. Po tomto stručnom úvode do problematiky sa zameriame na gradient boosting modely, pri ktorých si načrtneme, akým spôsobom funguje učiaci algoritmus. Záver tejto kapitoly bude patriť vysvetľovacím technikám, pomocou ktorých dokážeme interpretovať aj zložité modely strojového učenia. Posledná kapitola bude praktickým zhrnutím predstavenej teórie. Pomocou reálnych dát z poistenia zodpovednosti za škodu spôsobnú vedením motorového vozidla

vytvoríme najskôr Poissonov regresný model, a potom aj negatívne binomický model. Využitím týchto modelov sa pokúsime odhadnúť očakávanú ročnú frekvenciu nehodovosti pre dané rizikové skupiny. Modely porovnáme a vyberieme ten, ktorý viac vyhovuje našim dátam. Neskôr upriamime pozornosť na tvorbu gradient boosting modelu a predovšetkým na aplikovanie vysvetľovacích techník, pomocou ktorých sa budeme snažiť tento model interpretovať. V závere práce porovnáme oba typy modelov a pozrieme sa, ako si modely poradia s neznámymi dátami. Všetky výpočty budú vykonané prostredníctvom štatistického softvéru .

Kapitola 1


Neživotné poistenie

V úvodnej kapitole tejto diplomovej práce si na začiatok povedzme pár základných informácií o samotnom neživotnom poistení. Podľa zákona o poisťovníctve [1] klasifikujeme poistenie na odvetvie životných poistení a odvetvie neživotných poistení. Pri odvetví neživotných poistení sa najčastejšie jedná o škodové poistenie (t. j. účelom je náhrada škody vzniknutej v dôsledku poistnej udalosti). Pojomom škoda sa rozumie ujma, či už zdravotná, majetková alebo iná, ktorú je možné peňažne vyčíslieť. V porovnaní s odvetvím životných poistení sa pri neživotnom poistení uzatvárajú poistné zmluvy na kratšie poistné doby s prípadným predlžovaním. Poistné plnenie v odvetví neživotných poistení je obmedzené rozsahom poistného záujmu¹. Kompletne členenie odvetví neživotných poistení môžeme nájsť v prílohe 1, časť B zákona č. 277/2009 Sb., o pojišťovníctví [1]. Za zmienku ale stojí poznamenať, že sem patrí majetkové poistenie, poistenie zodpovednosti za škody, úrazové poistenie a súkromné zdravotné poistenie.

Pre lepšiu predstavu sa teraz pozrime na štatistické údaje za kalendárny rok 2022 z Českej asociácie pojišťoven (ozn. ČAP), ktoré sú dostupné na internetových stránkach ČAP [3]. Z vývoja predpísaného zmluvného poistného za ukončené roky 2018 až 2022 zaznamenaného na obrázku 1.1 môžeme vypožorovať, že počas pozorovaného päťročného obdobia je predpísané poistné zodpovedajúce produktom neživotného poistenia výrazne vyššie, ako pri produktoch životného poistenia. Od roku 2019 je dokonca výška predpísaného poistného pri produktoch neživotného poistenia viac ako dvakrát väčšia v porovnaní s predpísaným poistným pri produktoch neživotného poistenia, pričom sa tento rozdiel neustále zväčšuje. Pre ilustráciu si môžeme uviesť približnú výšku predpísaného poistného na českom poistnom trhu za rok 2022, ktorá je viac ako 157 miliárd Kč, z čoho viac ako 107 miliárd Kč zodpovedá poistnému predpísanému pri produktoch neživotného poistenia. Vidíme teda, že z hľadiska zinkasovaného poistného má na českom poistnom trhu väčšie zastúpenie práve neživotné poistenie.

Pozrime sa ešte na podiel vybraných položiek v neživotnom poistení. Na Obrázku 1.2 môžeme vidieť graf zobrazujúci podiel vybraných položiek neživotného poistenia podľa predpísaného poistného za rok 2022. Vidíme, že najväčší podiel v tejto časti poistného trhu

¹Podľa § 2761 zákona č. 89/2012 Sb. [2] je poistný záujem oprávnená potreba ochrany pred následkami poistnej udalosti.



Obr. 1.1: Vývoj predpísaného zmluvného poistenia podľa metodiky ČAP [3]

tvorí poistenie zodpovednosti z prevádzkovania vozidla², a to až takmer 25 %. Na druhom mieste sa nachádza havarijne poistenie vozidiel s takmer 24% zastúpením. Oba tieto produkty klasifikujeme ako poistenia motorových vozidiel, a ako môžeme vidieť, tak spolu tvoria bežmála polovičný podiel na trhu neživotného poistenia. Práve poisteniu motorových vozidiel sa budeme bližšie venovať v celej tejto diplomovej práci. Samozrejme, kde to bude relevantné a vhodné, tam spomenieme aj ostatné produkty neživotného poistenia. Predstavené techniky môžu byť aplikované aj na iné produkty, pri ktorých ale poisťiteľ nemá vždy k dispozícii dostatočne veľký počet historických dát, a preto musia byť často zvažované aj iné faktory. Pre prehľadnosť a jednoznačnosť, sa ale budeme odvolávať na poistenie motorových vozidiel. Na tomto mieste je teda vhodné pripomenúť rozdiel medzi vyššie spomínanými poisťovacími produktami. Poistenie zodpovednosti z prevádzkovania vozidla patrí medzi povinné zmluvné poistenia a každý vlastník motorového vozidla, ktorý chce prevádzkovať na verejných komunikáciách v Českej republike je povinný si tento typ poistenia zaobstaráť. Hlavným cieľom tohto poistenia je poskytnutie poisťovej ochrany poisťovanému v prípade škody spôsobenej prevádzkovaním vozidla inej, tretej osobe. Poisteného chráni pred možnými nepriaznivými finančnými dopadmi nárokov poškodeného. Všetky práva a povinnosti účastníkov tohto typu poistenia sú spolu s poisťovacími podmienkami definované zákonom č. 168/1999 Sb., o pojištění odpovědnosti za újmu způsobenou provozem vozidla [4]. Havarijne poistenie patrí medzi dobrovoľné zmluvné poistenia, a teda záleží na vlastníckovi vozidla, či si tento produkt zaobstará alebo nie. Tento typ poistenia poskytuje ochranu vlastníckovi vozidla pre prípad jeho zničenia, poškodenia alebo odcudzenia. Predmetom poistenia je vozidlo, takže ide o majetkové poistenie, zatiaľčo pri poistení zodpovednosti z prevádzkovania vozidla ide o poistenie zodpovednosti.

²Často označované aj ako poistenie zodpovednosti za škodu spôsobenú vedením motorového vozidla alebo v Českej republike len skrátené povinné ručení.



Obr. 1.2: Podiel vybraných položiek neživotného poistenia podľa predpísaného poistného za rok 2022 podľa metodiky ČAP [3]

Cieľom tejto kapitoly bolo pripomenúť pár základných informácií o neživotnom poistení, a takisto demonštrovať, aké silné postavenie na poistnom trhu v Českej republike majú poistné produkty zamerané na krytie rizík spojených s prevádzkou motorových vozidiel. V prípade záujmu je možné nájsť všetky relevantné informácie k neživotnému poisteniu v zákone č. 277/2009 Sb., o pojišťovníctví [1]. Aktuálne štatistické údaje sú dostupné na webových stránkach ČAP [3].

Kapitola 2

Pravdepodobnostné rozdelenia počtu poistných nárokov

V Kapitole 1 sme si povedali, aké silné zastúpenie majú produkty neživotného poistenia na českom poistnom trhu. Ukázali sme si, že poistenie motorových vozidiel patrí k najviac využívaným produktom v neživotnom poistení. Rozprávame sa teda o značných finančných čiastkach a predkladá sa nám otázka, akým spôsobom správne určiť poistné, ktoré by mali jednotliví klienti platiť. Práve túto otázku rieši oblasť poistnej matematiky a my sa v ďalšej časti práce pokúsime na túto otázku aspoň čiastočne odpovedať.

Úlohou poistného matematika je navrhnuť tarifnú štruktúru tak, aby klienti platili poistné v takej výške, ktorá čo najlepšie zodpovedá ich rizikovému faktoru. Inak povedané, aké vysoké riziko poistený pre poisťovňu predstavuje, také vysoké poistné by mal platiť. Rizikom sa rozumie pravdepodobnosť vzniku škody. Nastavenie správnej tarifnej štruktúry je samozrejme motivované aj tým, aby bol zabezpečený správny a zodpovedný chod poisťovne, a teda aby poisťovňa nezbankrotovala. Pre jednoduchosť budeme v celej práci predpokladať, že poistený a poistník sú tá istá osoba, čo je v poistení motorových vozidiel bežnou praxou. Výnimkou môže byť, napríklad, keď si havarijne poistenie nového vozidla uzavrie ako poistník leasingový nájomca, ale poistená bude leasingová spoločnosť ako majiteľ vozidla. Na spôsobe výpočtu poistného táto skutočnosť ale nič nemení, keďže riziká ostávajú rovnaké. Pre stanovenie správneho poistného je kľúčová apriórna segmentácia klientov a následná aposteriórna korekcia poistného. Pred podpisom zmluvy s klientom sa snaží poisťovňa získať čo najviac relevantných informácií. Pri poistení motorových vozidiel ide napríklad o typ vozidla, nákupnú cenu a vek vozidla, váhu a výkon vozidla, spôsob využitia a podobne. Všetko sú to apriórne informácie, ktoré vstupujú do procesu tvorby poistného na jeho úplnom začiatku. Po poskytnutí týchto apriórnych informácií je klient priradený do jednej z tarifných skupín danej poisťovne, ktorej prislúcha určitý rizikový faktor a všetci klienti v tejto skupine platia rovnaké základné poistné. V tomto bode by proces tvorby poistného mohol skončiť za predpokladu homogénneho rizika v jednotlivých tarifných skupinách. Keďže ale chceme, aby každý klient platil spravodlivé poistné reflektujúce jeho rizikovosť, tak musíme brať ohľad aj na iné, ťažšie identifikovateľné premenné, ktoré nám vstupujú do tohto procesu. Pre poisťovňu je veľmi náročné na začiatku poistného procesu zistiť informácie, ako napríklad vodičské schopnosti klienta, potenciálnu zvýšenú

agresivitu za volantom, schopnosť rýchlo reagovať v nepredvídateľných situáciách a podobne. Tieto informácie budú určite vplývať na rizikovosť daného klienta, ale pre poisťiteľa je veľmi obtiažne ich získať, či dokonca odmerať. Je ale možné sledovať počet dopravných nehôd, ktoré daný klient ohlásil v určitom období. K tomu nám slúži bonus-malus systém, na základe ktorého je daný klient odmenený zľavou na poistnom za každý rok bez ohlásenej nehody, a naopak potrestaný prirážkou k poistnému za jednu a viac ohlásených dopravných nehôd. Aposteriórna korekcia poistného je potom uskutočnená práve prostredníctvom bonus-malus systému, ktorý umožňuje znižovať zostatkovú heterogenitu v jednotlivých tarifných skupinách klientov. Tento mechanizmus umožňuje klientom platiť spravodlivejšie poistné, ktoré presnejšie odzrkadľuje ich rizikový faktor. Hlbší pohľad na prechod od rizikovej klasifikácie klientov na základe očakávaného počtu poistných nárokov až po bonus-malus poskytuje vo svojej publikácii napríklad Denuit a kol. [5], kde je táto problematika dobre spracovaná a demonštrovaná na konkrétnych príkladoch. Táto diplomová práca je písaná ako náväznosť na bakalársku prácu s názvom Bonus malus systémy v pojišťení [6], ktorá sa zameriava práve na aposteriórnu korekciu poistného prostredníctvom bonus-malus systémov. V tejto diplomovej práci sa preto zameriame na prvú časť procesu tvorby poistného, a síce na apriórnu segmentáciu klientov do tarifných skupín. Pred tým, ako sa dostaneme k samotnému problému segmentácie klientov, tak si na začiatok v tejto kapitole uvedieme najčastejšie používané pravdepodobnostné rozdelenia používané v neživotnom poistení.

Keďže základným predpokladom vzniku poistnej udalosti je náhoda (t. j. nie je dopredu známe kedy a či vôbec bude poistné plnenie vyplatené), tak počet poistných nárokov na jednu poistnú zmluvu behom jedného roku budeme označovať náhodnou veličinou N . Ide o diskretnú náhodnú veličinu, ktorá môže nadobúdať hodnoty z množiny prirodzených čísel vrátane 0 (t. j. z množiny $\mathbb{N}_0$). V rámci tejto kapitoly si postupne predstavíme pravdepodobnostné rozdelenia popisujúce túto náhodnú veličinu. Pôjde o takzvané počítacie rozdelenia³. Povieme si ich základné vlastnosti, a tiež predpoklady pre ich použitie. Ku každému pravdepodobnostnému rozdeleniu si uvedieme príslušnú strednú hodnotu a rozptyl. Pokúsime sa ukázať vzťahy medzi jednotlivými pravdepodobnostnými rozdeleniami. Budeme čerpať najmä z publikácie skupiny autorov Klugman, Panjer a Willmot [7], ďalej z textu publikácie od autorov de Jong a Heller [8]. Opierať sa budeme aj od teóriu ohľadom pravdepodobnosti a štatistiky zhrnutú autormi Zvára a Štěpán [9].

Pre úplnosť je potrebné dodať, že pri neživotnom poistení sa najčastejšie jedná o škodové poistene. Takže pri nastavovaní vhodnej tarifnej štruktúry musí poisťiteľ brať do úvahy nielen počet poistných nárokov, ale aj výšku jednotlivých poistných nárokov. Čisté netto poistné je potom definované ako súčin frekvencie a výšky poistných nárokov. Túto skutočnosť popisuje kolektívny model rizika. Tento model nám hovorí o tom, že celkový poistný nárok, ktorý vznikol v portfóliu poistných zmlúv za dané obdobie, je súčet jednotlivých poistných nárokov, ktoré sú vzájomne nezávislé a majú rovnaké pravdepodobnostné rozdelenie. V takomto modeli je teda náhodný aj samotný počet poistných nárokov, aj výška

³Počítacie rozdelenia sú diskretné rozdelenia s pravdepodobnosťami definovanými len na nezáporných celých číslach. V niektorej literatúre sa môžeme stretnúť aj s pojmom rozdelenia škôd, resp. v anglickej literatúre s pojmom *loss distributions*.

jednotlivých poistných nárokov. V tejto diplomovej práci sa budeme ale venovať len počtu poistných nárokov a ukážeme si techniky, pomocou ktorých je možné segmentovať klientov práve na základe frekvencie ich predpokladanej nehodovosti. Z komplexnejšieho hľadiska sa na túto problematiku pozerá napríklad Kaas [10], Mikosch [11] alebo Ohlsson s Johansson [12].

2.1 Binomické rozdelenie

Prvým počítacím rozdelením, ktoré sa nám prirodzene ponúka na modelovanie počtu poistných nárokov je binomické rozdelenie.

Definícia 2.1. Náhodná veličina N sa riadi binomickým rozdelením s parametrami $v \in \mathbb{N}$ a $p \in (0, 1)$, zapisujeme $N \sim Bi(v, p)$, ak jej pravdepodobnostná funkcia je v tvare

$$P(N = y) = \begin{cases} \binom{v}{y} p^y (1-p)^{v-y} & \text{pre } y = 0, 1, 2, \dots, v \\ 0 & \text{inak.} \end{cases}$$

Poznámka 2.1. Hodnota binomického koeficientu pre $x, y \in \mathbb{N}_0$ je daná vzťahom

$$\binom{x}{y} = \begin{cases} \frac{x!}{y!(x-y)!} & \text{pre } 0 \leq y \leq x, \\ 0 & \text{inak.} \end{cases}$$

Faktoriál zapísaný pomocou gamma funkcie (t.j. $x! = \Gamma(x+1)$) umožňuje binomický koeficient zovšeobecniť aj na reálne (dokonca aj komplexné) hodnoty x, y . Binomický koeficient je potom v tvare

$$\binom{x}{y} = \frac{\Gamma(x+1)}{\Gamma(y+1)\Gamma(x-y+1)} = \exp\{\ln\Gamma(x+1) - \ln\Gamma(y+1) - \ln\Gamma(x-y+1)\},$$

kde $\ln\Gamma(x)$ označuje prirodzený logaritmus gamma funkcie v x . Tento tvar binomického koeficientu môže byť užitočný pri používaní rôznych programovacích jazykov, ktoré nemajú preddefinovanú funkciu na výpočet binomického koeficientu. Naopak, funkcia $\ln\Gamma(\cdot)$ býva štandardnou výbavou väčšiny programovacích jazykov, takže vieme jednoducho a rýchlo spočítať binomický koeficient. Túto funkciu nájdeme napríklad pod názvom `gammaaln` v programovacom jazyku MATLAB a Python alebo `lgamma` v jazykoch C a R.

Binomické rozdelenie je teda dvoj-parametrické rozdelenie, kde parameter v označuje počet nezávislých pokusov a parameter p označuje pravdepodobnosť „úspechu“ v danom pokuse. Môžeme vidieť, že pravdepodobnostné rozdelenie závisí na neznámom parametri p , pričom parameter v je známy. V našom kontexte to môžeme poňať ako v nezávislých poistných zmlúv v portfóliu, kde p je pravdepodobnosť, že na jednej poistnej zmluve dôjde behom sledovaného obdobia k poistnej udalosti. Binomické rozdelenie je v podstate zovšeobecnením alternatívneho⁴ rozdelenia.

⁴Niekedy označované aj ako Bernoulliho rozdelenie.

Poznámka 2.2 (Alternatívne rozdelenie). Náhodná veličina N sa riadi alternatívnym rozdelením s parametrom $p \in (0, 1)$, zapisujeme $N \sim \text{Alt}(p)$, ak jej pravdepodobnostná funkcia je v tvare

$$P(N = y) = \begin{cases} p^y(1-p)^{1-y} & \text{pre } y = 0, 1, \\ 0 & \text{inak.} \end{cases}$$

Je zjavné, že alternatívne rozdelenie je len špeciálnym prípadom binomického rozdelenia pre $v = 1$ (t.j. $N \sim \text{Bi}(1, p)$). Výskyt poistnej udalosti pri jednotlivých zmluvách v portfóliu môže potom sledovať alternatívne rozdelenie s parametrom p a celkový počet ohlásených poistných udalostí v portfóliu poistných zmlúv bude súčtom jednotlivých náhodných veličín s alternatívnym rozdelením.

Nosič⁵ (angl. *support*) binomického rozdelenia je konečný (t. j. množina hodnôt, pre ktoré existujú kladné hodnoty pravdepodobnosti, je konečná), a preto je použitie tohto rozdelenia užitočné v prípadoch, keď máme definovanú hornú hranicu pre počet poistných nárokov. Použitie binomického rozdelenia môže byť taktiež užitočné v situáciách, keď sa predpokladá, že pripisovanie kladných pravdepodobností hodnotám prekračujúcim určitý bod nie je dostatočne odôvodnené, a teda nerozumné. Autori Klugman, Panjer a Willmot [7, str. 86] uvádzajú ako príklad modelovanie počtu nehôd v poistení motorových vozidiel v priebehu jedného roka. Uvádzajú, že je pravdepodobne fyzicky nemožné, aby klient na jednu poistnú zmluvu ohlásil viac ako 12 nehôd za jeden kalendárny rok. Toto tvrdenie dáva pochopiteľne zmysel, ak vezme do úvahy čas potrebný na opravu automobilu medzi jednotlivými nehodami. Ak by predsa len bol model rozšírený a použili by sa aj pravdepodobnosti pre viac ako 12 dopravných nehôd v priebehu jedného kalendárneho roka, tak by tieto pravdepodobnosti boli veľmi malé, a teda by mali len veľmi malý vplyv na rozhodnutia prijímané poskytovateľom poistenia.

Stredná hodnota náhodnej veličiny $N \sim \text{Bi}(v, p)$ je v tvare

$$E(N) = vp \quad (2.1)$$

a rozptyl

$$\text{Var}(N) = vp(1-p). \quad (2.2)$$

Keď porovnáme strednú hodnotu (2.1) a rozptyl (2.2), tak si môžeme všimnúť charakteristickú vlastnosť binomického rozdelenia, a síce, že rozptyl je vždy menší ako stredná hodnota. Túto vlastnosť binomického rozdelenia nazývame *underdispersion* (angl. *underdispersion*). Použitie tohto rozdelenia je vhodné pre dáta, ktoré spĺňajú túto vlastnosť. Binomické rozdelenie nemusí byť vhodné pre niektoré produkty neživotného poistenia, obzvlášť napríklad pre poistenie motorových vozidiel, kde je rozsah poistného kmeňa⁶ (t. j. parameter v) spravidla veľký a pravdepodobnosť poistnej udalosti (t. j. parameter p) malá. Preto môžeme prejsť k aproximácii Poissonovým rozdelením.

⁵Nosičom funkcie $f : X \rightarrow \mathbb{R}$ rozumieme uzáver množiny $\{x \in X : f(x) \neq 0\}$. Značíme ho ako $\text{supp } f$.

⁶Súbor poistných zmlúv podobného typu.

2.2 Poissonovo rozdelenie

Definícia 2.2. Náhodná veličina N sa riadi Poissonovým rozdelením s parametrom $\lambda > 0$, značíme $N \sim \text{Pois}(\lambda)$, ak jej pravdepodobnostná funkcia je v tvare

$$P(N = y) = \begin{cases} \frac{\lambda^y}{y!} e^{-\lambda} & \text{pre } y = 0, 1, 2, \dots, \\ 0 & \text{inak.} \end{cases}$$

Poissonovo rozdelenie je jedno-parametrické rozdelenie s parametrom $\lambda > 0$, ktorý označuje počet „úspechov“ vo veľkom počte nezávislých pokusov s malou pravdepodobnosťou „úspechu“. Toto rozdelenie popisuje výskyt riedkych javov za určitú jednotku času, priestoru a podobne. Často sa môžeme stretnúť aj s označeniami ako rozdelenie riedkych javov alebo zákon malých čísel. Poissonovo rozdelenie je základným rozdelením počtu poistných udalostí, a teda patrí medzi najčastejšie využívané rozdelenia pre modelovanie počtu dopravných nehôd v poistení motorových vozidiel.

V sekcii 2.1 sme si povedali, že pri neživotnom poistení, obzvlášť pri poistení motorových vozidiel, je rozsah poistného kmeňa spravidla veľký a pravdepodobnosť poistnej udalosti je malá. Ukážme si, že binomické rozdelenie môžeme aproximovať Poissonovým rozdelením, respektíve, že Poissonovo rozdelenie je limitným prípadom binomického rozdelenia.

Veta 2.1. Uvažujme binomické rozdelenie s parametrami v, p . Ak $v \rightarrow \infty$ a $p \rightarrow 0$ takým spôsobom, že $vp = \lambda$, kde λ je kladná konštanta, potom y -ty člen binomického rozdelenia

$$\binom{v}{y} p^y (1-p)^{v-y}$$

konverguje ku y -temu členu Poissonovho rozdelenia

$$\frac{\lambda^y}{y!} e^{-\lambda}.$$

Dôkaz. Ak $N \sim \text{Bi}(v, p)$ a $\lim_{v \rightarrow \infty} vp = \lambda > 0$, za predpokladu, že $v \rightarrow \infty$ a $p \rightarrow 0$, potom si označme $vp = \lambda$, a teda $p = \frac{\lambda}{v}$. Ďalej nech $y = 0, 1, 2, \dots$ je pevne zvolené číslo. Teraz počítajme nasledujúcu limitu

$$\begin{aligned} \lim_{v \rightarrow \infty} P(N = y) &= \lim_{v \rightarrow \infty} \binom{v}{y} p^y (1-p)^{v-y} = \lim_{v \rightarrow \infty} \frac{v!}{y!(v-y)!} \left(\frac{\lambda}{v}\right)^y \left(1 - \frac{\lambda}{v}\right)^{v-y} \\ &= \lim_{v \rightarrow \infty} \frac{\lambda^y}{y!} \underbrace{\frac{v}{v}}_{\rightarrow 1} \underbrace{\frac{v-1}{v}}_{\rightarrow 1} \dots \underbrace{\frac{v-y+1}{v}}_{\rightarrow 1} \underbrace{\left(1 - \frac{\lambda}{v}\right)^v}_{\rightarrow e^{-\lambda}} \underbrace{\left(1 - \frac{\lambda}{v}\right)^{-y}}_{\rightarrow 1} \\ &= \frac{\lambda^y}{y!} e^{-\lambda}. \end{aligned}$$

□

V dôkaze Vety 2.1 sme si ukázali, že Poissonovo rozdelenie je limitným rozdelením pre binomické rozdelenie. Predstavme si teraz jeho základné charakteristiky. Pre náhodnú veličinu $N \sim Poi(\lambda)$ platí nasledovný vzťah:

$$E(N) = \text{Var}(N) = \lambda,$$

čiže stredná hodnota je rovná rozptylu. Táto vlastnosť sa nazýva ekvidisperzia (angl. *equidispersion*). Model Poissonovho rozdelenia preto nie je vhodné použiť napríklad v situácii, keď rozptyl počtu poistných udalostí výrazne prevyšuje strednú hodnotu. Poissonovo rozdelenie má ale dve užitočné vlastnosti, ktoré si zhrnieme v nasledujúcich vetách.

Veta 2.2. *Nech $N_1, N_2, \dots, N_k$ sú nezávislé náhodné veličiny s Poissonovým rozdelením a s parametrami $\lambda_1, \lambda_2, \dots, \lambda_k$. Potom súčet $N = N_1 + N_2 + \dots + N_k$ má tiež Poissonovo rozdelenie s parametrom $\lambda_1 + \lambda_2 + \dots + \lambda_k$.*

Dôkaz. Plyní z tvrdenia, že generujúca funkcia súčtu nezávislých náhodných veličín je rovná súčinu generujúcich funkcií jednotlivých náhodných veličín. Tvrdenie je možné nájsť u autorov Klugmana, Panjera a Willmota [7, str. 29] a celý dôkaz je dostupný taktiež v tejto publikácii [7, str. 81]. $\square$

Veta 2.3. *Predpokladajme, že počet udalostí je vyjadrený náhodnou veličinou N s Poissonovým rozdelením a strednou hodnotou λ . Ďalej predpokladajme, že každá udalosť môže byť zaradená do jednej z m skupín s pravdepodobnosťami $p_1, p_2, \dots, p_m$, pričom všetky udalosti sú navzájom nezávislé. Potom náhodné veličiny $N_1, N_2, \dots, N_m$ vyjadrujúce počet udalostí v jednotlivých skupinách $1, 2, \dots, m$ sú navzájom nezávislé a riadia sa Poissonovým rozdelením so strednými hodnotami $\lambda p_1, \lambda p_2, \dots, \lambda p_m$.*

Dôkaz. Dôkaz je dostupný u autorov Klugmana, Panjera a Willmota [7, str. 82]. $\square$

Vlastnosť plynúca z Vety 2.3 je užitočná napríklad pri modelovaní poistných rizík. Opäť predpokladajme poistenie motorových vozidiel. Počet poistných udalostí za nejaké pevne stanovené časové obdobie, napríklad jeden kalendárny rok, sa riadi Poissonovým rozdelením. Predpokladajme, že poistné udalosti môžu byť rozdelené do m rozličných skupín. Poistné udalosti môžu byť rozdelené napríklad podľa veľkosti poistného plnenia. Pre jednoduchosť uvažujme len dve skupiny, a to poistné udalosti pod fixným limitom a poistné udalosti nad fixným limitom. Obe skupiny sa riadia Poissonovým rozdelením, pričom ale parametre Poissonovho rozdelenia pre obe skupiny sú rôzne. Obe skupiny, respektíve pravdepodobnostné rozdelenia popisujúce počet poistných udalostí v jednotlivých skupinách, budú navyše navzájom nezávislé. Táto vlastnosť je takisto užitočná v prípade, keď poisťiteľ rozhoduje o úprave rozsahu poistného krytia.

2.3 Negatívne binomické rozdelenie

Definícia 2.3. Náhodná veličina N sa riadi negatívne binomickým rozdelením s parametrami $r > 0$ a $p \in (0, 1)$, značíme $N \sim NeBi(r, p)$, ak jej pravdepodobnostná funkcia je v tvare

$$P(N = y) = \begin{cases} \binom{r+y-1}{y} p^r (1-p)^y & \text{pre } y = 0, 1, 2, \dots, \\ 0 & \text{inak.} \end{cases} \quad (2.3)$$

Negatívne binomické rozdelenie je dvoj-parametrické rozdelenie a pre celočíselné r ho môžeme interpretovať ako počet „neúspechov“ pred r -tým „úspechom“ v rade alternatívnych pokusov s pravdepodobnosťou „úspechu“ p . V niektorých publikáciách sa môžeme stretnúť aj s názvami ako Pascalovo alebo Pólyovo rozdelenie. Negatívne binomické rozdelenie sa často využíva ako alternatíva ku Poissonovmu rozdeleniu, pretože vďaka dvom parametrom má negatívne binomické rozdelenie flexibilnejší tvar ako spomínané Poissonovo. Stredná hodnota náhodnej veličiny $N \sim \text{NeBi}(r, p)$ je rovná

$$E(N) = \frac{r(1-p)}{p}$$

a rozptyl je v tvare

$$\text{Var}(N) = \frac{r(1-p)}{p^2}.$$

Keďže $p \in (0, 1)$, potom výraz $\frac{1-p}{p} > 0$, a teda rozptyl negatívneho binomického rozdelenia je väčší ako jeho stredná hodnota. Túto vlastnosť nazývame *overdispersion* (angl. *overdispersion*) a pre dáta, ktorých rozptyl značne prevyšuje strednú hodnotu, je vhodné na modelovanie použiť práve negatívne binomické rozdelenie.

Poznámka 2.3 (Geometrické rozdelenie). Špeciálnym prípadom negatívneho binomického rozdelenia pre $r = 1$ je geometrické rozdelenie, ktoré interpretujeme ako počet „neúspechov“ pred prvým „úspechom“. Náhodnú veličinu N , ktorá sa riadi geometrickým rozdelením s parametrom $p \in (0, 1)$, značíme $N \sim \text{Ge}(p)$. Pravdepodobnostnú funkciu takejto náhodnej veličiny môžeme odvodiť z pravdepodobnostnej funkcie (2.3) dosadením za $r = 1$. Geometrické rozdelenie je, v istom zmysle, diskretnou analógiou k spojitému exponenciálnemu rozdeleniu, ktoré je možné použiť napríklad pri modeloch výšky poistných nárokov. Obe rozdelenia, geometrické aj exponenciálne, majú exponenciálne klesajúcu pravdepodobnostnú funkciu, respektíve pravdepodobnostnú hustotu, a preto sú obe charakteristické takzvanou bezpamäťovosťou (angl. *memoryless property*). Pri geometrickom rozdelení popisujúcom počet poistných nárokov si môžeme túto vlastnosť interpretovať ako $P(N > m + n \mid N \geq m) = P(N > n)$, kde $m, n \in \mathbb{N}_0$. Pri počítacích rozdeleniach platí, že rozdelenia, ktoré klesajú v chvostoch pomalšie ako geometrické rozdelenie sú často považované za rozdelenia s ťažkými chvostami. Naopak rozdelenia, ktoré klesajú rýchlejšie ako geometrické, majú zvyčajne ľahké chvosty. Negatívne binomické rozdelenie má v tom prípade ťažké chvosty, ak $r < 1$ a ľahké chvosty, ak $r > 1$.

V Definícii 2.3 sme si uviedli tvar pravdepodobnostnej funkcie, ktorý sa používa zvyčajne v prípadoch, keď $r \in \mathbb{N}_0$. V Poznámke 2.1 sme si ale povedali, že binomický koeficient vieme zovšeobecniť na všetky reálne čísla pomocou gamma funkcie. Pri negatívnom binomickom rozdelení pre $r > 0$ a $p \in (0, 1)$ sa preto často stretávame aj s pravdepodobnostnou funkciou v tvare

$$P(N = y) = \begin{cases} \frac{\Gamma(y+r)}{y!\Gamma(r)} p^r (1-p)^y & \text{pre } y = 0, 1, 2, \dots, \\ 0 & \text{inak.} \end{cases} \quad (2.4)$$

Na začiatku tejto sekcie sme si povedali, že negatívne binomické rozdelenie sa často používa ako alternatíva k Poissonovmu rozdeleniu pri modelovaní počtu poistných nárokov. Načrtnime si teraz pár základných spojitostí medzi týmito dvoma rozdeleniami. Negatívne binomické rozdelenie môžeme vytvoriť prostredníctvom zmiešaného Poissonovho rozdelenia s gamma rozdelením. Vychádzajme z predpokladu, že parameter Poissonovho rozdelenia je náhodná veličina Λ s príslušnou hustotou $u(\lambda)$, kde $\lambda > 0$. Predpokladajme ďalej, že podmienené rozdelenie náhodnej veličiny N , pri danom $\Lambda = \lambda$, je Poissonovo rozdelenie s parametrom λ . Takýto zmiešaný model môžeme uvažovať napríklad v poistnom kmeni, kde je možné modelovať počty poistných nárokov na jednotlivých poistných zmluvách Poissonovým rozdelením, pričom poistný kmeň je rizikovo heterogénny. Pri poistení motorových vozidiel môže byť zdrojom heterogenity napríklad typ vozidla, výkon, využitie vozidla a podobne. Heterogenita v poistnom kmeni je myslená v tom zmysle, že rôznym poistným zmluvám môžu prislúchať rozdielne parametre λ . Parameter λ v podstate meria očakávaný počet poistných nárokov na určitú poistnú zmluvu, respektíve na určitého klienta. Opäť si ako príklad vezmeme poistenie motorových vozidiel, kde sa môže parameter λ meniť naprieč celou populáciou vodičov. Pre konkrétneho vodiča je parameter λ pre poistiteľa neznámy, ale poistiteľ predpokladá, že tento parameter sa riadi nejakým pravdepodobnostným rozdelením s hustotou $u(\lambda)$. V bayesovskom kontexte sa pravdepodobnostné rozdelenie náhodnej veličiny Λ nazýva apriórne rozdelenie a hustota $u(\lambda)$ hrá dôležitú úlohu v teórii kredibility, a taktiež pri aposteriórnej korekcii poistného prostredníctvom bonus-malus systému. Nepodmienenú hustotu náhodnej veličiny N označujúcej počet poistných nárokov v tomto zmiešanom Poissonovom modeli odvodíme pomocou vzťahu

$$P(N = y) = E[P(N = y | \Lambda)] = \int_0^\infty P(N = y | \Lambda = \lambda) u(\lambda) d\lambda = \int_0^\infty \frac{\lambda^y}{y!} e^{-\lambda} d\lambda.$$

Pre strednú hodnotu tohto rozdelenia platí

$$E(N) = E[E(N | \Lambda)] = E(\Lambda)$$

a rozptyl je v tvare

$$\text{Var}(N) = E(\Lambda) + \text{Var}(\Lambda).$$

Ako môžeme vidieť, tak tento postup vedie k rozdeleniu počtu poistných nárokov, ktorého rozptyl je väčší ako stredná hodnota. Ak navyše zvolíme gamma rozdelenie ako pravdepodobnostné rozdelenie náhodnej veličiny Λ v uvedenom zmiešanom Poissonovom modeli, tak dostávame práve spomínané negatívne binomické rozdelenie. Celý postup je možné opäť nájsť u autorov Klugmana, Panjera a Willmota [7, str. 84-86] a využívané vzťahy sú takisto odvodené v tej istej publikácii.

Za zmienku ešte stojí jeden vzťah medzi Poissonovým rozdelením a negatívne binomickým rozdelením. Poissonovo rozdelenie je limitným prípadom negatívneho binomického rozdelenia. Je to možné ukázať pomocou generujúcich funkcií oboch rozdelení. Dôkaz tohto vzťahu môžeme nájsť u Klugmana, Panjera a Willmota [7, str. 85].

Poznámka 2.4. Pri zovšeobecnených lineárnych modeloch je vhodná následná parametrizácia pravdepodobnostnej funkcie (2.4):

$$\lambda = \frac{r(1-p)}{p}, \quad \kappa = \frac{1}{r}.$$

Použitím tejto parametrizácie dostaneme nasledujúci tvar pravdepodobnostnej funkcie

$$P(N=y) = \begin{cases} \frac{\Gamma(y + \frac{1}{\kappa})}{y! \Gamma(\frac{1}{\kappa})} \left(\frac{1}{1 + \kappa\lambda} \right)^{\frac{1}{\kappa}} \left(\frac{\kappa\lambda}{1 + \kappa\lambda} \right)^y, & \text{pre } y = 0, 1, 2, \dots, \\ 0 & \text{inak,} \end{cases} \quad (2.5)$$

a potom príslušný tvar strednej hodnoty a rozptylu môžeme zapísať nasledujúcim spôsobom:

$$E(N) = \lambda, \quad \text{Var}(N) = \lambda(1 + \kappa\lambda). \quad (2.6)$$

Parameter κ sa nazýva overdispersný parameter. Je zrejmé, že pre overdispersný parameter $\kappa = 0$ platí $E(N) = \text{Var}(N) = \lambda$, čo je vzťah typický pre Poissonovo rozdelenie. Pri zovšeobecnených lineárnych modeloch je táto parametrizácia využívaná pri rozhodovaní o vhodnosti Poissonovho regresného modelu, respektíve negatívneho binomického modelu.

Poznámka 2.5. Pripomenutie vzťahov medzi strednou hodnotou a rozptylom náhodnej veličiny N , ktorá sa riadi nasledujúcimi rozdeleniami.

- Binomické rozdelenie: $E(N) > \text{Var}(N)$ (t.j. underdispéria).
- Poissonovo rozdelenie: $E(N) = \text{Var}(N)$ (t.j. ekvidispéria).
- Negatívne binomické rozdelenie: $E(N) < \text{Var}(N)$ (t.j. overdispéria).

Poznámka 2.6. Predpokladajme všeobecnejší príklad, keď náhodná veličina N označuje celkový počet poistných nárokov behom jedného roka v k navzájom nezávislých poistných zmluvách. Náhodná veličina N_i bude udávať počet poistných nárokov behom jedného roka prislúchajúci i -tej poistnej zmluve, pričom $i = 1, 2, \dots, k$. Celkový počet poistných nárokov bude teda rovný $N = N_1 + N_2 + \dots + N_k$. Z vlastností uvažovaných pravdepodobnostných rozdelení plynú:

- ak $N_i \sim Bi(v_i, p)$, potom $N \sim Bi(v_1 + v_2 + \dots + v_k, p)$;
- ak $N_i \sim Pois(\lambda_i)$, potom $N \sim Pois(\lambda_1 + \lambda_2 + \dots + \lambda_k)$;
- ak $N_i \sim NeBi(r_i, p)$, potom $N \sim NeBi(r_1 + r_2 + \dots + r_k, p)$.

Poznámka 2.7. Pri dostatočne veľkom poistnom kmeni môžeme namiesto jednotlivých pravdepodobnostných rozdelení použiť aproximáciu normálnym rozdelením. Daná aproximácia je možná vďaka platnosti centrálnej limitnej vety, ktorá nám v teórii pravdepodobnosti označuje tvrdenie, podľa ktorého sa rozdelenie výberového priemeru po vhodnej normalizácii blíži k normálnemu rozdeleniu.

2.4 Modifikované rozdelenia

2.4.1 Trieda rozdelení $(a, b, 0)$

Ako sme si mohli všimnúť, všetky vyššie spomenuté rozdelenia, menovite binomické, Poissonovo a negatívne binomické rozdelenie, sú úzko prepojené. V predchádzajúcej podkapitole sme si ukázali limitné vzťahy medzi spomínanými rozdeleniami, povedali sme si, že sa označujú aj ako počítacie rozdelenia a uvideli sme si ich základné vlastnosti. Práve tieto tri rozdelenia spolu tvoria špeciálnu triedu rozdelení, ktorú nazývame trieda rozdelení $(a, b, 0)$ alebo aj Panjerova trieda rozdelení.

Definícia 2.4. Nech $P(N = y)$ je pravdepodobnostná funkcia popisujúca rozdelenie diskretnej náhodnej veličiny N . Potom povieme, že toto rozdelenie je členom triedy $(a, b, 0)$, ak existujú reálne konštanty a, b také, že platí nasledujúci vzťah

$$\frac{P(N = y)}{P(N = y - 1)} = a + \frac{b}{y} \quad \text{pre } y = 1, 2, 3, \dots \quad (2.7)$$

Pravdepodobnosť $P(N = 0)$ dopočítame z podmienky $\sum_{y=0}^{\infty} P(N = y) = 1$.

Vyššie uvedený rekurzívny vzťah popisuje relatívnu veľkosť po sebe nasledujúcich pravdepodobností počítacieho rozdelenia. Je možné dokázať, že jediné rozdelenia, ktoré sa dajú zapísať pomocou vzťahu (2.7) sú práve binomické, Poissonovo a negatívne binomické rozdelenie (viď. [7]).

Poznámka 2.8. Hodnoty konštánt a, b pre rozdelenia z triedy $(a, b, 0)$ sú nasledovné:

- pre binomické rozdelenie je $a = -\frac{p}{1-p} < 0$, $b = (v+1)\frac{p}{1-p}$;
- pre Poissonovo rozdelenie je $a = 0$, $b = \lambda$;
- pre negatívne binomické rozdelenie je $a = 1-p > 0$, $b = (r-1)(1-p)$.

Poznámka 2.9. Pomocou vzťahu (2.7) môžeme určiť vhodný model pre konkrétny dátový súbor s veľkým množstvom pozorovaní nasledujúcim spôsobom.

1. Vzťah (2.7) prepíšeme do nasledujúceho tvaru

$$\frac{P(N = y)}{P(N = y - 1)} y = ak + b, \quad y = 1, 2, 3, \dots$$

2. Podiel $\frac{P(N = y)}{P(N = y - 1)}$ odhadneme z dátového súboru na základe pozorovaných početností n_k, n_{y-1} a hodnôt $y, y - 1$. Môžeme to zapísať nasledujúcim spôsobom

$$\frac{\widehat{P(N = y)}}{\widehat{P(N = y - 1)}} y = \frac{n_k}{n_{y-1}} y.$$

3. Graf prechádzajúci bodmi $\left[y, \frac{n_k}{n_{y-1}} y\right]$ by mal približne vykazovať lineárny priebeh a podľa smernice a danej priamky zvolíme potom vhodný model. Z Poznámky 2.8 je zrejmé, že záporná smernica indikuje binomické rozdelenie, nulová smernica indikuje Poissonovo rozdelenie a kladná smernica indikuje negatívne binomické rozdelenie. Treba však brať na vedomie že n_k musí byť nenulové pre všetky hodnoty y . Z tohto dôvodu je tento prístup menej užitočný pre dátové súbory s malým počtom pozorovaní.

2.4.2 Trieda rozdelení $(a, b, 1)$

Rozdelenia triedy $(a, b, 0)$ často nepopisujú adekvátne dáta z poistnej praxe. Ako príklad nám poslúži poistenie zodpovednosti za škodu spôsobenú vedením motorového vozidla alebo havarijne poistenie.⁷ Ako už vieme, v oboch prípadoch ide o škodové poistenia a zaujíma nás počet nahlásených nehôd za sledované obdobie, ktorým je zvyčajne jeden kalendárny rok. Ak budeme uvažovať adekvátne veľký poistný kmeň, tak pri drvivej väčšine poistných zmlúv nedôjde k žiadnej nahlásenej nehode počas sledovaného obdobia. Inak povedané, pravdepodobnosť toho, že $N = 0$ je omnoho väčšia ako pravdepodobnosť $N = y$, pre $y = 1, 2, \dots$. Túto skutočnosť je potrebné pri modelovaní počtu škôd nejakým spôsobom zohľadniť, a preto si predstavíme triedu rozdelení $(a, b, 1)$, ktorá je vlastne rozšírením triedy rozdelení $(a, b, 0)$.

Definícia 2.5. Nech $P(N = y)$ je pravdepodobnostná funkcia popisujúca rozdelenie diskretnej náhodnej veličiny N . Potom povieme, že toto rozdelenie je členom triedy $(a, b, 1)$, ak existujú reálne konštanty a, b také, že platí nasledujúci vzťah

$$\frac{P(N = y)}{P(N = y - 1)} = a + \frac{b}{y} \quad \text{pre } y = 2, 3, 4, \dots \quad (2.8)$$

Súčet pravdepodobností $\sum_{y=1}^{\infty} P(N = y)$ môže nadobúdať ľubovoľnú hodnotu na intervale $(0, 1]$. Pre pravdepodobnosť v 0 potom platí

$$P(N = 0) = 1 - \sum_{y=1}^{\infty} P(N = y).$$

Trieda rozdelení $(a, b, 1)$ sa odlišuje od triedy rozdelení $(a, b, 0)$ len tým, že rekurentný vzťah (2.8) začína v hodnote $P(N = 1)$, a nie v hodnote $P(N = 0)$.

2.4.3 Rozdelenia modifikované v 0

Pri triede rozdelení $(a, b, 1)$ zvyčajne rozlišujeme dve podtriedy. Ak je $P(N = 0) > 0$, hovoríme o rozdelení modifikovanom v 0 a pravdepodobnostnú funkciu značíme ako $p_N^M(y)$.⁸ Ak je $P(N = 0) = 0$, tak hovoríme o rozdelení odseknutom v 0 a pravdepodobnostnú funkciu značíme ako $p_N^T(y)$. Anglické ekvivalentné názvy pre tieto podtriedy sú *zero-modified*

⁷Ďalším príkladom je poistenie majetku alebo poistenie zodpovednosti vo všeobecnosti.

⁸Značenie: $p_N(y) = P(N = y)$.

distribution, respektíve *zero-truncated distribution*.

Na rozdelenia modifikované v 0 sa môžeme pozerať ako na zmes rozdelenia triedy $(a, b, 0)$ a degenerovaného rozdelenia so všetkými pravdepodobnosťami v 0. Platí nasledujúci vzťah

$$p_N^M(y) = \frac{1 - p_N^M(0)}{1 - p_N(0)} p_N(y) \quad \text{pre } y = 1, 2, \dots \quad (2.9)$$

Vzťah (2.9) je možné jednoducho odvodiť pomocou generujúcich funkcií. Celé odvedenie je možné nájsť u Klugmana, Panjera a Willmota [7, str. 91]. Rozdelenia odsekuté v 0 môžeme chápať ako špeciálny prípad modifikovaného rozdelenia s hodnotou $p_N^M(0) = 0$. Po zohľadnení tejto skutočnosti dostávame z (2.9) nasledujúci vzťah

$$p_N^T(y) = \frac{1}{1 - p_N(0)} p_N(y) \quad \text{pre } y = 1, 2, \dots$$

Poznámka 2.10 (Degenerované rozdelenie). Diskrétna náhodná veličina N sa riadi degenerovaným rozdelením s parametrom $c \in \mathbb{R}$, ak jej pravdepodobnostná funkcia je v tvare

$$P(N = y) = \begin{cases} 1 & \text{pre } y = c, \\ 0 & \text{inak.} \end{cases}$$

Poznámka 2.11 (ETNB). Povedali sme si, že do triedy rozdelení $(a, b, 0)$ patria len binomické, Poissonovo a negatívne binomické rozdelenie. Avšak, do triedy rozdelení $(a, b, 1)$ môžeme zaradiť ešte jedno dodatočné rozdelenie, ktoré označujeme ako rozšírené odsekuté negatívne binomické rozdelenie alebo skrátene len ETNB⁹ rozdelenie. Ak si pripomenieme vlastnosti negatívneho binomického rozdelenia zo strany 11, tak je nám jasné, že pri triede rozdelení $(a, b, 0)$ sa vyžaduje, aby bol parameter $r > 0$. Kombinácie parametrov a, b pri negatívnom binomickom rozdelení umožňujú rozšíriť toto rozdelenie aj na prípady, keď $r \in (-1, 0)$. Množina všetkých možných hodnôt parametru r je teda rozšírená z $r > 0$ na $r > -1$, pričom $r \neq 0$. Pravdepodobnostná funkcia ETNB rozdelenia je potom v tvare

$$p_N^T(y) = \begin{cases} \frac{\binom{r+y-1}{y} (1-p)^y}{p^{-r} - 1} & \text{pre } y = 1, 2, \dots, \quad p \in (0, 1), \\ 0 & \text{inak.} \end{cases}$$

Pre konštanty a, b rozdelenia ETNB platí, že $a = 1 - p > 0$ a $b = (r - 1)(1 - p)$. Keďže ide o odsekuté rozdelenie v 0, tak $p_N(0) = 0$.

Poznámka 2.12 (Logaritmické rozdelenie). Logaritmické rozdelenie je limitným prípadom ETNB rozdelenia pre $r \rightarrow 0$. Neexistuje k nemu však zodpovedajúce rozdelenie v triede rozdelení $(a, b, 0)$. Pravdepodobnostná funkcia logaritmického rozdelenia je v tvare

$$p_N^T(y) = \begin{cases} -\frac{(1-p)^y}{y \ln(p)} & \text{pre } y = 1, 2, \dots, \quad p \in (0, 1), \\ 0 & \text{inak.} \end{cases}$$

⁹Z anglického výrazu *Extended Truncated Negative Binomial*.

V tomto prípade je opäť možné dokázať, že okrem vyššie spomenutých pravdepodobnostných rozdelení do triedy rozdelení $(a, b, 1)$ žiadne ďalšie nepatria (viď. [7]).

Poznámka 2.13. V anglickej literatúre sa môžeme stretnúť aj s názvami ako *zero-inflated distribution*, čo zodpovedá nami predstavenému rozdeleniu modifikovanému v 0. Tomuto názvu potom zodpovedajú aj príslušné funkcie a procedúry v programovacích jazykoch, ako R alebo Python.

Kapitola 3

Modelovanie počtu poistných nárokov

Ako sme si už viackrát povedali, poisťiteľ má na začiatku poistenia k dispozícii viacero informácií o potenciálnom klientovi. Pri poistení motorových vozidiel ide napríklad o typ automobilu, váhu automobilu, výkon, využitie a podobne. Na základe týchto apriórnych informácií musí poisťiteľ zaradiť klienta do jednej z tarifných skupín. Všeobecne platí, že čím viac informácií má poisťiteľ na začiatku poistenia, tým presnejšie dokáže potenciálneho klienta zaradiť do vhodnej tarifnej skupiny a aposteriórne korekcie poistného budú potom minimálne. Úlohou poisťovne je navrhnúť vhodný model, pomocou ktorého bude možné klientov deliť na základe ich rizikovosti do jednotlivých skupín, ktoré by mali byť čo najviac homogénne. Jednotlivé tarifné skupiny sa medzi sebou odlišujú očakávaným počtom poistných nárokov, prípadne aj ich výškou. Pravdepodobnostné rozdelenia počtu poistných nárokov sme si predstavili v Kapitole 2. Otázkou zostáva, aký model je najvhodnejší na toto delenie. Na začiatok sa pozrime na klasický lineárny regresný model, uvedieme si jeho základné vlastnosti a predpoklady, a takisto si povieme, prečo tento model nie je príliš vhodným riešením nášho problému. Klasický lineárny regresný model tvorí základ zovšeobecneného lineárneho modelovania. Pochopenie fungovania lineárneho regresného modelu je dôležité pre následné pochopenie fungovania zovšeobecneného lineárneho modelu. Zovšeobecnený lineárny model budeme naprieč celou prácou označovať ako GLM¹⁰. V tejto kapitole budeme vychádzať opäť najmä z publikácie od autorov de Jonga a Hellera [8], ďalej z publikácie od autorky Dobson [13] a niektoré informácie prevezmeme aj z publikácie napísanej autormi James a kol. [14].

3.1 Lineárny regresný model

Lineárna regresia je jednou z najjednoduchších metód riadeného učenia. Táto metóda historicky patrí medzi staršie metódy štatistického modelovania a v porovnaní s modernými metódami sa môže javiť ako veľmi jednoduchá a priamočiara. Napriek tomu je lineárna regresia stále široko používanou metódou, a to práve vďaka jej jednoduchosti a ľahkej interpretácii. Uplatnenie táto metóda nachádza napríklad v praktickej ekonometrii. Ako už bolo vyššie spomenuté, správne pochopenie lineárnej regresie je dobrým základom pre porozumenie zložitejším technikám riadeného učenia.

¹⁰Z anglického výrazu *Generalized Linear Model*

Na začiatok si zavedme základné značenie potrebné pre budovanie lineárneho regresného modelu. Lineárny model môžeme napísať nasledujúcim spôsobom

$$Y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik} + \varepsilon_i, \quad \text{kde } \varepsilon_i \stackrel{\text{iid}}{\sim} (0, \sigma^2), \quad i \in \{1, \dots, n\}.$$

Značenie:

- Y_i – odozva, závislá premenná, regresand (anglické ekvivalenty sú *response*, *target*, *outcome*);
- $x_{i1}, \dots, x_{ik}$ – nezávislé premenné, regresory, atribúty (anglické ekvivalenty sú *covariates*, *predictors*, *inputs*, *exploratory variables*, *attributes*);
- $\beta_0, \dots, \beta_k$ – regresné koeficienty (anglický ekvivalent je *coefficients*);
- ε_i – náhodná chyba (anglický ekvivalent je *random error*).

Lineárny model môžeme tiež zapísať v maticovom tvare nasledujúcim spôsobom

$$\begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1k} \\ 1 & x_{21} & x_{22} & \dots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nk} \end{pmatrix} \times \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix},$$

respektíve

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad \text{kde } \boldsymbol{\varepsilon} \sim (\mathbf{0}, \sigma^2 \mathbf{I}).$$

Predpoklad nulovej strednej hodnoty pri náhodnej chybe $\boldsymbol{\varepsilon}$ zabezpečuje elimináciu systematickej chyby a predpoklad konštantného rozptylu zabezpečuje rovnakú presnosť merania. Pri náhodnej chybe sa často pracuje s predpokladom normality, t. j. $\boldsymbol{\varepsilon} \sim \mathbf{N}(\mathbf{0}, \sigma^2 \mathbf{I})$, a potom $\mathbf{Y} \sim \mathbf{N}(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I})$. Maticu $\mathbf{X}$ nazývame aj dizajnová matica, regresná matica alebo matica plánu. Väčšinou sa takisto uvažuje $n > p$, kde $p = k + 1$ je počet regresných koeficientov. Počet pozorovaní by mal byť teda väčší ako počet regresorov. Regresný koeficient β_0 je konštantný a v dvoj-dimenzionálnom probléme označuje vertikálny posun regresnej priamky. Tento koeficient môžeme často nájsť aj pod názvom intercept.

Cieľom tejto sekcie nie je detailné predstavenie lineárneho regresného modelu, ale len základné pochopenie jeho fungovania. Keďže naším cieľom je jednak predikcia, ale aj pochopenie fungovania modelu a zároveň sme si povedali, že lineárne regresia patrí medzi metódy riadeného učenia, tak uvažujme nasledujúci príklad. Majme množinu pozorovaní $\{(y_i, \mathbf{x}_i^T)\}_{i=1}^n$, kde y_i je realizácia závislej premennej Y_i a $\mathbf{x}_i^T = (x_{i1}, \dots, x_{ik})$ je vektor reprezentujúci nezávislé premenné. Síce sme si povedali, že lineárna regresia nie je príliš vodná na modelovanie počtu škôd, ale v tomto prípade nám to môže poslúžiť aspoň ako príklad. Náhodná veličina Y_i s realizáciou y_i by reprezentovala počet dopravných nehôd na i -tej poistnej zmluve, zatiaľčo vektor $\mathbf{x}_i^T$ by reprezentoval apriórne informácie o vodičovi,

respektíve o vozidle, ako napríklad vek vodiča, typ vozidla, výkon vozidla, využitie atď. Chceme teda modelovať počet nehôd na i -tej zmluve pri daných fixných hodnotách $\mathbf{x}_i^T$, t. j.

$$\hat{Y}_i = E(Y_i) = \beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik} = \mathbf{x}_i^T \boldsymbol{\beta}.$$

Na to, aby sme mohli vytvoriť vhodný klasifikačný model, ktorý dokáže spoľahlivo predikovať očakávaný počet nahlásených nehôd nových klientov, musíme odhadnúť regresné koeficienty $\beta_0, \dots, \beta_k$ z historických dát, t. j. z množiny pozorovaní $\{(y_i, \mathbf{x}_i^T)\}_{i=1}^n$.

Regresné koeficienty sa najčastejšie odhadujú použitím metódy najmenších štvorcov (ozn. OLS¹¹). Hlavnou myšlienkou tejto metódy je minimalizovať chybu $\boldsymbol{\varepsilon}$, čím vlastne minimalizujeme vzdialenosť skutočnej hodnoty $\mathbf{Y}$ od jej očakávanej hodnoty $E[\mathbf{Y}] = \mathbf{X}\boldsymbol{\beta}$. Matematicky to môžeme zapísať ako

$$\hat{\boldsymbol{\beta}} = \arg \min_{\boldsymbol{\beta}} \|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|^2, \quad (3.1)$$

kde

$$\|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|^2 = (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^T (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) = \sum_{i=1}^n \left(Y_i - \beta_0 - \sum_{j=1}^k x_{ij} \beta_j \right)^2.$$

Odhad pomocou metódy OLS minimalizuje súčet štvorcov vertikálnej vzdialenosti medzi fitovanou hodnotou $\mathbf{Y}$ a pozorovanou hodnotou $\mathbf{X}\hat{\boldsymbol{\beta}}$. Rovnicu (3.1) môžeme jednoducho vyriešiť tak, že deriváciu prvého rádu podľa $\boldsymbol{\beta}$ položíme rovnú 0. Riešením potom bude nasledujúci výraz

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}. \quad (3.2)$$

Nie je ťažké ukázať, že skutočne ide o minimum. Stačí overiť, že matica druhých derivácií podľa $\boldsymbol{\beta}$ je pozitívne definitná. Je potrebné povedať, že rovnica (3.2) má jednoznačné riešenie práve vtedy, keď má matica $\mathbf{X}$ plnú hodnotu, t. j. $\text{rank}(\mathbf{X}) = k+1$. To znamená, že všetky regresory musia byť lineárne nezávislé. Navyše, v ideálnom prípade, by mala byť korelácia medzi jednotlivými regresormi čo najmenšia, aby sme sa vyhli početným problémom. Ak sa pozrieme na rovnicu (3.2), tak vidíme, že je potrebné vypočítavať inverziu zo súčinu matic $\mathbf{X}^T \mathbf{X}$. Je zrejmé, že čím viac budú regresory korelované, tým viac sa nám skomplikuje výpočet tejto inverzie. Determinant matice $\mathbf{X}^T \mathbf{X}$ bude pri vysokej korelácii blízky hodnote 0, a teda budeme pracovať s veľmi malými hodnotami. Tento jav sa nazýva multikolinearita a prináša so sebou viacero problémov, ktorým sa ale nebudeme do hĺbky venovať. Podstatné je, že v dôsledku multikolinearity je model nestabilný. Multikolinearita sa dá odstrániť viacerými spôsobmi, ako napríklad použitím metódy hlavných komponent (ozn. PCA¹²), hrebeňovou regresiou¹³, lasso regresiou, transformáciou premenných atď. Opäť sa vráťme k nášmu príkladu, kde uvažujeme poistenie motorových vozidiel a naším cieľom je predikovať počet poistných udalostí na základe apriórnych informácií, akými sú vek vodiča, výkon vozidla, typ vozidla, využitie a podobne. Je zrejmé, že existuje značná

¹¹Z anglického výrazu *Ordinary least squares*.

¹²Z anglického výrazu *Principal Component Analysis*.

¹³V anglickej literatúre sa môžeme stretnúť s označením *Ridge regression*.

korelácia medzi jednotlivými premennými, ako napríklad výkon a typ vozidla.

Pre úplnosť je potrebné dodať, že rovnica (3.1) má riešenie len vtedy, keď $n \geq p$, teda ak je počet pozorovaní väčší alebo rovný počtu regresorov. V takomto prípade je odhad regresných koeficientov $\hat{\beta}$ metódou najmenších štvorcov podľa Gaussovej-Markovovej vety najlepší lineárny nevychýlený odhad regresných koeficientov β . To znamená, že takýto odhad má najmenší rozptyl spomedzi všetkých nevychýlených odhadov. V prípade, ak je počet pozorovaní menší ako počet regresorov, t.j. $n < p$, tak odhad regresných koeficientov $\hat{\beta}$ metódou najmenších štvorcov nie je ani definovaný. V takomto prípade musíme použiť inú metódu, ako napríklad metódu maximálnej vierohodnosti, ktorá bude predstavená v ďalšej časti práce.

Na záver je k metóde najmenších štvorcov vhodné dodať, že odhad regresných koeficientov $\hat{\beta}$ je možné zrealizovať numericky, pomocou iteratívnych metód, alebo analyticky. Oba prístupy majú svoje výhody aj nevýhody. Numerické riešenie je vhodné pre veľké datasety, a taktiež sa s väčšou pravdepodobnosťou vyhneme preučeniu modelu ako v prípade analytického riešenia. Iteratívne metódy môžu byť ale pomalé, je potrebné vhodne zvoliť veľkosť kroku učenia modelu, ale každá iterácia je potom zvyčajne početne nenáročná. Analytické riešenie, na druhej strane, vyzerá lepšie a nepotrebujeme žiadne iterovanie a všetko s tým spojené. Výpočet môže byť ale výpočtovo veľmi náročný, hlavne pri veľkých datasetoch, keďže potrebujeme vypočítať inverznú maticu.

Ďalším predpokladom pre lineárny regresný model je homoskedasticita, t.j. konštantný rozptyl náhodných chýb. Už vyššie sme si uviedli, že náhodná chyba $\varepsilon_i \stackrel{\text{iid}}{\sim} (0, \sigma^2)$ pre každé $i \in \{1, \dots, n\}$, respektíve v maticovom zápise $\varepsilon \sim (\mathbf{0}, \sigma^2 \mathbf{I})$. Často sa pritom uvažuje aj normalita týchto náhodných chýb, a teda $\varepsilon \sim \mathbf{N}(\mathbf{0}, \sigma^2 \mathbf{I})$. Keďže matica plánu $\mathbf{X}$ a aj vektor regresných koeficientov β sú fixne dané, tak odozva $\mathbf{Y}$ sa bude tiež riadiť normálnym rozdelením, t.j. $\mathbf{Y} \sim \mathbf{N}(\mathbf{X}\beta, \sigma^2 \mathbf{I})$. Pripomeňme si, že naším problémom je segmentácia klientov do rozličných tarifných skupín na základe predikovaného počtu poistných nárokov. Odozva bude potom rovná počtu poistných nárokov, respektíve počtu nahlásených nehôd. V predchádzajúcej časti práce sme sa venovali práve pravdepodobnostným rozdeleniam náhodnej veličiny, ktorá popisuje očakávaný počet poistných udalostí. Povedali sme si, že takáto náhodná veličina sa bude riadiť počítacím pravdepodobnostným rozdelením, ktoré patrí do triedy rozdelení $(a, b, 0)$, respektíve $(a, b, 1)$. Pri žiadnom z rozdelení patriacich do tejto triedy nebude požiadavka na konštantný rozptyl naplnená. Ako príklad si môžeme vziať najčastejšie využívané rozdelenie, ktorým je Poissonovo rozdelenie. Ako už vieme, rozptyl a stredná hodnota sa pri Poissonovom rozdelení rovnajú. Jednotlivé tarifné skupiny sa odlišujú práve očakávaným počtom poistných udalostí, teda strednou hodnotou. Zároveň sa budú potom odlišovať aj rozptylom, ktorý je rovný strednej hodnote. Je zjavné, že podmienka homoskedasticity v tomto prípade určite naplnená nebude, a teda nie je možné použiť lineárny model. Podobná analógia sa dá použiť aj na ostatné pravdepodobnostné rozdelenia patriace do triedy rozdelení $(a, b, 0)$, respektíve $(a, b, 1)$. Riešenie tohto problému si predstavíme v nasledujúcej podkapitole, kde si zdefinujeme zovšeobecnený lineárny model a s ním spojenú triedu rozdelení exponenciálneho typu.

3.2 Zovšeobecnený lineárny model

V tejto časti práce nadviažeme na lineárne regresné modely, ktoré sme si predstavili v predchádzajúcej podkapitole. Zdefinujeme si zovšeobecnené lineárne modely, ktoré sú prirodzeným rozšírením a zovšeobecnením lineárnych modelov. Priblížime si prípad, keď má odozva iné ako normálne rozdelenie, a to konkrétne ľubovoľne pravdepodobnostné rozdelenie z triedy exponenciálnych rozdelení. Opäť si predstavenú teóriu demonštrujeme na príklade a uvedieme si pár užitočných informácií.

Zovšeobecnené lineárne modely sú široko používané modely v poisťovníctve, pretože sú vhodné na analýzu dát, ktoré nie sú normálne rozdelené. Ako už vieme z predchádzajúcich častí práce, práve takéto dáta sa často v poistnej praxi vyskytujú. Hlavným rozdielom oproti lineárnym regresným modelom je skutočnosť, že odozva bude funkciou lineárnej kombinácie regresorov, a to nie nutne identitou, ako tomu bolo pri lineárnych modeloch. Viackrát už bolo vrámci tejto práce spomenuté pomenovanie trieda exponenciálnych rozdelení, a preto si na začiatok zdefinujeme, čím sa táto trieda pravdepodobnostných rozdelení vyznačuje a ktoré rozdelenia do nej spadajú.

Definícia 3.1. Nech Y je náhodná veličina, ktorej pravdepodobnostné rozdelenie závisí na parametri θ . Povieme, že pravdepodobnostné rozdelenie náhodnej veličiny Y patrí do triedy exponenciálnych rozdelení, ak môžeme jeho pravdepodobnostnú funkciu (v prípade diskretných rozdelení), respektíve pravdepodobnostnú hustotu (v prípade spojitých rozdelení) zapísať v nasledujúcom tvare

$$f(y; \theta) = s(y)t(\theta) \exp \{a(y)b(\theta)\} = \exp \{a(y)b(\theta) + c(\theta) + d(y)\}, \quad (3.3)$$

kde, θ je neznámy parameter a a, b, c, d sú známe funkcie. Navyše, ak $a(y) = y$, tak povieme, že rozdelenie je v kanonickom tvare. Funkciu $b(\theta)$ niekedy nazývame aj prirodzený parameter. Ak v danom pravdepodobnostnom rozdelení figurujú aj ďalšie neznáme parametre, tak ich nazývame rušivé parametre a zaobchádzame s nimi tak, ako by boli známe.

Tabuľka 3.1: Počítacie rozdelenia ako členovia triedy exponenciálnych rozdelení

Rozdelenie	$a(y)$	$b(\theta)$	$c(\theta)$	$d(y)$
Binomické	y	$\ln \left(\frac{p}{1-p} \right)$	$v \ln(1-p)$	$\ln \binom{v}{y}$
Poissonovo	y	$\ln(\lambda)$	$-\lambda$	$-\ln(y!)$
Negatívne binomické	y	$\ln(1-p)$	$r \ln(p)$	$\ln \binom{r+y-1}{y}$

Množstvo známych pravdepodobnostných rozdelení patrí do triedy exponenciálnych rozdelení. Sú to napríklad binomické, Poissonovo, negatívne binomické, normálne, gamma rozdelenie a iné. Prvé tri pravdepodobnostné rozdelenia sú nám už dobre známe, keďže sme

sa im venovali v Kapitole 2. V tabuľke 3.1 sú preto uvedené všetky potrebné informácie k tomu, aby sme tieto rozdelenia mohli prepísať do tvaru, aký bol definovaný v rovnici (3.3). Tvary pravdepodobnostných funkcií týchto rozdelení môžeme takisto nájsť v Kapitole 2.

Pre pravdepodobnostné rozdelenia z triedy exponenciálnych rozdelení navyše platí nasledujúci vzťah

$$\begin{aligned} E[a(y)] &= -\frac{c'(\theta)}{b'(\theta)}, \\ \text{Var}[a(y)] &= \frac{b''(\theta)c'(\theta) - c''(\theta)b'(\theta)}{[b'(\theta)]^3}, \end{aligned} \quad (3.4)$$

kde $b'(\theta)$ a $b''(\theta)$ sú prvá, respektíve druhá derivácia funkcie $b(\theta)$ podľa parametru θ . Analogický to platí aj pre $c(\theta)$ a $c''(\theta)$. Vzťahy (3.4) môžeme využiť hlavne v prípade, ak je rozdelenie v kanonickom tvare. Z Tabuľky 3.1 vidíme, že všetky počítacie rozdelenia sú v kanonickom tvare, a teda pomocou vzťahov (3.4) môžeme jednoducho dopočítať strednú hodnotu a rozptyl týchto rozdelení. Vzťahy (3.4) sú detailne odvodené v publikácii od autorov Dobson [13, str. 48-49].

Keďže sme si už zadefinovali triedu exponenciálnych rozdelení, tak môžeme prejsť k definícii zovšeobecneného lineárneho modelu. V tejto časti práce nadviažeme na teóriu predstavenú v sekcii 3.1 a zachováme aj rovnaké značenie. Majme teda súbor náhodných veličín $Y_1, \dots, Y_n$, kde každá z nich sa riadi pravdepodobnostným rozdelením z triedy exponenciálnych rozdelení a spĺňa nasledujúce vlastnosti.

1. Pravdepodobnostné rozdelenie náhodnej veličiny Y_i , pre všetky $i \in \{1, \dots, n\}$ je v kanonickom tvare a závisí na parametri θ_i , t.j.

$$f(y_i; \theta) = \exp \{y_i b_i(\theta_i) + c_i(\theta_i) + d_i(y_i)\}.$$

2. Pravdepodobnostné rozdelenia všetkých náhodných veličín $Y_1, \dots, Y_n$ majú rovnakú formu (t.j. všetky náhodné veličiny sa riadia napríklad Poissonovým rozdelením). Indexy pri funkciách b, c a d teda nie sú potrebné, avšak parametre θ_i pre $i \in \{1, \dots, n\}$ nemusia byť rovnaké. Združená pravdepodobnostná funkcia, respektíve pravdepodobnostná hustota bude potom v tvare

$$\begin{aligned} f(y_1, \dots, y_n; \theta_1, \dots, \theta_n) &= \prod_{i=1}^n \exp \{y_i b(\theta_i) + c(\theta_i) + d(y_i)\} \\ &= \exp \left\{ \sum_{i=1}^n y_i b(\theta_i) + \sum_{i=1}^n c(\theta_i) + \sum_{i=1}^n d(y_i) \right\}. \end{aligned}$$

Parametre θ_i zvyčajne nie sú predmetom nášho záujmu, keďže sa môžu líšiť pre každé jedno pozorovanie. Pre špecifikovanie modelu nás zvyčajne zaujíma menšia množina parametrov, a to síce parametre $\beta = (\beta_0, \dots, \beta_k)^\top$, pričom $k+1 = p < n$. Predpokladajme ďalej, že

$E(Y_i) = \mu_i$, kde $\mu_i = \mu(\theta_i)$ je nejaká funkcia parametru θ_i . Pri zovšeobecnených lineárnych modeloch uvažujeme nasledujúcu transformáciu μ_i

$$g(\mu_i) = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} = \mathbf{x}_i^\top \boldsymbol{\beta},$$

kde parameter $\mathbf{x}_i^\top \boldsymbol{\beta}$ nazývame aj lineárny prediktor. Funkcia g v rovnici (3.2) je rýdzo monotónna a diferencovateľná, a teda k nej bude existovať aj inverzná funkcia. Funkciu g nazývame link funkcia. Ak zhrnieme všetky vyššie uvedené vzťahy, tak potom platí

$$E(Y_i) = \mu_i = g^{-1}(\mathbf{x}_i^\top \boldsymbol{\beta}). \quad (3.5)$$

Povieme, že link funkcia je v kanonickom tvare, ak platí $\theta_i = \mathbf{x}_i^\top \boldsymbol{\beta} = g(\mu_i)$.

Opäť sa môžeme v krátkosti vrátiť k lineárnemu regresnému modelu z predchádzajúcej sekcie. Lineárny regresný model je evidentne najjednoduchším príkladom zovšeobecného lineárneho modelu. Ak si pripomenieme značenie, zo sekcie 3.1, tak môžeme vidieť, že link funkciou je v danom prípade identita. Táto link funkcia je zjavne v kanonickom tvare. Takisto nie je náročne overiť, že normálne rozdelenie patrí do triedy exponenciálnych rozdelení a je v kanonickom tvare.

V Tabuľke 3.2 sú uvedené najčastejšie používané link funkcie spolu so zodpovedajúcimi počítacími pravdepodobnostnými rozdeleniami, ktorým sme sa venovali v predchádzajúcej časti práce.

Tabuľka 3.2: Počítacie rozdelenia ako členovia triedy exponenciálnych rozdelení

Rozdelenie	Link funkcia	$g(\mu)$	$g^{-1}(\mathbf{x}_i^\top \boldsymbol{\beta})$
Binomické	logit	$\ln\left(\frac{\mu}{1-\mu}\right)$	$\frac{1}{1 + \exp\{-\mathbf{x}_i^\top \boldsymbol{\beta}\}}$
Poissonovo	log	$\ln(\mu)$	$\exp\{\mathbf{x}_i^\top \boldsymbol{\beta}\}$
Negatívne binomické	log	$\ln(\mu)$	$\exp\{\mathbf{x}_i^\top \boldsymbol{\beta}\}$

Pri binomickom rozdelení sa občas takisto používa link funkcia s názvom cloglog¹⁴, kde

$$g(\mu) = \ln\left(-\ln\left(1 - \frac{\mu}{n}\right)\right).$$

Pri negatívnom binomickom rozdelení sa môžeme stretnúť aj s link funkciou

$$g(\mu) = \ln\left(\ln\frac{\frac{\mu}{r}}{1 + \frac{\mu}{r}}\right).$$

Ďalšími známymi link funkciami sú napríklad identita, druhá odmocnina alebo probit link funkcia.

¹⁴Z anglického výrazu *complementary log-log*.

3.3 Odhady parametrov modelu

Pri zovšeobecnených lineárnych modeloch ostáva náš cieľ rovnaký, ako sme si ho predstavili v podkapitole 3.1. Chceme predikovať odozvu Y_i , ktorá sa v tomto prípade riadi pravdepodobnostným rozdelením z triedy exponenciálnych rozdelení. V poistnej praxi máme zvyčajne k dispozícii historické dáta, pomocou ktorých vieme odhadnúť príslušné regresné koeficienty. Následne pomocou týchto koeficientov a aktuálnych hodnôt regresorov $\mathbf{x}_i^\top$ vieme predikovať odozvu Y_i . Otázkou zostáva, akým spôsobom vieme odhadnúť tieto koeficienty.

3.3.1 Metóda vážených najmenších štvorcov

V podkapitole 3.1 sme si v krátkosti predstavili jednu z metód, ktorou je metóda najmenších štvorcov. Túto metódu môžeme analogicky využiť aj pri zovšeobecnených lineárnych modeloch. Treba mať na pamäti, že táto metóda funguje len v prípade, že $n \geq p$, teda len ak je počet pozorovaní väčší ako počet odhadovaných parametrov. Pri zovšeobecnených lineárnych modeloch môžeme ďalej predpokladať, že odozva Y_i má rozptyl σ_i^2 , pričom tento rozptyl nemusí byť rovnaký pre všetky $i \in \{1, \dots, n\}$. Potom je vhodné použiť metódu vážených najmenších štvorcov (ozn. WLS¹⁵), t. j. minimalizovať váženú vzdialenosť skutočnej hodnoty odozvy od jej očakávanej hodnoty. Cieľom je teda minimalizovať nasledujúci výraz

$$\sum_{i=1}^n w_i [Y_i - \mu_i(\boldsymbol{\beta})]^2, \quad (3.6)$$

kde váhy $w_i = \frac{1}{\sigma_i^2}$. Ide v podstate o zovšeobecnenie metódy najmenších štvorcov, kedy do výpočtu zahrňame aj informáciu o rozptyle danej odozvy. Čím väčší rozptyl náhodná veličina Y_i bude mať, tým menší vplyv bude mať táto odozva na výsledný odhad. Vo všeobecnosti sa pozorovania s väčším rozptylom považujú za menej spoľahlivé, a preto je lepšie v takomto prípade použiť metódu vážených štvorcov. Maticovo môžeme vzťah (3.6) zapísať nasledujúcim spôsobom

$$(\mathbf{Y} - \boldsymbol{\mu})^\top \mathbf{V}^{-1} (\mathbf{Y} - \boldsymbol{\mu}),$$

kde $\mathbf{V}^{-1}$ je príslušná kovariančná matica.

3.3.2 Metóda maximálnej vierohodnosti

Ďalšou metódou pre hľadanie odhadov je metóda maximálnej vierohodnosti (ozn. MLE¹⁶). Táto metóda patrí medzi najčastejšie využívané metódy a dokáže s ňou pracovať väčšina softvérov. Opäť uvažujme n nezávislých rovnako rozdelených náhodných veličín $Y_1, \dots, Y_n$, ktoré tvoria náhodný vektor $\mathbf{Y}$. Príslušný vektor realizácií týchto náhodných veličín označíme ako $\mathbf{y} = (y_1, \dots, y_n)^\top$. Ďalej nech ich združená pravdepodobnostná funkcia, respektíve združená pravdepodobnostná hustota $f(\mathbf{y}; \boldsymbol{\beta})$ závisí na vektore neznámych parametrov

¹⁵Z anglického výrazu *Weighted least squares*.

¹⁶Z anglického výrazu *Maximum likelihood estimation*.

$\boldsymbol{\beta} = (\beta_0, \dots, \beta_k)^\top$. Keďže ide o nezávisle rovnako rozdelené náhodné veličiny, tak združená pravdepodobnostná funkcia, respektíve pravdepodobnostná hustota bude súčinom marginálnych pravdepodobnostných funkcií, respektíve pravdepodobnostných hustôt, t. j.

$$f(\mathbf{y}; \boldsymbol{\beta}) = \prod_{i=1}^n f(y_i; \boldsymbol{\beta}). \quad (3.7)$$

Vierohodná funkcia

$$\mathcal{L}(\boldsymbol{\beta}; \mathbf{y}) = \prod_{i=1}^n f(y_i; \boldsymbol{\beta}) \quad (3.8)$$

je z algebraického hľadiska to isté ako združená hustota. Jediný rozdiel môžeme pozorovať v značení. Zatiaľ čo združená pravdepodobnostná funkcia, respektíve pravdepodobnostná hustota je funkciou neznámej $\mathbf{y}$ pri fixnom parametri $\boldsymbol{\beta}$, vierohodná funkcia je funkciou neznámeho parametru $\boldsymbol{\beta}$ pri fixnom $\mathbf{y}$. Ďalej nech Ω značí množinu všetkých možných hodnôt, ktoré môže parameter $\boldsymbol{\beta}$ nadobúdať. Množinu Ω nazývame aj parametrický priestor. Maximálne vierohodný odhad parametru $\boldsymbol{\beta}$ bude potom hodnota $\hat{\boldsymbol{\beta}}$, ktorá maximalizuje vierohodnú funkciu. Platí

$$\mathcal{L}(\hat{\boldsymbol{\beta}}; \mathbf{y}) \geq \mathcal{L}(\boldsymbol{\beta}; \mathbf{y}) \quad \text{pre všetky } \boldsymbol{\beta} \in \Omega,$$

t. j.

$$\hat{\boldsymbol{\beta}} = \arg \max_{\boldsymbol{\beta}} \mathcal{L}(\boldsymbol{\beta}; \mathbf{y}).$$

Často môže byť výpočtovo náročné nájsť maximum súčinu. Špeciálne tomu tak je v tomto prípade, keď ide o súčin hodnôt v rozmedzí $(0, 1)$. Z tohto dôvodu sa častejšie používa logaritmická vierohodná funkcia. Vzhľadom k tomu, že logaritmus je monotónna rastúca funkcia, tak maximum maximálne vierohodnej funkcie nastane pri rovnakej hodnote parametru $\boldsymbol{\beta}$ ako pri logaritmickej vierohodnosti. Logaritmickú vierohodnú funkciu môžeme teda zapísať v nasledujúcom tvare

$$\ell(\boldsymbol{\beta}; \mathbf{y}) = \ln \mathcal{L}(\boldsymbol{\beta}; \mathbf{y}) = \sum_{i=1}^n \ln f(y_i; \boldsymbol{\beta}).$$

Opäť bude platiť, že maximálne vierohodný odhad parametru $\boldsymbol{\beta}$ bude potom hodnota $\hat{\boldsymbol{\beta}}$, ktorá maximalizuje logaritmickú vierohodnú funkciu. Platí

$$\ell(\hat{\boldsymbol{\beta}}; \mathbf{y}) \geq \ell(\boldsymbol{\beta}; \mathbf{y}) \quad \text{pre všetky } \boldsymbol{\beta} \in \Omega,$$

t. j.

$$\hat{\boldsymbol{\beta}} = \arg \max_{\boldsymbol{\beta}} \ell(\boldsymbol{\beta}; \mathbf{y}). \quad (3.9)$$

Maximálne vierohodný odhad $\hat{\beta}$ z rovnice (3.9) potom obdržíme takým spôsobom, že položíme prvú deriváciu logaritmickú vierohodnej funkcie $\ell(\beta; y)$ vzhľadom k β_i pre všetky $i \in \{0, \dots, k\}$ a následne vyriešime systém rovníc. Pre úplnosť je potrebné overiť, že matica druhých derivácií vyhodnotená v $\beta = \hat{\beta}$ je negatívne definitná. Pre korektnosť by bolo potrebné skontrolovať aj hranice parametrického priestoru Ω a uistiť sa, že obdržané maximum z predošlých výpočtov je skutočne aj globálnym maximom.

Dôležitou vlastnosťou maximálne vierohodných odhadov je vlastnosť invariance. Nech existuje nejaká monotónna funkcia h . Platí, že ak $\hat{\beta}$ je maximálne vierohodný odhad parametru β , tak potom $h(\hat{\beta})$ je maximálne vierohodným odhadom funkcie $h(\beta)$. Vďaka tejto vlastnosti sa nám môže značne uľahčiť hľadanie maximálne vierohodného odhadu. V praxi ale väčšinou nie je potrebné hľadať derivácie vierohodnej, respektíve logaritmickú vierohodnej funkcie a následne vyriešiť systém rovníc. V poistnej praxi sa zvyčajne pracuje s veľkými dátovými setmi, a preto by bol tento postup náročný a zdĺhavý. Obzvlášť pri zovšeobecnených lineárnych modeloch je dôležitá numerická aproximácia, s ktorou pracujú aj výpočtové softvéry.

Pripomeňme si tvar vierohodnej funkcie (3.8). Je zrejmé, že odhad $\hat{\beta}$ bude závisieť na hodnotách $y_1, \dots, y_n$, t. j. na vzorke dát s ktorými pracujeme. Odhad $\hat{\beta}$ je teda sám o sebe náhodnou veličinou. Pri splnení podmienok regularity¹⁷ sú maximálne vierohodné odhady asymptoticky nestranné, konzistentné, a takisto asymptoticky normálne, t. j.

$$\hat{\beta} \approx N\left(\beta, \frac{J^{-1}(\beta)}{n}\right), \quad (3.10)$$

kde

$$J(\beta) = \left\{ E \left[\frac{\partial \ln f(Y_i; \beta)}{\partial \beta_i} \cdot \frac{\partial \ln f(Y_i; \beta)}{\partial \beta_j} \right] \right\}_{i,j=1}^k$$

je Fisherova informačná matica. Zo vzťahu (3.10) je zrejmé, že pri dostatočne veľkom počte dát, t. j. pri veľkom n , má maximálne vierohodný odhad $\hat{\beta}$ minimálny rozptyl, a preto bude aj najpresnejším možným odhadom. Naopak, pri malých dátových vzorkách býva maximálne vierohodný odhad $\hat{\beta}$ často vychýlený. V poistnej praxi sa väčšinou pracuje s dostatočne veľkým objemom dát, takže vychýlenosť odhadu zvyčajne nespôsobuje problém.

Na záver tejto sekcie si ešte uvedieme pár užitočných poznámok týkajúcich sa odhadovania parametrov. Vyššie sme si uviedli dve základné metódy odhadovania regresných koeficientov. Dôležitým rozdielom medzi spomínanými metódami je, že metóda najmenších štvorcov môže byť použitá bez akýchkoľvek predpokladov kladených na pravdepodobnostné rozdelenie odozvy. Na druhej strane, ak chceme použiť metódu maximálnej vierohodnosti, tak musíme špecifikovať združenú pravdepodobnostnú funkciu, respektíve pravdepodobnostnú

¹⁷Systém pravdepodobnostných hustôt parametru β je regulárny (t. j. nosič rozdelenia nezávisí na neznámom parametri.)

hustotu odozvy. Vo väčšine prípadov je ale výsledok oboch metód identický. Príkladom toho sú lineárne regresné modely. Každopádne, ako už bolo viackrát spomenuté, v praxi sú pri oboch metódach uprednostňované numerické výpočty pred analytickými. Okrem vyššie spomínaných metód sú všeobecne známe aj metóda momentov, respektíve metóda vážených momentov. Tieto metódy sú výpočtovo menej náročná a často sa používa pri určovaní počiatočných odhadov. V prípade, ak nemáme k dispozícii dostatok dát a chceme sa vyhnúť problémom s vychýlenosťou odhadu, môžeme použiť bayesovské odhady, pri ktorých vieme do procesu odhadovania zahrnúť apriórne informácie o odhadovanom parametri, čím dosiahneme presnejšie fungovanie výsledného modelu.

3.4 Výber vhodného modelu

Poslednou a v konečnom meradle asi najdôležitejšou úlohou zostáva výber vhodného modelu. Tento proces pozostáva z výberu vhodných regresorov, vytvorenia modelu, prípadne viacerých modelov a ich následného porovnania. Na konci celého procesu nám zostane len jeden model, ktorý najlepšie spĺňa naše požiadavky. Existuje viacero metód a postupov ako skonštruovať a vybrať čo najlepší model. Bližšie sa celému procesu budeme venovať v ďalšej časti práce, kde si vysvetlíme všetky použité metódy. V tejto sekcii si predstavíme len pár spôsobov, ktoré nám môžu pomôcť pri výbere vhodného modelu. Na tomto mieste je vhodné pripomenúť si výrok Georgea Boxa, ktorý povedal: „Všetky modely sú nesprávne, ale niektoré sú užitočné.“ Cieľom teda nie je nájsť ten správny model, ale ten najviac užitočný.

Regresné modelovanie patrí medzi metódy riadeného učenia. Výber vhodného modelu závisí na tom, čo je našim cieľom. Na základe tohto cieľa potom volíme vhodný postup tvorby modelu a vieme si špecifikovať kritéria pre náš model. Cieľom môže byť inferencia alebo predikcia. Ako už bolo vrámci tejto práce spomenuté, naším cieľom je predikovanie počtu poistných nárokov v závislosti na dostupných apriórnych informáciach. V poistnej praxi ale hrá dôležitú úlohu taktiež interpretovateľnosť modelu, čo je v podstate dôvodom širokého využívania regresných modelov namiesto iných, častokrát oveľa presnejších, metód strojového učenia. Pri výbere modelu však musíme brať ohľad aj na iné faktory, ako napríklad veľkosť dátovej vzorky, výpočtová náročnosť a podobne. Často sa pri modelovaní riadime princípom Occamovej britvy (t. j. princípom jednoduchosti), kedy dávame prednosť jednoduchším modelom pred komplexnejšími modelmi aj za cenu toho, že jednoduchšie modely nebudú skúmané dáta popisovať tak dobre, ako modely komplexnejšie. S rastúcou komplexnosťou modelu rastie aj pravdepodobnosť preučenia modelu, čo môže pri následnej predikcii spôsobovať problémy, a preto na túto skutočnosť treba myslieť v procese tvorby modelu. Prejdime ale ku spomínaným metódam, ktoré nám môžu pomôcť pri vhodnom výbere modelu.

3.4.1 Presnosť modelu

Pripomeňme si, čo je vlastne naším cieľom. Majme vstupný dataset, ktorý označíme ako $\mathbf{X}$. Ďalej majme vektor zodpovedajúcich odoziev $\mathbf{Y}$. Predpokladáme, že existuje neznáma fixne

daná funkcia f , pre ktorú platí $\mathbf{Y} = f(\mathbf{X}) + \varepsilon$, kde ε je nejaká zostatková neznáma chyba nezávislá na $\mathbf{X}$ s nulovou strednou hodnotou (t. j. $E(\varepsilon) = 0$). Cieľom je pomocou dostupných dát $\mathbf{X}$ a už vyššie predstavených techník odhadnúť funkciu f . Odhadom, tejto cieľovej funkcie je vlastne náš model, ktorý si označme ako g . Výstupom nášho modelu g bude vektor $\hat{\mathbf{Y}}$, t. j. $\hat{\mathbf{Y}} = g(\mathbf{X})$.

Ďalej nás bude zaujímať, ako dobre náš model popisuje realitu a ako dobre dokáže náš model predikovať. Bude nás teda zaujímať očakávaná predikčná chyba nášho modelu, respektíve presnosť modelu. Chyba modelu sa skladá z dvoch zložiek, a to z redukovateľnej chyby, ktorá je spôsobená aproximáciou cieľovej funkcie f , a neredukovateľnej chyby, ktorá pochádza z ε . Presnosť modelu môžeme merať pomocou rôznych stratových funkcií. V tejto práci si pre demonštratívne účely budeme voliť strednú kvadratickú chybu (ozn. MSE¹⁸). Rozklad MSE na redukovateľnú a neredukovateľnú časť si matematicky môžeme demonštrovať nasledujúcim spôsobom

$$\begin{aligned} E[(\mathbf{Y} - \hat{\mathbf{Y}})^2] &= E[(f(\mathbf{X}) - g(\mathbf{X}))^2] + \text{Var}(\varepsilon) \\ &= [f(\mathbf{X}) - E(g(\mathbf{X}))]^2 + \text{Var}(g(\mathbf{X})) + \text{Var}(\varepsilon) \\ &= [\text{Bias}(g(\mathbf{X}))]^2 + \text{Var}(g(\mathbf{X})) + \text{Var}(\varepsilon), \end{aligned}$$

kde $[\text{Bias}(g(\mathbf{X}))]^2 + \text{Var}(g(\mathbf{X}))$ je redukovateľná chyba a $\text{Var}(\varepsilon)$ je neredukovateľná chyba. Úlohou je teda nájsť taký model, ktorý má malú redukovateľnú chybu.

Pri výbere vhodného modelu si musíme dávať pozor na takzvaný bias-variance trade-off. Bias je vlastne chyba spôsobená aproximáciou cieľovej funkcie f pomocou zvoleného modelu g . Variancia nám hovorí, ako veľmi sa zmení náš zvolený model g , ak pri jeho tréningu použijeme iné dáta. Vyššie sme si uviedli, že cieľom je nájsť model s malou redukovateľnou chybou, a teda minimalizovať výraz $[\text{Bias}(g(\mathbf{X}))]^2 + \text{Var}(g(\mathbf{X}))$. Bias-variance trade-off spočíva v tej skutočnosti, že ak zvolíme príliš komplexný model s veľkým počtom regresorov, tak bude mať nízky bias, ale s veľkou pravdepodobnosťou bude mať veľkú varianciu a nebude tak dobre fungovať na nových neznámych dátach. Tento jav sa nazýva preučenie alebo overfitting. Naopak, ak zvolíme príliš jednoduchý model s minimálnym počtom regresorov, potom bude mať tento model veľký bias, ale jeho variancia bude nízka a na nových dátach bude fungovať podobne ako fungoval na dátach, pomocou ktorých bol vytvorený. Kvalita takéhoto modelu ale nebude príliš uspokojivá. Takýto jav sa označuje ako underfitting. Chceme teda docieľiť, aby náš model mal malý bias a zároveň malú varianciu.

S pojmi bias, resp. variancia úzko súvisia pojmy tréningová chyba (angl. *in-sample error*, ozn. err_{in}), resp. testovacia chyba (angl. *out-of-sample error*, ozn. err_{out}). Pri tvorbe modelu je vhodné si dáta rozdeliť minimálne na tréningovú vzorku a testovaciu vzorku. V ideálnom prípade je dobré rozdeliť si dáta na tréningovú vzorku, validačnú vzorku a testovaciu vzorku. Pomocou tréningovej vzorky vytvoríme viacero modelov, ktoré budú reflektovať náš

¹⁸Z anglického výrazu *Mean Squared Error*.

problém. Následne za pomoci validačnej vzorky dát vyberieme najlepší model. Nakoniec otestujeme ako funguje zvolený model na testovacej vzorke dát, aby sme dostali predstavu, ako bude fungovať na úplne nových dátach. Pre jednoduchosť interpretácie budeme teraz uvažovať len rozdelenie na tréningovú a testovaciu vzorku, keďže validácia modelu nie je nič iné ako opätovné rozdelenie tréningovej vzorky na tréningové a testovacie dáta. Platí, že pri rastúcej komplexite modelu klesá tréningová chyba, ale naopak rastie testovacia chyba. Chceme docieľať, aby $err_{out} \approx err_{in}$ a zároveň chceme, aby obe boli čo najmenšie, ideálne čo najbližšie k 0. Testovaciu chybu ale priamo ovplyvniť nevieme. Môžeme využiť Hoeffdingovu nerovnosť, ktorá v jednoduchosti hovorí, že

$$err_{out} \leq err_{in} + \mathcal{O}\left(\sqrt{\frac{C}{n}}\right),$$

kde C označuje komplexitu modelu a n označuje veľkosť dátového súboru. Výraz $\mathcal{O}\left(\sqrt{\frac{C}{n}}\right)$ je možné vyjadriť explicitne, ale pre účely tejto práce a pochopenie riešenej problematiky je postačujúci aj uvedený tvar, ktorý môžeme vnímať ako akýsi penalizačný výraz. Plný tvar Hoeffdingovej nerovnosti a viac informácií o tejto problematike je možné nájsť v publikácii od autorov Shaleva-Shwartz a Bena-Davida [15]. Dôležité je si uvedomiť, že prípustná komplexnosť modelu závisí aj na veľkosti dátovej vzorky, keďže čím viac tréningových dát máme k dispozícii, tým je väčšia pravdepodobnosť, že sa nám podarí odhaliť viacero skrytých vzťahov medzi jednotlivými atribútmi.

3.4.2 Krížová validácia

V praxi nie je možné vypočítať skutočnú strednú kvadratickú chybu, keďže cieľová funkcia f je neznáma. Musíme teda túto chybu len odhadnúť a k tomu použijeme práve rozdelenie dostupného datasetu na tréningové a testovacie dáta. V predchádzajúcej sekcii sme si povedali, že pri tvorbe modelu musíme brať v úvahu jeho komplexnosť, aby sme sa vyhli prípadnému preučeniu modelu, t. j. musíme sa snažiť držať pod kontrolou testovaciu chybu modelu. Existuje viacero spôsobov, ako sa vyhnúť preučeniu modelu. Komplexitu modelu môžeme znížiť napríklad použitím vhodných regularizačných techník alebo využitím meta-algortimov (angl. *ensemble techniques*). V praxi je ale často používaná metóda krížovej validácie (angl. *cross-validation*, ozn. CV), ktorú si priblížime v tejto časti práce. Krížová validácia nám umožní držať pod kontrolou potenciálny overfitting modelu a zároveň bude zachovaná interpretovateľnosť daného modelu.

Základnou myšlienkou krížovej validácie je rozdelenie datasetu na viacero disjunktných množín. Jedna množina dát bude slúžiť ako testovacia vzorka a ostatné množiny budú slúžiť ako tréningové vzorky. Pomocou tréningovej vzorky vytvoríme model, ktorého presnosť potom otestujeme na testovacej vzorke. V ďalšom kroku zvolíme inú množinu dát ako testovaciu, zvyšok použijeme na tréningovanie. Celý proces následne opakujeme. Celková chybovosť modelu môže byť vypočítaná ako aritmetický priemer jednotlivých chýb. Tento prístup je vhodný hlavne v prípade, ak máme viacero modelov a chceme vybrať ten najlepší, ktorý bude najlepšie zachytávať realitu a bude najlepšie fungovať na nových neznámych dátach. Tento prístup je takisto vhodný pri ladení hyper-parametrov jednotlivých modelov

alebo pre výber vhodných parametrov pre určité regularizačné techniky.

Existujú tri základné prístupy, ktoré sa používajú pri krížovej validácii. Najjednoduchším prístupom je jednoduché rozdelenie dát na trénovacie a testovacie. Ide o výpočtovo najjednoduchší spôsob, keďže stačí celý dataset náhodne rozdeliť na dve disjunktné množiny. Pomocou trénovacej vzorky zostavíme model, ktorého presnosť následne otestujeme na testovacej vzorke. Zvyčajne sa používa rozdelenie v pomere 80:20. Nevýhodou tohto prístupu je skutočnosť, že chybovosť v takomto prípade môže byť veľmi variabilná. Vypočítaná chybovosť bude závisieť na tom, ako boli dáta rozdelené. Takisto, keďže bola na trénovanie použitá len jedna vzorka dát, tak do celého procesu vnášame veľký bias, čo môže vyústiť k nadhodnoteniu testovacej chyby. Ako ale bolo spomenuté, ide o výpočtovo veľmi nenáročnú operáciu a tento prístup sa berie ako základné minimum pri tvorbe vhodného modelu.

Ďalším prístupom je takzvaná LOO¹⁹ krížová validácia. Ako už vyplýva zo samotného názvu, pri tomto prístupe použijeme na testovanie len jedno pozorovanie a zvyšok dát použijeme na trénovanie modelu. Tento proces ale musíme zopakovať pre všetky pozorovania. Ak máme dátový súbor s rozsahom n , tak dáta síce trénujeme na množine s rozsahom $n - 1$, čím odstránime problém s náhodnosťou rozdelenia dát ako tomu bolo v predchádzajúcom prípade a znížime bias, ale na druhej strane musíme tento postup zopakovať n -krát, čo značne zvýši výpočtovú náročnosť celého procesu. Tento proces môže byť vhodný v prípade, ak pracujeme s dátovými súbormi s malým rozsahom.

Posledným a najčastejšie používaným prístupom je K -násobná krížová validácia (angl. *K-fold cross-validation*.) Tento prístup spočíva v tom, že si dataset náhodne rozdelíme na K disjunktných množín s približne rovnakou veľkosťou. Následne budeme náš model trénovať na $K - 1$ množinách a na zostávajúcej množine tento model otestujeme. Tento postup zopakujeme K -krát. Konečnú testovaciu chybu dostaneme spriemerovaním jednotlivých testovacích chýb, ktoré sme počas tohto procesu dostali. Otázkou zostáva, ako zvoliť hodnotu K . Z praxe sa ukazuje, že $K = 5$ alebo $K = 10$ ukazuje najlepšie výsledky. Samozrejme ale závisí aj na veľkosti uvažovaného datasetu. Vidíme, že oproti prístupu LOO sa značne znížila výpočtová náročnosť. Bias zostane nízky, pretože fitujeme na takmer všetkých dátach. Súčasne sa zmenší variabilita výslednej chyby v porovnaní s LOO prístupom, keďže budú výstupy jednotlivých fitov menej korelované. K -násobná krížová validácia odstraňuje nedostatky oboch vyššie spomenutých prístupov, a preto je jej využitie aj najviac preferované. Viac informácií o krížovej validácii, ale aj o iných prevzorkovacích technikách je možné nájsť u autorov James a kol. [14, kapitola 5], kde sú tieto techniky aj graficky znázornené pre lepšie pochopenie.

3.4.3 Analýza deviácie

Analýza deviácie sa používa na určenie vplyvu regresorov na odozvu, respektíve na jej odhad. Pri analýze deviácie uvažujeme len aditívne pôsobenie regresorov. Interakciu medzi jednotlivými regresormi je ale takisto vhodné pri zovšeobecnených lineárnych modeloch brať do úvahy, avšak tá nie je predmetom analýzy deviácie. Analýza deviácie v podstate

¹⁹Z anglického výrazu *Leave-One-Out*.

slúži na porovnávanie jednotlivých submodelov zodpovedajúcim základnému zovšeobecnému lineárnemu modelu.

Jednou z možností, ako určiť kvalitu uvažovaného modelu, respektíve jeho schopnosť odhadovať dáta, s ktorými pracujeme, je porovnať uvažovaný model s modelom s najlepším možným odhadom. Model s najlepším možným odhadom dostaneme práve vtedy, keď tento model bude obsahovať rovnaký počet parametrov ako je počet pozorovaní. Takýto model nazývame aj saturevaný model a je to v podstate maximálny možný model, ktorý dokážeme vytvoriť. Pri saturevanom modeli je každá odhadovaná hodnota rovná skutočnej hodnote pozorovania, a teda saturevaný model odhaduje dáta perfektne. Navyše, maximálne virohodný odhad saturevaného modelu je maximálny možný, ktorý pri danej odozve môžeme dostať. Tieto tvrdenia je možné overiť u de Jonga a Hellera [8, str. 71-72]. Pre úplnosť je potrebné si zadať aj minimálny možný zovšeobecný lineárny model, ktorý nazývame aj nulový model. Tento model má rovnaký typ pravdepodobnostného rozdelenia a rovnaký typ link funkcie ako skúmaný model, pričom nulový model má len jeden regresný parameter. Nulový model a saturevaný model sú dva teoretické extrémny, ktoré slúžia ako indikátor najhoršej, respektíve najlepšej možnej regresie pri danom rozdelení a danej link funkcii. Skúmaný model sa bude nachádzať niekde medzi týmito dvoma prípadmi. Treba mať však stále na pamäti, že túto metódu môžeme použiť len na porovnanie skúmaného modelu a jeho submodelu, nie však na porovnanie dvoch kompletne odlišných modelov. Submodel je v podstate zovšeobecný lineárny model, ktorý má rovnaké pravdepodobnostné rozdelenie a rovnakú link funkciu ako skúmaný model. Počet regresných parametrov submodelu je menší, ako počet regresných parametrov skúmaného modelu a matica plánu submodelu je kombináciou stĺpcov matice plánu skúmaného modelu.

Majme teda dva zovšeobecné lineárne modely. Prvý uvažovaný model bude saturevaný model, ktorý označíme ako GLM_{max} s maximálne virohodným odhadom $\hat{\beta}_{max}$. Druhý uvažovaný model bude náš skúmaný model, ktorý označíme GLM s príslušným maximálne virohodným odhadom $\hat{\beta}$. Deviácia je potom definovaná ako miera vzdialenosti medzi GLM_{max} a GLM , t. j.

$$D = 2 \left[\ell(\hat{\beta}_{max}; \mathbf{y}) - \ell(\hat{\beta}; \mathbf{y}) \right], \quad (3.11)$$

kde $\ell(\beta; \mathbf{y})$ označuje logaritmicke virohodnú funkciu zodpovedajúcu danému vektoru parametrov β a vektoru $\mathbf{y}$. Ak skúmaný model GLM dobre odhaduje dáta, s ktorými pracujeme, tak môžeme očakávať, že hodnota virohodnej funkcie $\ell(\hat{\beta}; \mathbf{y})$ bude blízka hodnote $\ell(\hat{\beta}_{max}; \mathbf{y})$, nie však väčšia, a teda očakávame kladnú deviáciu. Naopak, ak skúmaný model nedokáže dobre odhadnúť dáta, tak môžeme očakávať veľkú hodnotu deviácie. V rovnici (3.11) môžeme vidieť, že rozdiel logaritmicke virohodností je prenasobený číslom 2, čo by malo zabezpečiť, že deviácia D bude mať približne χ^2 rozdelenie s $n - k$ stupňami voľnosti. Túto skutočnosť môžeme predpokladať, ak skúmaný model správne odhaduje naše dáta, počet pozorovaní n je dostatočne veľký a k je počet regresných parametrov. Očakávaná hodnota deviácie by bola potom rovná počtu stupňov voľnosti $n - k$. Pri praktických výpočtoch často skúmame hodnotu $\frac{D}{n - k}$, pričom čím je výsledná hodnota bližšie k 1, tým vhodnejší náš skúmaný model je. Naopak, hodnoty značne väčšie ako 1 indikujú nevhodný

model vzhľadom k našim dátam.

Pomocou deviácie môžeme porovnávať aj skúmaný model a jeho submodel. Opäť uvažujme skúmaný model GLM s k regresnými parametrami a jeho submodel GLM_{sub} s q regresnými parametrami, pričom $q < k < n$. Submodel označíme za vhodný, ak

$$\Delta D = D_{sub} - D \approx \chi^2(k - q), \quad (3.12)$$

kde D pre daný model vypočítame pomocou vzťahu (3.11). Ak teda testujeme hypotézu o vhodnosti submodelu, potom pre $\Delta D > \chi^2_{1-\alpha}(k - q)$ zamietame hypotézu o vhodnosti modelu na hladine významnosti α .

3.4.4 Informačné kritéria

Ďalšou využívanou metódou pre porovnávanie rôznych modelov je porovnávanie informačných kritérií. Pri použití informačných kritérií už nie sme obmedzení na porovnávanie len skúmaného modelu a jeho submodelov, ako tomu bolo pri analýze deviácie, a teda vieme porovnávať širšiu škálu modelov. Naším cieľom stále zostáva nájsť vhodný model, ktorý dokáže čo najlepšie aproximovať realitu a zároveň zachovať čo najviac informácií, ktoré sú obsiahnuté v dátach. Už sme si vrámci v tejto práci povedali, že pri výbere vhodného modelu je potrebné nájsť správny balans medzi komplexnosťou modelu a požadovanou presnosťou modelu. Ak zahrnieme do procesu tvorby modelu príliš veľa regresorov, tak vytvorený model bude síce popisovať naše dáta s veľkou presnosťou, ale zvyšuje sa rozptyl odhadu parametru $\hat{\beta}$, a preto presnosť vytvoreného modelu pri nových dátach nemusí byť už taká vysoká. Informačné kritéria sú práve preto vhodným ukazovateľom vhodnosti modelu, lebo berú do úvahy nielen presnosť s akou dokáže model popísať dáta, ale taktiež penalizujú model za každý pridaný parameter. Dôležitá je teda nielen presnosť, ale aj komplexnosť uvažovaného modelu. V tejto časti práce si predstavíme veľmi známe informačné kritéria, a síce Akaikeho informačné kritérium (ozn. AIC) a Bayesovo informačné kritérium (ozn. BIC).

Definícia 3.2. Akaikeho informačné kritérium zovšeobecneného lineárneho modelu je definované ako

$$\text{AIC} = -2\ell(\hat{\beta}; \mathbf{y}) + 2k, \quad (3.13)$$

kde k je počet regresných parametrov modelu a $\hat{\beta}$ je zodpovedajúci maximálne vierohodný odhad.

Definícia 3.3. Bayesovo informačné kritérium zovšeobecneného lineárneho modelu je definované ako

$$\text{BIC} = -2\ell(\hat{\beta}; \mathbf{y}) + k \ln n, \quad (3.14)$$

kde k je počet regresných parametrov modelu, $\hat{\beta}$ je zodpovedajúci maximálne vierohodný odhad a n je počet pozorovaní.

Akaikeho informačné kritérium je v podstate odhad pre testovaciu predikčnú chybu. Ide o rozšírenie konceptu maximálne vierohodného odhadu na prípad, keď počet parametrov

k je taktiež neznámy. Zo vzťahu (3.13) vidíme, že s rastúcim k bude narastať aj hodnota AIC, a teda každý ďalší parameter bude do modelu pridaný len v prípade, že pôjde o signifikantné zlepšenie fitu. Bayesovo informačné kritérium je podobné ako AIC. Ako vidíme zo vzťahu (3.14), tak toto informačné kritérium tiež zahŕňa informáciu o veľkosti dátového súboru n . Tento údaj je takisto veľmi podstatným pri procese tvorby modelu, keďže čím viac dát máme k dispozícii, tým komplexnejší model môžeme použiť bez toho, aby sme sa dostali do problémov s preučením modelu. Ak posudzujeme kvalitu modelu na základe vyššie spomínaných informačných kritérií, potom preferujeme taký model, ktorého hodnota AIC, respektíve BIC je nižšia. Jedinou podmienkou je, aby boli porovnávané modely založené na rovnakej množine pozorovaní.

Ďalšími široko používaným kritériom pri voľbe vhodného modelu je napríklad korigované Akaikeho informačné kritérium, do ktorého je zahrnutá aj informácia o veľkosti dátového súboru, aby sme sa vyhli spomínaným problémom s preučením modelu. Toto informačné kritérium sa odporúča používať hlavne v prípade, ak nemáme k dispozícii dostatočne veľkú vzorku dát. Korigované Akaikeho informačné kritérium je definované ako

$$AIC_c = -2\ell(\hat{\beta}; \mathbf{y}) + 2k \cdot \frac{n}{n - k - 1},$$

kde k je počet regresných parametrov modelu, $\hat{\beta}$ je zodpovedajúci maximálne vierohodný odhad a n je počet pozorovaní. Ďalej sa pri práci s rôznymi výpočtovými softvérmi môžeme stretnúť s koeficientom determinácie R^2 , respektíve s adjustovaným koeficientom determinácie R_{adj}^2 , ktorých hodnota nám hovorí o tom, aká časť celkovej variability bola pomocou uvažovaného modelu vysvetlená. Opäť treba mať na pamäti, že koeficient R^2 bude uprednostňovať komplexnejšie modely, a preto treba radšej brať v úvahu adjustovaný koeficient R_{adj}^2 , kde je informácia o veľkosti dátového súboru už zahrnutá. Ďalšie metódy a postupy, či už pre budovanie vhodného modelu alebo pre výber toho najvhodnejšieho, môžeme nájsť v publikácii od autorov James a kol. [14].

Kapitola 4

Modely strojového učenia v poisťovníctve

Metódy strojového učenia si v posledných rokoch získali zvýšený záujem medzi poisťnými matematikmi. Ich prijatie odborníkmi však bolo obmedzené, čiastočne kvôli nedostatočnej transparentnosti týchto metód v porovnaní so zovšeobecnenými lineárnymi modelmi, ktoré sme si predstavili v podkapitole 3.2. Napriek tomu sú nové algoritmy strojového učenia, ako napríklad gradient boosting modely, v súčasnosti nielen sofistikovanejšími odhadmi rizika, ale sú tiež zdanlivo rovnako interpretovateľné ako tradične používané zovšeobecnené lineárne modely. V tejto časti práce si porovnáme klasické zovšeobecnené lineárne modely s modelmi strojového učenia. Povieme si o výhodách a nevýhodách použitia jednotlivých modelov. Ďalej si v rýchlosti predstavíme teóriu rozhodovacích stromov, pozrieme sa konkrétne aj na gradient boosting modely. Na záver si načrtujeme, ako by takéto modely mohli fungovať v poisťnej sfére. Opäť budeme uvažovať problém apriórnej segmentácie klientov v neživotnom poistení. Táto časť práce je inšpirovaná hlavne článkami od Michaela Prokscha [16, 17], Patricka Halla [18] a dvojice autorov Kuo a Lupton [19].

Najväčšou výzvou pre poisťného matematika je v tomto prípade odstrániť rozdiely medzi presnosťou a interpretovateľnosťou modelov. Keď hovoríme o presnosti, musíme brať do úvahy oboje – presnosť predikcií a presnosť vysvetlení (t. j. presnosť jednotlivých atribútov vstupujúcich do modelu). V oblasti poisťnej matematiky regulačné úrady často vyžadujú interpretovateľnosť algoritmov, a teda poisťný matematik musí byť schopný vysvetliť, akú úlohu zohrávajú jednotlivé premenné vstupujúce do daného modelu. Navyše stále musíme mať na mysli aj diskrimináciu, ktorá sa môže objaviť v modeloch. Aby sme všetko zhrnuli, musíme sa zamerať na tri najdôležitejšie body: presnosť, interpretovateľnosť a diskrimináciu. Postupom času metódy strojového učenia pokročili od úplnej „čiernej skrinky“ až k pochopeniu rôznych modelov na báze „riadok po riadku“. V súčasnosti môžeme vďaka novým vysvetľovacím technikám robiť menej kompromisov medzi vyššie spomenutými bodmi.

4.1 GLM versus metódy strojového učenia

Zovšeobecnené lineárne modely sú stále zlatým štandardom v klasifikácii poistných rizík a pravdepodobne nebudú v blízkej budúcnosti nahradené. Hlavnou výhodou týchto metód je ich jednoduchosť a interpretovateľnosť. Ako už bolo spomenuté, regulačné orgány vyžadujú interpretáciu v odvetviach, ako sú financie a poisťovníctvo. Spoliehajú sa na konkrétne vysvetlenia predikcií, respektíve konkrétne objasnenie celého predikčného algoritmu. GLM sa dajú ľahko použiť na preukázanie, že sú nevychýlené (angl. *unbiased*) a vyhýbajú sa diskriminačným výsledkom (napr. málo významné vplyvy prediktorov na odozvu – ako je diskriminácia na základe rasy, farby pleti, náboženstva atď. – môžu byť použité na preukázanie nezávislosti). Avšak tvrdenie o interpretovateľnosti GLM sa dá pomerne jednoducho namietť, pretože ak uvažujeme o zložitejšom modeli s nelineárnou funkciou a s určitými interakciami medzi premennými, potom sa stáva oveľa náročnejšie správne interpretovať takýto model. To nás privádza k ďalšiemu problému, ktorý spočíva v tom, že GLM nedokážu automaticky detegovať interakcie a nelineárne správanie, čo spôsobuje nielen nízku presnosť predikcie, ale aj nízku presnosť vysvetľovania premenných. Interakcie môžeme do modelu pridať manuálne, ale určite nemôžeme špecifikovať všetky interakcie. Zvyčajne sú obojsmerné interakcie maximom, ktoré môžeme špecifikovať, aby sme sa vyhli preučeniu. Nelineárne správanie je možné zachytiť pomocou nelineárnych funkcií (napr. polynomicke funkcie alebo GEM²⁰). Aby sme mohli použiť všetky tieto modifikácie, musíme mať dobré znalosti o doméne a pri ich používaní musíme byť opatrní, pretože vznikajú problém s nadmerným preučeníím modelu a následnou nedostatočnou interpretovateľnosťou.

V oblasti tvorby tarifných sadzieb je strojové učenie stále „v plienkach“. Ak by však poisťovatelia mohli získať lepší prehľad o tom, ako sa modely strojového učenia správajú v kontexte klasifikácie rizík, zvýšilo by to ich schopnosť ubezpečiť regulátorov a verejnosť, že všeobecne akceptované zásady tvorby sadzieb budú splnené. Možnosť účtovať presnejšie poistné by potom zefektívnilo systém prenosu rizika. Generovanie interpretovateľných výstupov je základným aspektom kontroly modelu. Poistní matematici sú pri výbere rizikových charakteristík viazaní príslušnými štandardmi. Vzhľadom na skutočnosť, že sa algoritmy strojového učenia vo všeobecnosti považujú za zložitejšie ako GLM, výzva na interpretovanie výsledkov takýchto modelov je ešte náročnejšia. Navyše, v mnohých krajinách môžu nové sofistikované prediktívne modely podliehať osobitnej regulačnej kontrole, a preto je potrebné vedieť vysvetliť výsledky procesu modelovania spôsobom, ktorý je pochopiteľný bez obetovania štatistickej presnosti.

Strojové učenie predstavuje pre odvetvie poisťovníctva špeciálnu výzvu z nasledujúcich dôvodov.

- Modely strojového učenia môžu byť až príliš „ad hoc“ v porovnaní s tradičnými štatistickými modelmi, ako sú GLM.
- Väčšina modelov strojového učenia sa vyznačuje overfittingom (t. j. častý problém s preučovaním modelov).

²⁰Z anglického výrazu *Generated effect modifiers*.

- Pretože mnohé modely strojového učenia nepredpokladajú základné rozdelenie pravdepodobnosti (alebo nepracujú s predpokladmi pre stochastické procesy), štandardné metriky na porovnanie modelov nemusia byť vhodné (napr. nie je jednoduché vypočítať AIC pre neurónovú sieť).
- Metódy strojového učenia sa často kombinujú do súborov, ktoré sa nedajú ľahko oddeliť a ktoré ako súbor môžu prestať pripomínať jedinú štandardnú verziu modelu (napr. ak používame tzv. stacking, a teda skombinujeme viacero modelov do jedného).
- Modely strojového učenia a nelineárne modely môžu skrývať diskrimináciu (t.j. zložitejšie modely môžu sťažiť objavovanie znakov diskriminácie, hoci to nevyhnutne neznamená, že sú viac diskriminačné).
- Modely strojového učenia môžu byť tzv. „čiernymi skrinkami“, pretože konečnú formu krivky odozvy nemožno ľahko predpovedať a môže do značnej miery závisieť od dostupných údajov, s ktorými aktuálne pracujeme (ktoré zase nemusí byť k dispozícii recenzentovi).

Všimnite si, že posledná položka z vyššie uvedeného zoznamu vyvoláva zaujímavý problém. GLM a im podobné modely sa často zostavujú pomocou štandardných a dobre pochopených prístupov (napr. odhad parametrov modelu pomocou metódy maximálnej vierohodnosti). Pri modeloch strojového učenia to však vo všeobecnosti nie je možné, pretože algoritmy často pracujú so stratovými funkciami vo vysokých dimenziách, ktoré sú veľmi zložité, takže nemusí byť možné vypočítať globálne minimum týchto funkcií. Ďalším dôležitým bodom je, že p -hodnoty tiež nie sú konceptom, ktorý by sa dal dobre preložiť do deterministického algoritmu pre strojové učenie. Nakoniec sme ešte spomenuli, že modely strojového učenia môžu určitým spôsobom skrývať diskrimináciu. Aby sme predišli diskriminácii, môžeme ju špecificky otestovať v danom modeli. Výhodou modelov strojového učenia je, že máme širokú škálu možných modelov, ktoré fungujú s podobnou presnosťou, takže si môžeme vybrať len taký, ktorý minimalizuje diskrimináciu. Naopak, v GLM toho nie sme schopní urobiť príliš veľa, aby sme sa vyhli diskriminácii. Môžeme vypustiť len tú premennú, ktorá je zdrojom diskriminácie, čo môže viesť k strate významnej presnosti. Ďalším spôsobom, ako sa vysporiadať s diskrimináciou v modeloch strojového učenia, je zahrnúť do procesu modelovania obmedzenia pre určité interakcie. Pre úplnosť je potrebné poznamenať, že nielen interakčné obmedzenia, ale aj monotónne obmedzenia môžu viesť k výraznému zlepšeniu modelov strojového učenia a môžu nám pomôcť dosiahnuť náš cieľ. Použitím monotónnych obmedzení môžeme do konštrukcie modelu vložiť naše apriórne znalosti o skúmanom probléme.

4.2 Riadené učenie

V tejto podkapitole si v krátkosti priblížime, ako funguje celý proces riadeného strojového učenia. Na začiatok si zadefinujeme pár základných pojmov, ktoré sú nevyhnuté pre pochopenie tohto procesu. Budeme čerpať najmä z publikácií od skupiny autorov Hastie, Tibshirani a Friedman [20] a skupiny autorov Tan a kol. [21].

4.2.1 Trieda modelu (priestor hypotéz)

Trieda modelu definuje rodinu matematických modelov, ktoré môžu byť použité v procese výstavby modelu. Napríklad, môžeme uvažovať rodinu lineárnych modelov. V takomto prípade bude hranicou rozhodovania (angl. *decision boundary*) priamka (ak je problém definovaný v $\mathbb{R}^2$) a trieda modelu bude priestor všetkých priamok v $\mathbb{R}^2$. Trieda modelu definuje aj geometrické vlastnosti rozhodovacej funkcie (angl. *decision function*). Existujú rôzne taxonomie, ale najznámejšími sú rodiny lineárnych a nelineárnych modelov. Tieto rodiny zvyčajne závisia na parametroch a riešením problému učenia je výber vhodných parametrov pre daný model alebo inak povedané – výber vhodného prvku z priestoru triedy modelu. Priestor všetkých prípustných modelov pre daný problém sa niekedy označuje aj ako priestor hypotéz.

Výber vhodného modelu bude závisieť na našom konkrétnom probléme a na skutočnosti, na čo chceme model použiť a aké informácie z neho chceme získať. Primárnym cieľom učenia je zvyčajne dosiahnutie minimálnej chyby, respektíve dosiahnutie maximálnej presnosti. Ďalšími požadovanými vlastnosťami môžu byť interpretovateľnosť, správanie modelu pri chýbajúcich dátach, rýchlosť učenia modelu a podobne.

4.2.2 Model problému


Model problému formalizuje a dekoduje požadované vlastnosti riešenia. V prevažnej väčšine prípadov ide o optimalizačný problém, ktorého najjednoduchším príkladom je hľadanie minima stratovej funkcie. Stratová funkcia v podstate meria vzdialenosť medzi naším modelom a skutočným riešením. Existuje veľké množstvo stratových funkcií, ako napríklad 0–1 loss, stredná kvadratická chyba, reziduálna stredná kvadratická chyba (ozn. RMSE²¹), stredná absolútna chyba (ozn. MAE²²) a ďalšie. Model problému môžeme využiť aj k zavedeniu ďalších obmedzení na naše požadované riešenie, ako napríklad hladkosť aproximácie, malá komplexita modelu atď.

4.2.3 Učiaci algoritmus

Učiaci algoritmus je optimalizačná metóda alebo algoritmus, ktorý pri danej triede modelu fituje tréningové dáta podľa zadefinovanej stratovej funkcie. Na základe povahy nášho problému môže existovať viacero rôznych a zároveň vhodných algoritmov. Vo všeobecnosti hovoríme o hľadaní minimálnej chyby aproximácie. Ak je problém konvexný (alebo kvázi-konvexný), tak sa typicky používajú metódy prvého alebo druhého rádu, ako napríklad gradientný zostup (angl. *gradient descent*), zostup súradníc (angl. *coordinate descent*), Newtonova metóda atď. Ďalšími známymi technikami sú generický algoritmus alebo Monte Carlo techniky, ktoré môžu byť použité v prípade, ak nie je možné spočítať prvé alebo druhé derivácie stratovej funkcie. Schému celého procesu riadeného učenia môžeme vidieť na Obrázku 4.1.

²¹Z anglického výrazu *Residual Mean Squared Error*.

²²Z anglického výrazu *Mean Absolute Error*.



Obr. 4.1: Proces riadeného učenia

4.3 Gradientný zostup

Podľa informácií, ktoré sme si uviedli v predchádzajúcej podkapitole vieme, že pri každom probléme si musíme určiť triedu modelu, stratovú funkciu a učiaci algoritmus. Predstavme si teda, že si zvolíme triedu modelu (napr. lineárne modely), zvolíme si stratovú funkciu (napr. MSE). Naším cieľom bude teda minimalizovanie takejto stratovej funkcie. Otázkou zostáva, akým spôsobom vyriešime tento optimalizačný problém. V predošlej podkapitole sme takisto spomenuli, že pri konvexných problémoch sa k minimalizácii často používa metóda gradientového zostupu, a práve túto metódu si stručne predstavíme.

Naším cieľom je teda minimalizovanie stratovej funkcie cez všetky hodnoty parametrov modelu. Tento problém môžeme zapísať nasledujúcim spôsobom

$$\min_{\mathbf{w}} \mathcal{L}(\mathbf{Y}, \hat{\mathbf{Y}}) \quad \text{kde} \quad \mathcal{L}(\mathbf{Y}, \hat{\mathbf{Y}}) = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

alebo pomocou vektorov

$$\min_{\mathbf{w}} \frac{1}{n} (\mathbf{Y} - \hat{\mathbf{Y}})^\top (\mathbf{Y} - \hat{\mathbf{Y}}),$$

kde $\mathbf{w}$ predstavuje vektor parametrov prislúchajúcich k uvažovanému modelu. Takýto problém vo väčšine prípadov nebude možné ani vhodné riešiť analyticky, a preto musíme pristúpiť k numerickému riešeniu.

Gradient je v podstate zovšeobecnením derivácie pre funkcie s viac premennými. Ide o vektor všetkých parciálnych derivácií príslušnej funkcie. Pri jednorozmerných a dvojrozmerných prípadoch môžeme gradient vnímať ako sklon funkcie, avšak pri vyšších dimenziách

už nastáva problém s vizualizáciou, a teda aj interpretáciou gradientu. Pri metóde gradientového zostupu postupujeme malými krokmi, ktoré sú úmerné zápornej hodnote gradientu v danom bode funkcie. Pri hľadaní maxima by sme postupovali analogicky, len s opačným znamienkom gradientu. Základnú myšlienku za celým algoritmom si môžeme intuitívne predstaviť nasledujúcim spôsobom.

1. Zvolíme si počiatočnú hodnotu vektora parametrov $\mathbf{w}_0$.
2. Určíme smer poklesu $\Delta \mathbf{w}$ a dĺžku kroku η – často nazývanú aj rýchlosť učenia (angl. *learning rate*).
3. Aktualizujeme parametre modelu

$$\mathbf{w}_t = \mathbf{w}_{t-1} + \eta \Delta \mathbf{w}.$$

4. Opakujeme kroky 2-3 až pokým zvolené kritérium zastavenia algoritmu (napr. počet iterácií alebo požadovaná chybová tolerancia) nie je splnené.

Cieľom vyššie uvedeného algoritmu je minimalizovať stratovú funkciu, resp. docieľiť, aby pre každú ďalšiu iteráciu platilo $\mathcal{L}(\mathbf{w}_t) \leq \mathcal{L}(\mathbf{w}_{t-1})$, a teda $\Delta \mathcal{L} \leq 0$. Pre prírastok stratovej funkcie $\Delta \mathcal{L}$ platí nasledujúci vzťah

$$\Delta \mathcal{L} \approx \nabla_{\mathbf{w}} \cdot \Delta \mathbf{w}. \quad (4.1)$$

Pri metóde gradient descent volíme smer poklesu ako zápornú hodnotu gradientu stratovej funkcie, t. j. $\Delta \mathbf{w} = -\nabla_{\mathbf{w}} \mathcal{L}$, čím docielime, aby pre prírastok stratovej funkcie platilo $\Delta \mathcal{L} \leq 0$. Ak tento vzťah dosadíme do rovnice (4.1), tak dostaneme nasledujúcu aproximáciu

$$\Delta \mathcal{L} \approx \nabla_{\mathbf{w}} \mathcal{L} \cdot (-\eta \nabla_{\mathbf{w}} \mathcal{L}),$$

respektíve

$$\Delta \mathcal{L} \approx -\eta (\nabla_{\mathbf{w}} \mathcal{L})^2.$$

Keďže vždy bude platiť $(\nabla_{\mathbf{w}} \mathcal{L})^2 \geq 0$, a takisto sme si zvolili podmienku, že $\nabla_{\mathbf{w}} \mathcal{L} \leq 0$, tak po implementácii algoritmu bude zaručené, že budeme postupovať smerom k minimu stratovej funkcie.

4.4 Rozhodovacie stromy

Rozhodovacie stromy (angl. *decision trees*) sú rozšírené používanými technikami riadeného učenia. Svoju popularitu si získali najmä vďaka ich prehľadnosti a interpretovateľnosti. Rozhodovacie stromy v kombinácii s určitými meta-algoritmami (angl. *ensemble learning*) vytvárajú veľmi silný nástroj na predikciu. Rozhodovacie stromy sú vhodnou metódou ako pre riešenie klasifikačného, tak aj pre riešenie regresného problému.

Rozhodovací strom je tvorený koreňmi, uzlami a listami, ktoré spolu reprezentujú súbor rozhodovacích pravidiel. Vetvenie sa uskutočňuje na základe jedného prediktora. Rovnaký prediktor môže byť použitý viackrát. Inak povedané, každý uzol rozhodovacieho stromu

predstavuje rozcestie, na ktorom sa rozhodujeme podľa vlastností niektorej zo vstupných premenných (napr. binárne delenie: $\text{vek vodiča} \geq 50$ a $\text{vek vodiča} < 50$). Každá jedna vetva predstavuje výsledok takéhoto testu. Podľa vetvenia rozlišujeme binárne stromy (t. j. každý uzol má dvoch potomkov) a všeobecné stromy (t. j. každý uzol môže mať dva a viac potomkov). Listy stromu sú kategórie, do ktorých môže daný prvok prislúchať. Cesta celým rozhodovacím stromom (t. j. od koreňa až k listom) reprezentuje množinu klasifikačných, resp. regresných pravidiel. Výstavba stromu sa väčšinou uskutočňuje od koreňa k listom (TDIDT²³).

4.4.1 Algoritmus CART

Algoritmus CART²⁴ je metóda výstavby binárneho stromu. Pre každý prediktor v danom uzle nájdeme najlepšie delenie podľa tohto prediktoru. V danom uzle nájdeme spomedzi všetkých prediktorov najlepšie delenie. Uzol následne rozdelíme do dvoch nasledovníkov. Pre každého nasledovníka tento postup opakujeme, až pokým daný uzol nie je označený ako konečný uzol, t. j. list. Detailnejší popis tohto algoritmu aj s grafickým znázornením ponúkajú autori Breiman a kol. [22]. My v ďalšej časti si predstavíme aspoň základnú myšlienku algoritmu.

Ak je prediktor X_i spojitý, potom uvažujeme delenie typu $\{X_i < C\}$ versus $\{X_i \geq C\}$ pre všetky hodnoty C . Ak máme v dátovom súbore celkom m rôznych hodnôt, potom existuje $m - 1$ rôznych delení pre tento prediktor. Hodnota C sa typicky volí ako stred intervalu dvoch susedných hodnôt. Ak je prediktor X_i kategorický, s kategóriami z množiny $\{K_1, \dots, K_m\}$, potom uvažujeme delenie typu $\{X_i \in S_j\}$ versus $\{X_i \notin S_j\}$, kde $S \subset \{K_1, \dots, K_m\}$ a mení sa v závislosti na uzle. Algoritmus CART vo všeobecnosti nerozlišuje, či je prediktor ordinálneho alebo nominálneho typu. Ak by bol prediktor ordinálny, stačilo by uvažovať len susedné kategórie (t. j. iba tie, ktoré sú relevantné). Ak prediktor nadobúda celkom m rôznych hodnôt, potom existuje $2^{m-1} - 1$ rôznych delení pre tento prediktor.

Rozhodovací strom sa zostavuje tak, aby sa od seba objekty v jednotlivých uzloch čo najviac odlišovali, nie však úplne. Cieľom je čo najlepšie odlišovať jednotlivé skupiny v uzloch. Nechceme však, aby bol strom príliš rozvetvený (t. j. chceme sa vyhnúť preučeniu). Rozvetvenosť rozhodovacieho stromu vieme kontrolovať pomocou rôznych mier nečistoty (angl. *impurity*) v uzle. Označme si uzol rozhodovacieho stromu premennou t . Pre uzol t majme počet pozorovaní $n(t)$ v tomto uzle a $n_j(t)$ pre $j = 1, \dots, J$ počet pozorovaní v uzle t patriacich do triedy j . Ďalej si označme relatívnu početnosť pozorovaní z triedy j v uzle t ako $p_j(t) = \frac{n_j(t)}{n(t)}$, pre $j = 1, \dots, J$. Najčastejšie využívanými mierami nečistoty sú nasledujúce miery.

²³Z anglického výrazu *Top-down induction of decision trees*.

²⁴Z anglického výrazu *Classification and regression trees*.

- Giniho index:

$$i(t) = \sum_{j=1}^J \sum_{i \neq j} p_i(t) p_j(t) = 1 - \sum_{j=1}^J p_j^2(t).$$

- Shannonova entropia:

$$i(t) = - \sum_{j=1}^J p_j(t) \log p_j(t).$$

- Klasifikačná chyba:

$$i(t) = 1 - \max_j p_j(t) \quad \text{pre } j = 1, \dots, J.$$

Označme ďalej potomkov uzlu t pri danom delení ako t_1 a t_2 . Potom definujeme pokles nečistoty pri tomto delení ako

$$\Delta i(t, t_1, t_2) = i(t) - \frac{n(t_1)}{n(t)} i(t_1) - \frac{n(t_2)}{n(t)} i(t_2).$$

Ako výsledné delenie vezmeme to, ktoré maximalizuje pokles nečistoty v danom uzle.

Algoritmus CART sa samovoľne zastaví (t. j. daný uzol bude označený ako list), ak:

- v uzle zostane jediné pozorovanie;
- v uzle sú všetky pozorovania s rovnakou hodnotou závislej premennej (t. j. patria do rovnakej skupiny – miera nečistoty je nulová);
- v uzle sú všetky pozorovania s rovnakou hodnotou prediktoru (t. j. už nie je možné nájsť ďalšie delenie, ktoré by zmenšilo nečistotu – pozorovania v danom uzle môžu mať rozdielne hodnoty závislej premennej).

Ako už bolo spomenuté vyššie, u príliš rozvetveného stromu hrozí preučenie, pretože takýto strom príliš dobre popisuje dáta, na ktorých bol skonštruovaný, ale nedokáže správne klasifikovať nové pozorovania. Aby sme sa vyhli preučeniu, môžeme pridať niektoré z nasledujúcich pravidiel pre zastavenie rastu stromu. Pri implementácii môžeme nastaviť

- maximálnu hĺbku stromu;
- minimálny počet pozorovaní v uzle;
- minimálna miera nečistoty v uzle.

Iným riešením je tzv. prerezávanie (angl. *pruning*). Pri tomto spôsobe necháme narásť maximálny strom, a potom odstránime niektoré vetvy. K tomuto spôsobu potrebujeme mať validačné dáta. V prípade, ak nemáme dostatok dát, môžeme využiť corss-validáciu alebo iné penalizačné kritéria.

Danému listu sa priradí trieda s najväčšou početnosťou v tomto liste, t. j.

$$\hat{Y} = \arg \max_j p_j(t) = \arg \max_j n_j(t) \quad \text{pre } j = 1, \dots, J.$$

Ak triedy nie sú zastúpené rovnomerne, používa sa Bayesovské pravidlo, a teda

$$\hat{Y} = \arg \max_j p_j(t) \hat{\pi}_j \quad \text{pre } j = 1, \dots, J,$$

kde $\hat{\pi}_j$ je odhad apriórnej pravdepodobnosti j -tej triedy.

4.4.2 Algoritmus CHAID

Algoritmus CHAID²⁵ nevytvára binárny strom, ale všeobecný. Tento algoritmus dokáže pracovať s kategorickými prediktormi. Pre numerické prediktory je potrebná kategorizácia. Algoritmus CHAID prebieha podobne ako pri metóde CART, a teda pomocou princípu TDIDT, pričom sa líši len v hľadaní vhodného delenia. Bližší popis tohto algoritmu môžeme nájsť napríklad v publikácii od Kassa [23].

Pre každý prediktor X_i nájdeme optimálne delenie na základe χ^2 testu nezávislosti v kontingenčnej tabuľke, t. j.

1. pre všetky dvojice K_i a K_j spočítame p -hodnotu χ^2 testu nezávislosti v danej kontingenčnej tabuľke;
2. kategórie s najvyššou p -hodnotou zlúčime dohromady;
3. celý postup opakujeme, pokiaľ p -hodnoty všetkých testov nebudú nižšie ako predom zvolená hladina významnosti α_1 .

Následne spočítame korigovanú (angl. *adjusted*) p -hodnotu χ^2 testu nezávislosti pre celú kontingenčnú tabuľku zlúčených kategórií (tzv. Bonferroniho korekcia kvôli mnohonásobnému porovnávaniu). Táto korekcia je nutná, keďže prebehlo viacnásobné porovnávanie a testovanie. Nakoniec spomedzi všetkých prediktorov vyberieme ten s najnižšou korigovanou p -hodnotou. Ak sú všetky korigované p -hodnoty väčšie ako predom stanovená hladina významnosti α_2 , potom delenie neprebehne a uzol zostane označený ako list.

Ďalšími často používanými algoritmami sú QUEST²⁶, ID3, C4.5, C5. Zovšeobecnením rozhodovacích stromov sú metódy bagging (bootstrap agregácia), boosting, ďalej rozhodovacie lesy (angl. *Random forests*), a taktiež regresné stromy, pomocou ktorých vieme modelovať spojité premenné, pričom postup ostáva podobný.

Samotný rozhodovací strom nie je spravidla dosť silným predikčným modelom. Aby sme dosiahli lepšiu predikciu, môžeme použiť meta-algoritmy, ktoré kombinujú viacero algoritmov, čím zabezpečujú dosiahnutie lepšieho predikčného výkonu v porovnaní s predikčným výkonom jednotlivých zložiek tohto algoritmu.

²⁵Z anglického výrazu χ^2 *automatic interaction detector*.

²⁶Z anglického výrazu *Quick Unbiased and Efficient Statistical Tree*.

4.4.3 Bagging

Metóda bagging alebo taktiež známa ako bootstrap agregácia je technika horizontálnej agregácie, ktorá kombinuje množstvo rozhodovacích stromov pre vytvorenie stabilnejšieho a presnejšieho prediktora. Na začiatku je potrebné dáta rozdeliť na trénovacie a testovacie.²⁷ Z trénovacích dát sú náhodne vybraté podmnožiny s vopred určenou mohutnosťou. Následne je pre každú podmnožinu dát vytvorený rozhodovací strom. Testovacie dáta sú potom použité na predikciu, a to pomocou každého zo zostavených rozhodovacích stromov. Pri klasifikačnom probléme je konečným výsledkom potom kategória, ktorá bola najčastejšie určovaná vytvorenými rozhodovacími stromami. Pri regresnom probléme je konečným výsledkom priemer regresných kriviek. Implementovaním techniky bagging sa vieme do výraznej miery vyhnúť preučeniu predikčného algoritmu. Vyššie spomínaný algoritmus nazývaný rozhodovací les (angl. *Random forrest*) je v princípe založený na tejto technike s malými rozdielmi.

4.4.4 Boosting

Pri metóde nazývanej boosting sa snažíme pomocou tzv. slabých klasifikátorov vytvoriť jeden silný. Takisto ako v prípade vyššie uvedenej metódy bagging, ide o techniku horizontálnej agregácie. Pri každom pridaní slabého klasifikátoru do systému skontrolujeme správnosť celkovej klasifikácie. Objektom, ktoré boli predikované chybné zvýšime váhu. Naopak objektom, ktoré boli predikované správne, váhu znížime. Týmto spôsobom zaisťujeme, aby sa pri ďalšej klasifikácii slabé klasifikátory viac zamerali na objekty s vyššou váhou (t. j. na objekty, ktoré boli chybné predikované). Systém by mal s pribúdajúcimi iteráciami konvergovať k správnejmu riešeniu a predikčná chyba by sa mala znižovať. Medzi najznámejšie algoritmy, ktoré sú založené na metóde boosting, patria algoritmus Adaboost²⁸ a algoritmus GBM²⁹. Práve algoritmu GBM sa budeme venovať v ďalšej časti tejto práce. Tento algoritmus používa kombináciu rozhodovacích stromov a techniky boosting. Viac informácií o technikách bagging a boosting, a taktiež o algoritmoch založených na týchto technikách môžeme nájsť v publikácii od autorov Kuhn a Johnson [24].

Pre hodnotenie kvality modelu môžeme využiť nasledujúce kritéria

- matica zámen (t. j. kontingenčná tabuľka obsahujúca predikcie a skutočné hodnoty);
- správnosť klasifikácie (chyba klasifikácie);
- správnosť klasifikácie do danej triedy (chyba klasifikácie do danej triedy);
- špecitivita, senzitivita;
- ROC³⁰ krivky.

²⁷V ideálnom prípade na trénovacie, validačné a testovacie.

²⁸Z anglického výrazu *Adaptive boosting*.

²⁹Z anglického výrazu *Gradient boosting model/method*.

³⁰Z anglického výrazu *Receiver operating characteristic*.

Medzi výhody rozhodovacích stromov patrí ich jednoduchosť a pomerne dobrá interpretovateľnosť. Pri zostavovaní modelu nie je nutná zložitá príprava dát, keďže si algoritmus poradí aj s chýbajúcimi pozorovaniami. Navyše, ako už bolo spomenuté, algoritmus dokáže pracovať so spojitými aj s kategorickými premennými. Ďalej nám neprekáža ani multikolinearita (t. j. korelované premenné). Rozhodovacie stromy patria medzi robustné algoritmy vďaka slabým predpokladom modelu, a takisto sme schopní pracovať s pomerne rozsiahlymi dátovými súbormi.

Naopak, medzi nevýhody rozhodovacích stromov patrí ich výpočetná náročnosť a nestabilita riešení (t. j. ak iba trochu zmeníme dátový súbor, s ktorým pracujeme, tak dostaneme iný strom). Rozhodovacie stromy sú taktiež náchylné na preučenie, čo ale vieme opatriť pomocou viacerých techník uvedených vyššie. Pri implementácii rozhodovacích stromov je ale stále nutná znalosť a skúsenosť analytika.

4.5 Gradient boosting model

Ako sme spomínali v sekcii 4.4.4, jedným zo všeobecne známych a používaných algoritmov je algoritmus GBM, ktorý ako prvý vo svojom článku predstavil Friedman [25]. V tomto algoritme sú implementované myšlienky z rozhodovacích stromov, a takisto z techniky boosting. Gradient boosting je teda metóda, ktorá využíva kombináciu slabých prediktov – rozhodovacích stromov obmedzenej veľkosti. Nech T označuje počet koncových uzlov (t. j. listov) v čiastkovom strome. Počet týchto koncových uzlov nám určuje úroveň interakcie medzi vstupnými premennými. Empiricky bolo preukázané, že $T \in \{4, \dots, 8\}$ je pre gradient boosting optimálny počet koncových uzlov. Ak však napríklad uvažujeme strom s $T = 2$, je zrejmé, že v takomto strome neprebehne žiadna interakcia medzi vstupnými prediktormi. Takéto špeciálne prípady sa nazývajú rozhodovacie pne (angl. *decision stumps*). Algoritmus GBM je detailne popísaný v spomínanom článku od Friedmana [25]. My si v ďalšej časti predstavíme tento algoritmus len v krátkosti.

Majme model H v čase t v nasledujúcom tvare

$$H_t(\mathbf{X}) = \sum_{i=1}^T \alpha_i h_i(\mathbf{X}),$$

kde $\mathbf{X} = (\mathbf{x}_1^\top, \dots, \mathbf{x}_n^\top)^\top$ je vstupný dataset, $\mathbf{x}_j^\top = (x_1, \dots, x_k)$ pre $j = 1, \dots, n$ je potom j -te pozorovanie z tohto datasetu a h je tzv. kandidátska funkcia³¹. Uvažujme ďalej napríklad postup pomocou metódy najmenších štvorcov, t. j. stratová funkcia bude mať nasledujúci tvar

$$\mathcal{L}(\mathbf{Y}, \hat{\mathbf{Y}}) = \sum_{j=1}^n \left(Y_j - \sum_{i=1}^T \alpha_i h_i(\mathbf{x}_j^\top) \right)^2.$$

V čase $t + 1$ musíme zvoliť h_{t+1} a optimalizovať hodnotu α_{t+1} , zatiaľčo budeme stále

³¹Kandidátska funkcia je zvyčajne jednoduchá funkcia vstupných premenných $\mathbf{X}$. V sekcii 4.4.4 sme ju označovali ako slabý klasifikátor.

uvažovať model ako konštantný do tohto času, t. j.

$$H_{t+1}(\mathbf{X}) = \sum_{i=1}^T \alpha_i h_i(\mathbf{X}) + \alpha_{t+1} h_{t+1}(\mathbf{X}).$$

Ďalej vložme tento model do stratovej funkcie

$$\mathcal{L}(\mathbf{Y}, \hat{\mathbf{Y}}) = \sum_{j=1}^n \left(Y_j - \underbrace{\sum_{t=1}^T \alpha_t h_t(\mathbf{x}_j^\top)}_{r_t(\mathbf{x}_j^\top)} + \alpha_{t+1} h_{t+1}(\mathbf{x}_j^\top) \right)^2,$$

kde $r_t(\mathbf{x}_j^\top) = Y_j - H_t(\mathbf{x}_j^\top)$ je chyba modelu v čase t na pozorovaní $\mathbf{x}_j^\top$. V tomto jednoduchom prípade nám stačí vyriešiť problém pre α_{t+1} , a h_{t+1} , t. j.

$$\begin{aligned} \nabla_{h_{t+1}} \sum_{j=1}^n \left(r_t(\mathbf{x}_j^\top) + \alpha_{t+1} h_{t+1}(\mathbf{x}_j^\top) \right)^2 &= 2 \sum_{j=1}^n \left(r_t(\mathbf{x}_j^\top) + \alpha_{t+1} h_{t+1}(\mathbf{x}_j^\top) \right) \alpha_{t+1} = 0, \\ \nabla_{\alpha_{t+1}} \sum_{j=1}^n \left(r_t(\mathbf{x}_j^\top) + \alpha_{t+1} h_{t+1}(\mathbf{x}_j^\top) \right)^2 &= 2 \sum_{j=1}^n \left(r_t(\mathbf{x}_j^\top) + \alpha_{t+1} h_{t+1}(\mathbf{x}_j^\top) \right) h_{t+1}(\mathbf{x}_j^\top) = 0. \end{aligned} \quad (4.2)$$

Z rovnice (4.2) môžeme pozorovať nasledujúci vzťah

$$\sum_{j=1}^n \left(r_t(\mathbf{x}_j^\top) h_{t+1}(\mathbf{x}_j^\top) + \alpha_{t+1} h_{t+1}(\mathbf{x}_j^\top) h_{t+1}(\mathbf{x}_j^\top) \right) = 0,$$

respektíve

$$r_t^\top(\mathbf{X}) h_{t+1}(\mathbf{X}) + \alpha_{t+1} h_{t+1}^\top(\mathbf{X}) h_{t+1}(\mathbf{X}) = 0.$$

Vidíme, že hodnota α_{t+1} je proporčná skalárnemu súčinu súčasného rezídua a kandidátskej funkcie, t. j.

$$\alpha_{t+1} = \frac{r_t^\top(\mathbf{X}) h_{t+1}(\mathbf{X})}{h_{t+1}^\top(\mathbf{X}) h_{t+1}(\mathbf{X})}.$$

V tomto prípade máme binárny problém, t. j. $h_{t+1}^\top(\mathbf{X}) \in \{-1, +1\}$, $h_{t+1}^\top(\mathbf{X}) h_{t+1}(\mathbf{X}) = n$, kde n je počet prvkov. V tomto prípade teda výber optimálneho h korešponduje s hľadaním minimálnej chyby. Celý tento postup je základnou myšlienkou gradient boosting techniky. Je zjavné, že gradient boosting je vo svojej podstate algoritmom gradientového zostupu.

Algoritmus GBM je stále náchylný na preučenie, a preto je vhodné použiť niektoré regularizačné techniky. Jednou z používaných regularizačných techník pri GBM je obmedzenie počtu iterácií algoritmu. Ak je počet čiastkových stromov príliš veľký, model veľmi dobre popisuje tréningové dáta, ale na testovacích dátach je príliš veľká chybovosť. Ako už bolo v rámci tejto podkapitoly spomenuté, ideálne je dáta rozdeliť na tréningové, testovacie a validačné, pričom práve validačné dáta môžu byť použité na odhadnutie optimálneho počtu iterácií algoritmu.

Ďalšou technikou regularizácie GBM je technika nazývaná shrinkage. Ide o úpravu rýchlosti učenia algoritmu (angl. *learning rate*). Je všeobecne odporúčané túto hodnotu nastaviť ako $\eta < 0,1$. Pri takto zvolených hodnotách dokáže model lepšie generalizovať v porovnaní s prípadom, kedy by táto technika použitá nebola (t.j. $\eta = 1$). Treba mať ale na pamäti, že zmenšovaním rýchlosti učenia ale zvyšujeme výpočtovú náročnosť algoritmu. Ďalším spôsobom, ako metódu GBM viac zovšeobecniť, je použitie stochastickej varianty metódy GBM.

4.6 Vysvetľovacie techniky

Ako už bolo spomenuté v úvode tejto kapitoly, interpretovateľnosť je v poisťovníctve kľúčom k prechodu od GLM k sofistikovanejším modelom strojového učenia. Na začiatok by sme mali teda zadať samotný pojem interpretovateľnosť. Dokonca ani medzi výskumníkmi na túto tému neexistuje konsenzus o presnej definícii. V tejto diplomovej práci budeme podobne ako Hall [18] za interpretovateľnosť považovať schopnosť vysvetliť alebo prezentovať v zrozumiteľných pojmoch. Ďalšou definíciou, ktorú potrebujeme, je definícia dobre vysvetleného modelu. Táto definícia môže byť zachytená v nasledujúcej vete: „Keď sa už ďalej nemôžeš pýtať prečo.“

V tejto časti práce sa zameriame na niektoré vysvetľujúce techniky, ktoré by mohli pomôcť zlepšiť interpretovateľnosť modelov strojového učenia. Predstavíme si hlavnú myšlienku týchto techník a pridáme niekoľko odporúčaní na použitie.

Pri vysvetľovacích technikách budeme používať podobné značenie ako v priebehu celej práce, t.j.

- $\mathbf{X} = (\mathbf{x}_1^T, \dots, \mathbf{x}_n^T)^T$ označuje vstupný dataset so zodpovedajúcim vektorom odoziev $\mathbf{Y}$;
- g označuje model strojového učenia, ktorý pochádza z priestoru hypotéz $\mathcal{H}$ a ktorý je trénovaný tak, aby zodpovedal neznámej cieľovej funkcii (angl. *target function*) f (t.j. $g \approx f$);
- $\hat{\mathbf{Y}}$ označuje výstup, ktorý je vygenerovaný modelom g (t.j. $g(\mathbf{X}) = \hat{\mathbf{Y}}$).

4.6.1 Shapleyho hodnoty (Tree SHAP)

Ako už bolo spomenuté, metódy strojového učenia zaznamenávajú v posledných rokoch výrazný posun vpred vo všetkých smeroch. Interpretovateľnosť takýchto modelov sa vďaka objavu laureáta Nobelovej ceny za ekonómiu Lloyda Shapleyho výrazne priblížila interpretovateľnosti tradičných GLM. Shapleyho hodnoty alebo inak nazývané aj Shapleyho vysvetlenia³² boli prelomovým objavom, a preto sa na ne pozrieme ako prvé. Hlavná myšlienka použitia Shapleyho hodnôt v modeloch strojového učenia spočíva v tom, že pomocou nich vieme linearizovať komplexnejšie modely, ako napríklad spomínaný model

³²V anglickej literatúre ich môžeme nájsť pod názvami *Shapley values*, *Shapley explanations* or *Shapley additive explanations*

GBM z podkapitoly 4.5. Použitie týchto hodnôt poskytuje veľké množstvo rovníc pre každý riadok v množine údajov, s ktorými pracujeme, čo robí celý proces značne transparentnejším.

Teória ohľadom Shapleyho hodnôt je spájaná s teóriou hier pre hráčov pracujúcich v koalícii. Koalícia týchto hráčov spolupracuje s cieľom dosiahnuť určitý celkový zisk prameniaci z tejto spolupráce. Hráči nie sú identickí a každý hráč zohráva inú úlohu (t. j. rôzni hráči sú rôzne dôležití). Takáto spolupráca môže priniesť väčší benefit, ako individuálne akcie jednotlivých hráčov. Nastoľuje sa ale otázka, ako spravodlivo rozdeliť vygenerovaný prínos medzi jednotlivých hráčov. Účelom Shapleyho hodnôt v takejto hre je teda dosiahnuť proporcionálne rovnakú odmenu. Keď premietneme túto problematiku do kontextu modelov strojového učenia, tak jednotlivé atribúty predstavujú spomínaných hráčov a model g hrá rolu koalície. Chceme teda zistiť, ako prispievajú jednotlivé atribúty do celkového generovaného zisku z koalície, t. j. do predikcie modelu g .

V poistení sa Shapleyho hodnoty používajú na rozdelenie zodpovednosti za riziko medzi jednotlivých členov portfólia. Ako príklad si môžeme vziať predikciu ceny poistenia motorového vozidla na základe nasledujúcich charakteristík: vek, typ auta, čas od registrácie auta, počet nehôd za posledných päť rokov. Poistní matematici musia vedieť, ktoré charakteristiky zvyšujú alebo znižujú cenu poistenia. Shapleyho hodnoty počítajú príspevok každej funkcie a súčet Shapleyho hodnôt každej z nich dáva predpokladanú cenu poistenia. My sa v ďalšej časti práce pozrieme konkrétne na to, aký vplyv majú jednotlivé premenné na predikciu vybudovaného modelu.

Podľa Patricka Halla [18] sú Shapleyho hodnoty jedinými možnými lokálne presnými a globálne konzistentnými hodnotami príspevku atribútov³³. Toto tvrdenie v podstate znamená, že súčet týchto hodnôt pre vstupné atribúty je vždy $g(\mathbf{x}^\top)$ a že Shapleyho hodnoty sa nikdy nemôžu znížiť o x_j , keď je funkcia g zmenená tak, že x_j skutočne výraznejšie prispieva ku $g(\mathbf{x}^\top)$. Hall vychádza hlavne z článku publikovaného Lundbergom a Leem [26], ktorí sa ako prví vážne začali venovať efektívnemu využitiu Shapleyho vysvetlení v strojovom učení. V tomto článku je jasne vysvetlené, čo sa presne skrýva pod pojmom lokálna interpretovateľnosť a konzistencia, ktorá je tam aj dokázaná. Podľa Christopa Molnara [27] môžu byť práve Shapleyho hodnoty jedinou prípustnou metódou na poskytnutie úplného vysvetlenia v prípadoch, keď si zákon vyžaduje vysvetliteľnosť použitej metódy. Poisťovníctvo určite patrí do značne regulovanej sféry, a teda je možnosť, že sa Shapleyho hodnoty budú vo väčšej miere využívať práve tu.

Pre pozorovanie $\mathbf{x}^\top = (x_1, \dots, x_k) \in \mathbf{X}$ majú Shapleyho hodnoty nasledujúcu formu

$$g(\mathbf{x}^\top) = \phi_0 + \sum_{j=1}^k \phi_j z_j,$$

kde $\phi_j \in \mathbb{R}$ pre $j = 1, \dots, k$ je hodnota príspevku lokálneho atribútu spojená s x_j , $\mathbf{z} \in \{0, 1\}^k$ je tzv. koalický vektor (t. j. binárna reprezentácia $\mathbf{x}^\top$) a k je počet atribútov. Hodnota ϕ_0

³³Atribút alebo prediktor je len iné označenie pre premennú vstupujúcu do modelu, ktorá označuje nejakú charakteristiku (napr. vek vodiča je atribút vstupujúci do modelu tvorby poistného.)

reprezentuje intercept (t.j. je priemer $g(\mathbf{X})$).

Shapleyho hodnoty možno odhadnúť rôznymi spôsobmi. Tree SHAP je špecifická implementácia Shapleyho vysvetlením, s ktorou ako prví prišli vo svojej publikácii autori Lundberg, Erion a Lee [28]. Táto implementácia sa nespolieha na meta modely (angl. *surrogate models*). Tree SHAP sa namiesto toho spolieha na prechádzanie internými štruktúrami rozhodovacieho stromu, aby bolo možné odhadnúť vplyv každého x_j pre $g(\mathbf{x}^\top)$, t.j.

$$\phi_j = \sum_{S \subseteq P \setminus \{j\}} \frac{|S|! (|P| - |S| - 1)!}{|P|!} \left[g_{S \cup \{j\}}(\mathbf{x}_{S \cup \{j\}}^\top) - g_S(\mathbf{x}_S^\top) \right],$$

kde $|S|$ značí mohutnosť množiny S (t.j. počet jej prvkov), $|P|$ je mohutnosť množiny $P = \{1, \dots, k\}$ (t.j. celkový počet uvažovaných atribútov) a $g_S(\mathbf{x}_S^\top)$ je predikcia modelu g s použitím len tých prvkov vstupného vektoru $\mathbf{x}^\top$, ktoré zodpovedajú prvkom z množiny S . Tree SHAP a aj niektoré iné Shapleyove prístupy odhadujú ϕ ako rozdiel medzi predikciou modelu na podmnožine prvkov S bez atribútu x_j a predikciou modelu na podmnožine prvkov S s atribútom x_j . Tento rozdiel je sčítaný a primerane zväžený vo všetkých podmnožinách S z P , ktoré neobsahujú x_j (t.j. $S \subseteq P \setminus \{j\}$). V tomto prípade g zahŕňa mapovanie medzi $\mathbf{x}^\top$ a binárnym vektorom $\mathbf{z}^\top$. Keďže trénované funkcie odozvy rozhodovacieho stromu modelujú zložité závislosti medzi vstupnými atribútami (resp. nejakými ich funkciami), odstránenie rôznych podmnožín vstupných atribútov pomáha objasniť skutočný vplyv odstránenia x_j z $g(\mathbf{x}^\top)$. Metóda Tree SHAP sa preto javí ako výpočtovo efektívny prístup pre modely založené na rozhodovacích stromoch. Ďalšie prístupy, ako odhadnúť Shapleyho hodnoty ponúkajú už viackrát spomínaný autori Lundberg a Lee [26], ktorý taktiež ponúkajú vysvetlenie prečo je metóda Tree SHAP z hľadiska výpočtovej náročnosti efektívnejšia ako ostatné.

Okrem individuálneho príspevku jednotlivých atribútov do výslednej predikcie modelu môžu byť Shapleyho hodnoty využité aj na zistenie efektu interakcie jednotlivých atribútov. Ako vo svojej publikácii uvádza napríklad Molnar [27], práve odhalenie interakčného javu je ďalšou praktickou výhodou Shapleyho hodnôt a ide o krok vpred snahe porozumieť fungovaniu zložitých modelov strojového učenia. Hodnotu príspevku interakcie dvoch atribútov môžeme zapísať nasledujúcim spôsobom

$$\phi_{i,j} = \sum_{S \subseteq P \setminus \{i,j\}} \frac{|S|! (|P| - |S| - 2)!}{2(|P| - 1)!} \delta_{ij}(S),$$

kde $i \neq j$ a hodnotu $\delta_{ij}(S)$ môžeme vyjadriť nasledovne

$$\delta_{ij}(S) = g_{S \cup \{i,j\}}(\mathbf{x}_{S \cup \{i,j\}}^\top) - g_{S \cup \{i\}}(\mathbf{x}_{S \cup \{i\}}^\top) - g_{S \cup \{j\}}(\mathbf{x}_{S \cup \{j\}}^\top) + g_S(\mathbf{x}_S^\top). \quad (4.3)$$

Vzťah 4.3 ukazuje, že pri výpočte hodnoty príspevku interakcie do výslednej predikcie modelu g sa odčítavajú individuálne efekty jednotlivých atribútov, aby sme mohli dostať skutočný efekt interakcie. Samozrejme, tento prístup sa dá rozšíriť a umožňuje nám skúmať aj interakcie viacerých ako dvoch atribútov, s čím ale súvisí značne zvýšená výpočtová

náročnosť. Toto využitie Shapleyho hodnôt dáva ale ďalšiu výhodu zložitejším modelom strojového učenia oproti klasickým zovšeobecneným lineárnym modelom. V prípade zovšeobecnených lineárnych modelov musíme prípadné interakcie modelu pridávať manuálne, čím zvyšujeme komplexitu daného modelu a sťažujeme jeho interpretovateľnosť. Navyše, pri väčšom počte atribútov a za predpokladu, že uvažujeme aj interakcie medzi viac ako dvoma premennými, je takmer nemožné manuálne pridať všetky potenciálne interakcie, ktoré môžu mať vplyv na kvalitu modelu. Naopak, pri zložitejších modeloch strojového učenia sú interakcie medzi jednotlivými atribútmi do modelu zahrnuté automaticky. Shapleyho hodnoty nám dávajú iba nástroj, ako efekt týchto interakcií odhaliť a interpretovať. Zároveň môže byť tento prístup využitý aj na odhalenie prípadných vplyvných interakcií medzi jednotlivými atribútmi v rámci prípravy dát a exploračnej analýzy, a následné zistenia môžu byť použité pri tvorbe zovšeobecneného lineárneho modelu. Zložité modely strojového učenia nemusia v blízkej dobe úplne nahradiť široko používané zovšeobecnené lineárne modely. Za zváženie ale určite stojí implementácia moderných techník strojového učenia do procesu tvorby modelu s cieľom nastaviť tarifnú štruktúru tak, aby čo najlepšie zodpovedala rizikovému faktoru klienta. Moderné techniky strojového učenia môžu byť nápomocné pri odhaľovaní zdrojov zbytkovej heterogenity v jednotlivých rizikových skupinách a môžu pomôcť poisťiteľovi pri stanovovaní čo najspravodlivejšieho poistného.

Ďalším faktorom, ktorý zvyšuje výpočtovú náročnosť požadovanú na získanie Shapleyho vysvetlení je skutočnosť, že záleží aj na poradí atribútov pri tvorbe podmnožín S , resp. na poradí, s ktorým atribúty vstupujú do modelu g . Tento koncept je na prvé počutie pomerne ťažko uchopiteľný, keďže pri jednoduchých modeloch ako sú napríklad aj zovšeobecnené lineárne modely to zjavne neplatí. Pri zovšeobecnených lineárnych modeloch je vzťah odozvy a regresorov lineárny, a teda pri snahe vypočítať priemerný vplyv jednotlivých atribútov by poradie týchto atribútov nehralo žiadnu rolu. Pri zložitejších modeloch táto intuícia ale neplatí. Tejto problematike sa čiastočne venujú vo svojej publikácii Biecek s Burzykowskim [29], ktorý vychádzajú z článku Štrumbelja a Kovalenka [30]. Práve z tohto dôvodu sú pri výpočtoch Shapleyho vysvetlení používané Monte Carlo metódy.

Na záver sa pozrime ešte na štyri základné vlastnosti Shapleyho hodnôt.

1. Efektivita: súčet Shapleyho hodnôt je rovný predikcii modelu, t. j.

$$g(\mathbf{x}^\top) = \sum_{j=0}^k \phi_j.$$

2. Symetria: ak pre ľubovoľnú podmnožinu $S \subseteq P \setminus \{i, j\}$ je hodnota príspevkov atribútov x_i a x_j rovnaká, tak aj Shapleyho hodnoty zodpovedajúce týmto príspevkom sa rovnajú.
3. Nulový atribút: ak atribút x_j nijako neprispieva do predikcie modelu g pre žiadnu podmnožinu $S \subseteq P \setminus \{j\}$, tak potom je Shapleyho hodnota zodpovedajúca tomuto atribútu rovná nule.
4. Aditivita: ak je model g súčtom dvoch ďalších modelov f a h , potom aj Shapleyho hodnoty vypočítané pre model g sú súčtom Shapleyho hodnôt vypočítaných

pre modely f a h .

Shapleyho hodnoty sú určite zaujímavou témou aj z hľadiska poistnej matematiky. V tejto sekcii sme si predstavili základné informácie, ako by mohli byť Shapleyho hodnoty využité v strojovom učení, a teda konkrétne aj v sfére poistnej matematiky. Viac informácií o Shapleyho hodnotách, o ich využití v strojovom učení, ich výhodách a nevýhodách ponúkajú už viackrát spomínaný autori, ako napríklad najčastejšie citovaní Lundberg a Lee [26], Molnar [27, kapitola 5] a prepojenie teórie a praktických výpočtov ponúkajú vo svojej publikácii aj Biecek s Burzykowski [29, kapitola 8]. V ďalšej časti práce sa pokúsime vypočítať Shapleyho hodnoty pre gradient boosting model zostrojený pomocou reálnych dát z poisťovne.

4.6.2 Lokálne interpretovateľné modelovo-agnostické vysvetlenia

Shapleyho hodnoty, ktoré sme si predstavili v predchádzajúcej sekcii sú vhodné hlavne pri modeloch s menším počtom atribútov, kde väčšina atribútov nejakým spôsobom vplyva na výslednú predikciu modelu. Zamyslime sa teraz nad prípadom, kedy by sme mali k dispozícii veľké množstvo atribútov, z ktorých by väčšina mala nulový vplyv na výslednú predikciu modelu. V takomto prípade by bolo výpočtovo veľmi neefektívne počítat Shapleyho hodnoty. Autori Ribeiro, Singh a Guestrin [31] predstavili vo svojom článku metódu lokálne interpretovateľných modelovo-agnostických vysvetlení (ozn. LIME³⁴), pomocou ktorých sa pokúšajú vytvoriť reprezentatívnejšie vysvetlenia fitovaním lokálneho meta modelu h v lokálnej oblasti nejakého pozorovania $\mathbf{x}^\top \in \mathbf{X}$, kde $\mathbf{X}$ reprezentuje množinu všetkých pozorovaní. Hlavnou myšlienkou je v podstate aproximovať komplexný model použitím jednoduchšieho a ľahšie interpretovateľného modelu v nejakom lokálnom okolí daného pozorovania. Meta model h aj lokálne regióny možno definovať tak, aby vyhovovali potrebám používateľa. LIME pre pozorovanie $\mathbf{x}^\top \in \mathbf{X}$ môže byť špecifikované nasledujúcim spôsobom

$$\arg \min_{h \in \mathcal{H}} \mathcal{L}(g, h, \pi_{\mathbf{x}}) + \Omega(h),$$

kde h je interpretovateľný meta model modelu g , $\pi_{\mathbf{x}}$ je funkcia váh v doméne g (t. j. definuje ako veľké okolie pozorovania $\mathbf{x}^\top$ bude brané do úvahy v prípade vysvetľovania) a $\Omega(h)$ obmedzuje komplexnosť h . LIME vysvetlenie v podstate len minimalizuje stratovú funkciu $\mathcal{L}(g, h, \pi_{\mathbf{x}})$, zatiaľčo používateľ rozhoduje o komplexite h (napr. voľbou maximálneho počtu regresných parametrov pri zovšeobecnených lineárnych modeloch). Za meta model h je často volený práve zovšeobecnený lineárny model h_{GLM} , ktorý môže byť trénovaný nasledujúcim spôsobom

$$\tilde{\mathbf{X}}, g(\tilde{\mathbf{X}}) \xrightarrow{\text{LASSO}} h_{\text{GLM}},$$

kde $\tilde{\mathbf{X}}$ je vzorka z datasetu $\mathbf{X}$, $\pi_{\mathbf{x}}$ váži $\tilde{\mathbf{X}}$ vzorky podľa ich euklidovskej vzdialenosti od $\mathbf{x}^\top$, aby sa presadila lokalita. Príspevky lokálnych atribútov sa odhadujú ako súčin h_{GLM} koeficientov a s nimi súvisiacimi dátovými hodnotami. Komplexnosť $\Omega(h)$ je definovaná ako penalizácia lasso na h_{GLM} koeficientoch, ktoré sú riedko zastúpené v h_{GLM} . Nedostatočný fit alebo nepresnosť lokálnych lineárnych modelov sú sami o sebe informatívne, a teda

³⁴Z anglického výrazu *Local interpretable model-agnostic explanations*.

často naznačujú extrémnu nelinearitu alebo interakcie vysokého stupňa.

Medzi výhody LIME patrí práve fakt, že ide o modelovo-agnostické vysvetlenie, a teda nie sú kladené žiadne požiadavky na model strojového učenia, ktorý je pomocou LIME vysvetľovaný. Tieto vysvetlenia takisto poskytujú lokálnu presnosť a interpretovateľnú reprezentáciu zložitejšieho modelu strojového učenia. Avšak, LIME majú aj značné nevýhody. V porovnaní s Shapleyho hodnotami, ktoré tiež patria medzi modelovo-agnostické vysvetlenia, chýba LIME konzistencia, keďže voľby meta modelu, lokálnych regiónov a aj komplexnosti meta modelu sú na analytikovi. Rôzne voľby týchto parametrov môžu potom viesť k rôznym výsledkom. Ďalším problémom je takzvané preklatie dimenzionality, t. j. problém s riedkymi dátami a následným určením vhodného okolia. Ďalšou limitáciou LIME je to, že meta model je určený na aproximovanie komplexného modelu strojového učenia a nie na aproximovanie samotných dát. Kvalita lokálneho fitu meta modelu na uvažovaných dátach preto môže byť otázná. LIME vysvetlenia sú taktiež problematické pri klasických tabuľkových dátach, a to konkrétne v prípade kategorických premenných, kde stále nepanuje zhoda, ako postupovať v prípade, keď nie je dostatok dát v okolí skúmaného bodu a akým spôsobom by mali byť generované pomocné dáta, aby bola dosiahnutá čo najväčšia presnosť. Bližšie problematiku LIME vysvetlení spracovávajú autori Biecek a Burzykowski [29, kapitola 9], ktorí ponúkajú aj softvérovú implementáciu a praktickú demonštráciu tejto techniky.

4.6.3 Grafy parciálnej závislosti a individuálnych podmienených očakávaní

Poslednými vysvetľovacími technikami, ktoré si v tejto podkapitole predstavíme sú grafy parciálnej závislosti (ozn. PDP³⁵), grafy akumulovaného lokálneho efektu (ozn. ALE³⁶) a grafy individuálnych podmienených očakávaní (ozn. ICE³⁷) Zatiaľčo Shapleyho vysvetlenia a LIME predstavené v predošlých kapitolách sú metódy kvantifikujúce vplyv atribútov v kontexte predikcie pre jediné pozorovanie, metódy PDP, ALE a ICE vyhodnocujú efekt vybraného atribútu v zmysle zmien predikcie modelu g vyvolaných zmenami hodnôt daného atribútu. Tieto metódy skúmajú vplyv určitého atribútu za predpokladu, že hodnoty ostatných atribútov zostávajú nezmenené. Cieľom je porozumieť, ako zmeny hodnôt daného atribútu vplývajú na predikciu modelu g .

Grafy parciálnej závislosti v kontexte gradient boosting modelov prvýkrát predstavené Friedmanom [25] a možno ich podľa Kuoa a Luptona [19] vyjadriť nasledujúcou otázkou: „Ako sa v priemere zmenia predpokladané straty, keď zmeníme vstup?“ PDP je široko používaná metóda na opis priemerných predpovedí komplexného modelu g naprieč nejakou oblasťou údajov $\mathbf{X}$ pre daný atribút $\mathbf{X}_j \in \mathbf{X}$. Značenie je v tomto prípade iné, aby sme zdôraznili, že ide o globálne efekty, a teda označenie atribút $\mathbf{X}_j$ v tomto prípade zodpovedá j -temu stĺpcu matice $\mathbf{X}$ a nesie informácie o hodnotách j -tej premennej pre všetky pozorovania v datasete. Pre lepšiu predstavu si uveďme príklad. Atribút $\mathbf{X}_j$ môže predsta-

³⁵Z anglického výrazu *Partial dependence plots*

³⁶Z anglického výrazu *Accumulated local effects*.

³⁷Z anglického výrazu *Individual conditional expectation*.

vovať v tomto prípade určitú charakteristiku klientov v poisťnom kmeni, ako napríklad typ vozidla. Atribút $\mathbf{X}_j$ zodpovedajúci typu vozidla môže teda nadobúdať rôzne hodnoty, ako napríklad sedan, kombi, suv, a podobne. Doplnok $\mathbf{X}_j$ je označený ako $\mathbf{X}_{(-j)} \in \mathbf{X}$. Tento doplnok nesie informácie o ostatných atribútoch, resp. charakteristikách klienta, ktoré má poisťiteľ k dispozícii, ako napríklad vek, bydlisko, a podobne. Platí $\mathbf{X}_j \cup \mathbf{X}_{(-j)} = \mathbf{X}$. Potom sa PDP pre daný atribút $\mathbf{X}_j$ odhaduje ako priemerný výstup modelu $g(\mathbf{X})$, keď sa hodnoty atribútu $\mathbf{X}_j$ postupne menia hodnoty ostatných atribútov (t. j. $\mathbf{X}_{(-j)}$) zostávajú nezmenené. Počas fázy vývoja modelu možno PDP použiť aj ako test primeranosti pre kandidátske modely identifikáciou neočakávaných vzťahov, ktoré má analytik preskúmať. Mali by sme byť ale opatrní pri interpretácii PDP v prípade, ak existujú silne korelované údaje. Potom môžeme brať do úvahy nereálne údaje (napr. vysoký vek vozidla pre model, ktorý je úplne nový na trhu). Na vyriešenie tohto nedostatku boli navrhnuté alternatívne techniky vizualizácie, ako sú grafy akumulovaného lokálneho efektu popísané napríklad v článku od Apleyho a Zhua [32]. Metóda ALE rieši problém s prípadnou koreláciou jednotlivých atribútov počítaním očakávaných zmien vo výstupe modelu nad podmienenými, a nie nad marginálnymi distribúciami.

Grafy individuálnych podmienených očakávaní sú novšou metódou, ktorú vo svojej publikácii predstavila skupina autorov Goldstein a kol. [33]. Narozdiel od grafov PDP a ALE, ktoré patria medzi globálne metódy zamerané na celový priemerný efekt daného atribútu, metóda ICE popisuje lokálne správanie modelu g pre jedno pozorovanie $\mathbf{x}^\top \in \mathbf{X}$. Pre dané pozorovanie $\mathbf{x}^\top$ a atribút x_j je potom očakávanie ICE odhadované ako výstup $g(\mathbf{x}^\top)$, ak je atribút x_j nastavený na konštantu a všetky ostatné atribúty sú ponechané v pôvodnom stave. Krivky PDP a ICE sa preto zvyčajne vykrešľujú cez určitú množinu konštánt. Zatiaľčo použitie samotného PDP môže byť zavádzajúce v prítomnosti silnej korelácie alebo interakcií medzi jednotlivými atribútmi, vykreslenie PDP spolu s ICE poskytuje priamu vizuálnu indikáciu, či je zobrazená čiastočná závislosť dôveryhodným zástupcom jednotlivých predpovedí. Porovnanie grafov PDP a ICE s histogramom pre atribút $\mathbf{X}_j$ môže poskytnúť základnú kvalitatívnu mieru neistoty tým, že umožní vizuálne objavenie hodnôt predikcie modelu, ktoré sú založené len na malom množstve tréningových údajov. Keďže monotónnosť je často požadovaným znakom pre interpretovateľné modely, grafy PDP a ICE možno použiť na overenie monotónnosti $g(\mathbf{X})$ v priemere, a takisto naprieč percentilmi $g(\mathbf{X})$ vzhľadom na daný atribút $\mathbf{X}_j$. Porovnanie metód PDP, ALE a ICE môžeme nájsť v publikácii od Molnara [27, kapitola 5], kde sú odlišnosti znázornené aj graficky na praktických príkladoch.

Hlavným dôvodom, prečo sú a budú stále používané zovšeobecnené lineárne modely je to, že sú jednoduché, ľahko interpretovateľné a aplikátori dokážu rozlíšiť medzi diskriminačným a nediskriminačným rozhodovaním. Avšak v prípadoch, keď vzťahy v modeli nemajú lineárny alebo polynomickejší charakter, zovšeobecnený lineárny model môže spôsobiť nedostatočnú interpretovateľnosť alebo preučenie. Preto potrebujeme na aproximáciu reality komplexnejšie modely. GBM nám môžu priniesť dobrú presnosť predpovedí v zložitých modeloch, avšak nedokážeme rozlíšiť medzi diskriminačným a nediskriminačným rozhodovaním. Potenciálnu diskrimináciu môžeme minimalizovať práve použitím vysvetľujúcich techník. Pokračovanie vo vývoji nových techník a metód prinesie rýchly pokrok

v strojovom učení a môže spôsobiť revolučné zmeny v poisťovníctve a finančnom sektore. Úplný prechod z GLM na GBM môže ušetriť čas, a takisto znížiť cenu nákladov.

Kapitola 5

Tvorba modelu

Ako hovorí názov tejto práce, naším cieľom je segmentácia klientov v neživotnom poistení. V predchádzajúcich kapitolách sme si povedali, aké pravdepodobnostné rozdelenia sa v neživotnom poistení najčastejšie využívajú, ukázali sme si tradičný spôsob, ako sa dá modelovať počet poistných udalostí, a takisto sme si v krátkosti predstavili modernejšie techniky strojového učenia, ktoré môžu byť taktiež aplikované na uvažovanú problematiku. V tejto kapitole sa zameriame na samotnú konštrukciu modelu počtu poistných udalostí. Ako tomu bolo počas celej práce, aj v tejto časti sa zameriame na najväčší segment neživotného poistenia – poistenie motorových vozidiel.

Pripomeňme si, že na začiatku poistného vzťahu musí byť klient poisťiteľom zaradený do jednej z tarifných skupín, v závislosti od čoho sa bude odvíjať výška jemu prislúchajúceho základného poistného. Úlohou poistných matematikov je teda zostaviť tarifnú štruktúru, ktorá zaistí zdravý chod poisťovne a zároveň zabezpečí, aby klient platil poistné v takej výške, ktorá najlepšie zodpovedá jeho rizikovému faktoru. Z toho plynie, že jednotlivé tarifné skupiny by mali byť rizikovo homogénne. V predchádzajúcej časti práce sme si už povedali, že tomu v skutočnosti tak nie je a že v každej skupine ostáva istá miera heterogenity, ktorá je následne postupne odstraňovaná aposteriornou korekciou poistného prostredníctvom systému bonus-malus. Každopádne, my sa v tejto časti práce zameriame na apriórnu segmentáciu klientov do rizikových skupín. Na základe pozorovateľných rizikových faktorov sa budeme snažiť klientov rozdeliť do čo najviac homogénnych tarifných skupín. Pre každú takúto skupinu vypočítame očakávanú ročnú frekvenciu poistných nárokov. Na záver si povieme, aké ďalšie kroky by ešte poisťiteľ mohol zvážiť, aby vedel vhodne nastaviť tarifnú štruktúru poistenia.

5.1 Predstavenie dát

K vytvoreniu vhodného modelu na rozdelenie klientov do tarifných skupín budeme využívať dáta poskytnuté nemenovanou rakúskou poisťovňou. Tieto dáta boli zozbierané v rokoch 2013, 2014 a 2015 a týkajú sa poistenia zodpovednosti za škodu spôsobenú prevádzkovaním motorového vozidla. Predstavenie jednotlivých atribútov tohto datasetu môžeme vidieť v Tabuľke 5.1, kde sú zobrazené len premenné, ktoré boli využité v ďalšom

procesu tvorby modelu. K dispozícii sme mali aj premennú, ktorá obsahovala unikátne číslo poistnej zmluvy, pomocou ktorej sme mohli dáta zgrupovať a napočítať konkrétny počet poistných nárokov na jednu poistnú zmluvu. Ďalej sme mali k dispozícii aj premenné nesúce informácie o konkrétnom roku začiatku poistenia, konkrétnych dátumoch začiatku a konca poistenia a konkrétnom dátume dopravnej nehody. Tieto premenné boli použité k následnej úprave dát a odhaľovaniu potenciálnych odľahlých a chybných pozorovaní.

Tabuľka 5.1: Premenné v dátovom súbore

Označenie	Názov premennej	Možné hodnoty
NumClaims	Počet dopravných nehôd	0, 1, 2, 3, 4, 5, 6
Exposure	Doba trvania poistky (v rokoch)	0–3
Age	Veková kategória poistenca (v rokoch)	18–24
		25–34
		35–44
		45–54
		55–64
		65 a viac
Gender	Pohlavie klienta	M (muž), F (žena)
County	Oblasť bydliska poistenca	A, B, C, D
CarAge	Veková kategória vozidla (v rokoch)	3 a menej
		4–10
		11–15
		16 a viac
Weight	Váhová kategória vozidla (v kg)	1 200 a menej
		1 201–1 600
		1 601–2 000
		2 001 a viac
EngPerfKW	Kategória výkonu vozidla (v kW)	60 a menej
		61–100
		101–150
		151 a viac
Make	Výrobca vozidla	Audi, BMW, Mazda Opel, Renault, Volkswagen

Celý dataset očistený od chybných, chýbajúcich a príliš odľahlých pozorovaní sa skladá z 21 534 pozorovaní. Premennými, ktoré nás budú na začiatok najviac zaujímať, sú premenné NumClaims a Exposure, ktoré hovoria o počte dopravných nehôd na jednu zmluvu, respektíve o dĺžke trvania poistenia v rokoch. Naším cieľom bude modelovať očakávaný počet poistných nárokov na jednu zmluvu za jeden kalendárny rok.

K Tabuľke 5.1 je ešte potrebné povedať, že v prípade premenných Age, CarAge, Weight a EngPerfKW boli poskytnuté údaje v spojitom tvare. V Tabuľke 5.1 uvedené kategórie boli vytvorené až po následnej exploračnej analýze. Procesu kategorizácie predchádzalo preskúmanie poistného trhu s motorovými vozidlami. Pri premennej Exposure sme sa obmedzili len na poistné zmluvy s trvaním aspoň 14 dní. Po preskúmaní českého poist-

ného trhu sme dospeli k záveru, že väčšina poistiteľov neponúka poistenie zodpovednosti z prevádzkovania vozidla ani havarijne poistenie na kratšiu dobu ako 14 dní. Vo väčšine prípadov ide o poistenie na jeden kalendárny rok s možnosťou následnej prolongácie. Istá časť klientov si zjednáva aj takzvané krátkodobé poistenie na dobu od 14 dní do 3 mesiacov. Pri premennej Exposure je ďalej dobré si všimnúť, že nadobúda hodnoty v rozmedzí od 0 do 3. Toto rozmedzie môže byť v rozpore s väčšinou zdrojov, kde sa pri takomto type poistenia uvádza skôr rozmedzie 0–1. Treba ale vziať na vedomie fakt, že dáta boli zozbierané v rozmedzí troch kalendárnych rokov a našim cieľom je využiť všetky dostupné dáta na tvorbu modelu, ktorý dokáže túto očakávanú ročnú frekvenciu nehodovosti predikovať. Ak by sme uvažovali len dáta za jednotlivé roky, tak by sme buď museli obmedziť počet vstupných dát, alebo by sme do modelu vniesli duplicitné údaje. Z tohto dôvodu budeme v procese tvorby modelu uvažovať premennú Exposure v rozmedzí od 0 do 3. Ukážka dát je dostupná v Prílohe A.

5.2 Tvorba GLM

Na začiatku procesu tvorby modelu je dôležitá analytická znalosť domény. Pri zovšeobecnených lineárnych modeloch a konkrétne pri modelovaní počtu poistných nárokov v poistení motorových vozidiel je typická kategorizácia numerických premenných. Použitie numerických regresorov v modeli je obmedzujúce, keďže sa požaduje monotónna závislosť na odozve. V praxi často nie je táto podmienka splnená, a preto sa väčšinou robí kategorizácia numerických prediktorov aj za cenu zvýšenia počtu neznámych parametrov. Navyše, z hľadiska interpretovateľnosti a pochopenia daného modelu je takisto vhodnejšie použiť kategorizáciu numerických premenných, ak je to možné.

Tabuľka 5.2: Pozorované počty poistných nárokov v poistnom kmeni

Počet poistných nárokov	Absolútny počet zmlúv	Relatívny počet zmlúv	Celková doba trvania poistiek (v rokoch)
0	18 965	87,01 %	32 508,1
1	2 424	11,12 %	5 251,5
2	331	1,52 %	735,4
3	63	0,29 %	138,9
4	11	0,05 %	24,2
5	2	0,01 %	3,9
6	1	0,01 %	2,2

V našom prípade je závislou premennou počet dopravných nehôd (t. j. `NCIaims`). V Tabuľke 5.2 vidíme pozorované počty zaznamenaných nehôd v poistnom kmeni. Cieľom je modelovať očakávaný počet dopravných nehôd na jednu zmluvu. Avšak, v uvažovanom poistnom kmeni sa nachádzajú poistné zmluvy uzavreté na rôzne obdobia. Nachádzajú sa tam zmluvy uzavreté na 14 dní, ale aj na jeden rok s následnou prolongáciou až na 3 roky v celkovom súčte. Keďže máme v poistnom kmeni poistné zmluvy s rôznou

dĺžkou trvania poistky, tak nemôžeme na modelovanie počtu dopravných nehôd na jednu zmluvu použiť zovšeobecnený lineárny model bez ďalšej úpravy. Je potrebné si uvedomiť, že predpokladom použitia zovšeobecneného lineárneho modelu je, aby sa odozva riadila pravdepodobnostným rozdelením z triedy exponenciálnych rozdelení. V našom prípade ide dokonca o počítacie rozdelenia, ktoré sme si predstavili v Kapitole 2. Ak si vezmeme napríklad Poissonovo rozdelenie, ktoré popisuje očakávaný počet riedkych javov za určitú jednotku času, tak je hneď jasné, že v našom prípade nie je splnená určitost' jednotky času. Aby sme dosiahli túto určitost', tak môžeme buď uvažovať len poistné zmluvy s ročnou platnosťou poistky alebo musíme štandardizovať počet dopravných nehôd tým spôsobom, že pozorovaný počet dopravných nehôd vydělíme dĺžkou trvania poistky. V ďalšej časti tejto práce budeme uvažovať rôzne dĺžky poistnej doby, keďže chceme využiť všetky dostupné dáta a vytvoriť čo najlepší model. Navyše, v praxi sa neuzatvárajú poistné zmluvy len na obdobie jedného roka, a preto je tento postup všeobecnejší a môže byť aplikovaný v rôznych prípadoch. Aby sme ale tento koncept dokázali aj teoreticky uchopiť, musíme si stručne predstaviť teóriu náhodných počítacích procesov.

5.2.1 Počítacie procesy

Definícia 5.1 (Náhodný proces). Nech $(\Omega, \mathcal{A}, P)$ je pravdepodobnostný priestor a T je indexová množina. Náhodný proces $\{X(t, \omega); t \in T\}$ je zobrazenie

$$X : T \times \Omega \rightarrow \mathbb{R},$$

ktoré je tzv. $\mathcal{A}$ -merateľné, tzn.

$$\forall t \in T, \forall B \in \mathcal{B} : \underbrace{\{\omega \in \Omega : X(t, \omega) \in B\}}_{X_t^{-1}(B)} \in \mathcal{A}.$$

Uvažujme teda náhodný proces $N(t)$ podľa definície 5.1, v ktorom t nadobúda hodnoty z indexovej množiny T . Množina T bude v tomto prípade reprezentovať čas, a teda $T = \mathbb{R}_0^+$. Náhodný proces $\{N(t), t \in T\}$ nazývame počítací proces, ak $N(t)$ predstavuje celkový počet výskytu udalostí do času t . Počítací proces spĺňa nasledujúce predpoklady.

1. $N(t) \geq 0$.
2. $N(t)$ nadobúda hodnoty z množiny $\mathbb{N}_0$.
3. $\forall s, t \in T$ platí, že ak $s < t$, potom $N(s) < N(t)$.
4. $\forall s, t \in T$ také, že $s < t$, zodpovedá rozdiel $N(t) - N(s)$ počtu výskytu udalostí v časovom intervale $(s, t]$.

Ďalej budeme tiež predpokladať, že pre počiatkový stav procesu platí $N(0) = 0$.

V poistnej matematike sa na modelovanie počtu škôd používa najčastejšie Poissonov regresný model kvôli jeho jednoduchosti, jednoduchej interpretovateľnosti a pomerne dobrej predikčnej sile. V Kapitole 2 sme si predstavili viacero pravdepodobnostných rozdelení,

ktorými sa môžu počty škôd v poisťovníctve riadiť. Všetky tieto pravdepodobnostné rozdelenia môžu byť použité pri tvorbe zovšeobecneného lineárneho modelu, dokonca aj modifikované pravdepodobnostné rozdelenia z podkapitoly 2.4. Ak sa zameriame na rozdelenia bez dodatočnej modifikácie, tak sme si v Poznámke 2.5 uviedli, aké sú typické vzťahy strednej hodnoty a rozptylu pre náhodné veličiny riadiace sa danými pravdepodobnostnými rozdeleniami. Tieto vzťahy treba mať na pamäti, keď sa rozhodujeme aký model by bolo vhodné uvažovať pre náš daný problém. Použitie Poissonovho modelu predpokladá, že poistný kmeň je rizikovo homogénny, čo ale v praxi nemusí vždy platiť. V prípade značnej heterogenity v poistnom kmeni je potom dobré uvažovať ďalšie alternatívy, ako napríklad kvázi Poissonov model, negatívne binomický model alebo aj zmiešaný Poissonov model. Každý z týchto modelov má svoje výhody aj nevýhody a každý z nich môže byť určený na iný typ problému. Záleží len od skúseností analytika a od jeho znalosti domény, s ktorou pracuje. Z Tabuľky 5.2 nie je ťažké vypočítať strednú hodnotu (0, 153) a rozptyl (0, 187) premennej N_{Claims} . Vidíme, že rozptyl je väčší ako stredná hodnota, čo by mohlo indikovať skôr použitie negatívneho binomického modelu. Pri Poissonovej regresii je dôležité, aby stredná hodnota závislej premennej bola funkciou regresorov (viď. podkapitola 3.2). Dôležité je, aby neboli porušené predpoklady použitia takéhoto modelu, ktorými sú napríklad práve overdispéria, prítomnosť vplyvných outlierov alebo multikolinearita regresorov. V našom prípade budeme na začiatok uvažovať Poissonov regresný model. S outliermi sme sa vysporiadali už pri počiatočnom procesovaní dát. Pri exploračnej analýze nebola zistená významná korelácia medzi regresormi a prípadnú overdispériu si otestujeme pri tvorbe modelu. Poďme si teda zadefinovať samotný Poissonov proces, aby sme si teoreticky podložili náš skúmaný problém.

Definícia 5.2 (Homogénny Poissonov proces). Počítací proces $\{N(t), t \in T\}$ nazývame homogénny Poissonov proces s intenzitou $\lambda > 0$, ak spĺňa nasledujúce vlastnosti.

1. Prírastky náhodného procesu sú stacionárne, t. j. pre $\forall s, t \in T$, časový prírastok Δ a $\forall k \in \mathbb{N}_0$ platí

$$P[N(t + \Delta) - N(t) = k] = P[N(s + \Delta) - N(s) = k].$$

2. Prírastky náhodného procesu sú nezávislé, a teda $\forall k \in \mathbb{N}_0$ a pre všetky časové okamihy $0 \leq t_0 < t_1 < \dots < t_k$ platí, že rozdiely náhodných veličín $N(t_1) - N(t_0), N(t_2) - N(t_1), \dots, N(t_k) - N(t_{k-1})$ sú vzájomne nezávislé.

3. Platí

$$P[N(h) = k] \begin{cases} 1 - \lambda h + o(h) & \text{pre } k = 0 \\ \lambda h + o(h) & \text{pre } k = 1 \\ o(h) & \text{pre } k \geq 2, \end{cases}$$

kde $o(h)$ je funkciou h a platí pre ňu nasledovné

$$\lim_{h \rightarrow 0^+} \frac{o(h)}{h} = 0.$$

Veta 5.1. Pre každý Poissonov proces platí, že počet výskytu udalostí v časovom intervale dĺžky t sa riadi Poissonovým rozdelením so strednou hodnotou λt , a teda platí vzťah

$$P[N(t+s) - N(s) = k] = \frac{(\lambda t)^k}{k!} \exp\{-\lambda t\}, \quad k = 0, 1, 2, \dots \quad (5.1)$$

Dôkaz. Dôkaz je dostupný v publikácii od Denuita a kol. [5, str. 18]. $\square$

Opäť si pripomeňme, že v našom poistnom kmeni sa nachádzajú poistné zmluvy s rôznou dĺžkou platnosti. Naším cieľom je modelovať počet poistných nárokov na jednu poistnú zmluvu, a práve Definícia 5.2 a Veta 5.1 nám dávajú nástroj na to, ako sa s týmto problémom vysporiadať. Preformulujme si náš skúmaný problém. Predpokladajme, že počet výskytu dopravných nehôd za jednotku času sa riadi Poissonovým rozdelením s parametrom λ . Jednotkou času je v tomto prípade kalendárny rok. Ďalej predpokladajme, že i -ty klient má uzavretú zmluvu s poistiteľom na dobu t_i . Potom sa počet poistných nárokov N_i riadi Poissonovým rozdelením s pravdepodobnostnou funkciou

$$P[N_i = k_i] = \frac{(\lambda t_i)^{k_i}}{k_i!} \exp\{-\lambda t_i\}, \quad k_i = 0, 1, 2, \dots \quad (5.2)$$

a môžeme písať, že platí $N_i \sim \text{Pois}(\lambda t_i)$.

Ak sa pozrieme na údaje z Tabuľky 5.1, a takisto na vzťah (5.2), tak vidíme, že premenná N_{Claims} , ktorá je našou závislou premennou, obsahuje informácie zodpovedajúce náhodnej veličine N_i , premenná Exposure obsahuje informácie zodpovedajúce premennej t_i a naším cieľom zostáva odhadnúť frekvenciu nehodovosti zodpovedajúcu premennej λ .

Pripomeňme si informácie z podkapitoly 3.2, v ktorej sme sa zaoberali zovšeobecnenými lineárnymi modelmi. Chceme teraz túto teóriu aplikovať na vytvorenie modelu, ktorý dokáže popisovať počet dopravných nehôd na jednu poistnú zmluvu a ktorý zároveň bude zohľadňovať dĺžku trvania poistnej zmluvy. Inými slovami, chceme vytvoriť model, ktorý dokáže popisovať podiel $\frac{N_i}{t_i}$, resp. vzhľadom na naše dáta $\frac{N_{\text{Claims}_i}}{\text{Exposure}_i}$. Pripomeňme si, že náhodná veličina zodpovedajúca počtu poistných nárokov môže nadobúdať hodnoty z množiny $\mathbb{N}_0$. Avšak hodnota premennej označujúcej dĺžku trvania poistenia môže teoreticky mať ľubovoľnú hodnotu z množiny $\mathbb{R}_0^+$. Pomocou predstavených vzťahov (3.2) a (3.5) si teraz zapíšme náš skúmaný problém nasledujúcim spôsobom.

$$\begin{aligned} E\left(\frac{N_i}{t_i}\right) &= \exp\{\mathbf{x}_i^\top \boldsymbol{\beta}\} \\ \frac{E(N_i)}{t_i} &= \exp\{\mathbf{x}_i^\top \boldsymbol{\beta}\} \\ E(N_i) &= t_i \cdot \exp\{\mathbf{x}_i^\top \boldsymbol{\beta}\} \end{aligned} \quad (5.3)$$

Opäť sa vráťme k predpokladu, že počet dopravných nehôd sa riadi Poissonovým rozdelením, a teda na základe údajov z Tabuľky 3.2 budeme uvažovať logaritmicкую link funkciu, t. j. platí

$$\ln(N_i) \approx \ln(t_i) + \mathbf{x}_i^\top \boldsymbol{\beta}, \quad (5.4)$$

kde člen $\ln(t_i)$ nazývame offset. V prípade, ak by sme chceli uvažovať iné pravdepodobnostné rozdelenie, prípadne inú link funkciu, treba len vhodne upraviť vzťah (5.4). Podstatné je, že musíme túto premennú do nášho zovšeobecneného lineárneho modelu zakomponovať.

V prípade homogénneho Poissonovho procesu za predpokladu, že platí $N_i \sim \text{Pois}(t_i \lambda_i)$, môžeme použitím vety 5.1 a vzťahu 5.3 dokonca odvodiť nasledujúci vzťah

$$E(N_i) = t_i \lambda_i = t_i \exp\{\mathbf{x}_i^\top \boldsymbol{\beta}\},$$

a potom platí

$$\lambda_i = \exp\{\mathbf{x}_i^\top \boldsymbol{\beta}\}. \quad (5.5)$$

Keď zohľadníme všetky vyššie spomenuté skutočnosti, tak parameter λ_i z rovnice (5.5) označuje očakávanú ročnú frekvenciu poistných nárokov na poistnej zmluve i .

Cieľom práce je ale segmentácia klientov v neživotnom poistení, takže správanie jednotlivca nie je v centre nášho záujmu. Viac nás zaujíma špecifické správanie určitej skupiny klientov. V tejto práci sa zameriavame na počet poistných nárokov a snažíme sa vytvoriť model, na základe ktorého by sme vedeli klientov odlíšiť z hľadiska ročnej frekvencie nehodovosti. Predpokladajme, že parameter λ_i bude popisovať ročnú frekvenciu nehodovosti v určitej skupine klientov. Tento môžeme odhadnúť pomocou metód predstavených v podkapitole 3.3. My sa teraz konkrétne zameriame na odhad metódou maximálnej vierohodnosti, ktorú sme si popísali v sekcii 3.3.2. Opäť budeme predpokladať Poissonovo rozdelenie, t. j. $N_i \sim \text{Pois}(t_i \lambda)$, kde v tomto prípade bude parameter λ zodpovedať očakávanej ročnej frekvencii nehodovosti klientov v určitej rizikovej skupine klientov. Predpokladáme, že správanie klientov v tejto skupine je homogénne, a preto vypúšťame indexáciu parametru λ . Vierohodná funkcia bude potom v tvare

$$\mathcal{L}(\lambda; N) = \prod_{i=1}^n \exp(-\lambda t_i) \frac{(\lambda t_i)^{k_i}}{k_i!}, \quad k_i = 0, 1, 2, \dots$$

a logaritmická vierohodná funkcia v tvare

$$\ell(\lambda; N_i) = -\lambda \sum_{i=1}^n t_i + \sum_{i=1}^n k_i [\ln(\lambda) + \ln(t_i)] - \sum_{i=1}^n \ln(k_i!), \quad k_i = 0, 1, 2, \dots \quad (5.6)$$

Maximum funkcie (5.6) dostaneme, ak položíme prvú deriváciu tejto funkcie rovnú 0 a vyriešime túto rovnicu. V tomto prípade je to jednoduché a vieme to dobre zapísať aj analyticky, a to nasledujúcim spôsobom

$$\frac{\partial \ell(\lambda; N_i)}{\partial \lambda} = -\lambda \sum_{i=1}^n t_i + \frac{1}{\lambda} \sum_{i=1}^n k_i = 0. \quad (5.7)$$

Riešením rovnice (5.7) je

$$\hat{\lambda} = \frac{\sum_{i=1}^n k_i}{\sum_{i=1}^n t_i}, \quad k_i = 0, 1, 2, \dots \quad (5.8)$$

Očakávanú ročnú frekvenciu nehodovosti v danej rizikovej skupine klientov teda vieme jednoducho vypočítať pomocou vzťahu (5.8), ktorý v podstate reprezentuje podiel súčtu celkového počtu dopravných nehôd v danej skupine klientov a celkovej dĺžky poisťnej doby v tejto skupine.

5.2.2 Dopredná selekcia regresných parametrov

V tejto podkapitole sa zameriavame na tvorbu zovšeobecneného lineárneho modelu. Ako sme si povedali v predchádzajúcej sekcii, zameriame sa konkrétne na tvorbu Poissonovho regresného modelu. Na začiatok si však ešte rozdelíme celý dataset v pomere 80:20 na trénovacie a testovacie dáta. Na trénovaciu vzorku v ďalšom procese aplikujeme aj krížovú validáciu, ale testovaciu vzorku si necháme na porovnanie GLM a GBM, čomu sa budeme venovať na záver celej práce. Celý ďalší postup bude teda uskutočnený na trénovacej vzorke 17 438 pozorovaní. Existuje viacero spôsobov, ako postupovať pri tvorbe modelu a pri samotnom výbere vhodných regresorov. Viacero rôznych prístupov dobre popisujú autori James a kol. [14, kapitola 6]. Výber postupu opäť závisí od skúseností, preferencií analytika, a takisto jeho znalosti problému, s ktorým pracuje. My budeme postupovať takzvanou doprednou selekciou regresorov. Celý popis tohto postupu môžeme taktiež nájsť v spomínanej publikácii od skupiny autorov James a kol. [14, str. 207–208]. V podstate si zvolíme porovnávacie kritéria na základe ktorých budeme porovnávať jednotlivé modely a začneme od nulového modelu (t. j. v našom prípade model obsahujúci len offset). V ďalšom kroku postupne zostrojíme všetky modely obsahujúce práve jeden regresor a na základe zvolených porovnávacích kritérií vyberieme najlepší model za predpokladu, že aspoň jeden z vytvorených modelov je lepší ako nulový model. V ďalšom kroku postupujeme analogicky a opäť vytvoríme všetky možné modely pridaním práve jedného zo zostávajúcich regresorov. Modely opäť porovnáme a skúsime, či došlo k zlepšeniu od predchádzajúceho kroku. Celý proces opakujem, až kým nedospejeme ku vhodnému modelu.

Je potrebné dodať pár poznámok, a síce, že celý proces doprednej selekcie môže byť zautomatizovaný. Pri malom počte regresorov a konkrétne pri tvorbe zovšeobecneného lineárneho modelu sa ale odporúča postupovať krok po kroku, kedy analytik môže využiť svoje skúsenosti a znalosť domény, prípadne môže byť použitá širšia škála porovnávacích kritérií. Taktiež bude jednoduchšia následná interpretácia výsledkov. Pri vyššom počte regresorov je vhodné zvážiť použitie regularizačných techník, ako napríklad hrebeňová regresia alebo lasso regresia. Tieto metódy fungujú na princípe úmyselného drobného vychýlenia modelu, ktoré ale značne zníži varianciu. Lasso regresia dokonca dokáže pomôcť s identifikáciou regresorov, ktoré signifikantne ovplyvňujú výkonnosť modelu. Vyčerpávajúcejšie informácie k týmto metódam opäť ponúkajú autori James a kol. [14, sekcia 6.2].


Výber vhodnosti porovnávacích kritérií takisto závisí od skúmaného problému. V našom prípade budeme uvažovať porovnávacie kritéria predstavené v sekcii 3.4.4, t. j. AIC, BIC a strednú kvadratickú chybu (t. j. MSE). Budeme postupovať doprednou selekciou regresorov od nulového modelu až po saturovaný, zatiaľ čo budeme zaznamenávať všetky porovnávacie kritéria. Ďalej sa zameriame na analýzu deviácie, ktorú sme si priblížili v sekcii 3.4.3. Aby

sme sa vyhli preučeniu modelu, tak budeme využívať krížovú validáciu predstavenú v sekcii 3.4.2. Budeme uvažovať 10-násobnú krížikovú validáciu. Kým pristúpime k samotnému modelovaniu, tak treba ešte poznamenať, že hneď na začiatku procesu sme vyradili premennú Gender, ktorá uchováva informácie o pohlaví klienta. Týmto krokom sa vyhneme prípadnej diskriminácii na základe pohlavia. Ako sme už viackrát spomenuli, poisťná sféra je pomerne regulované odvetvie a vo viacerých krajinách v dnešnej dobe nie je prípustné, aby klienti platili rozdielnu výšku poisťného len na základe ich pohlavia za krytie rizík, ktoré nesúvisia s pohlavím. Po vypustení premennej Gender budeme mať teda k dispozícii už len 6 regresorov. Pri procese tvorby modelu budeme využívať štatistický softvér R. Používané funkcie sú dostupné v Prílohe B.


Tabuľka 5.3: Porovnanie modelov na základe informačných kritérií

Popis modelu	AIC	BIC
offset	14 158	14 166
offset+County	14 047	14 078
offset+County+Age	13 955	14 024
offset+County+Age+Weight	13 943	14 034
offset+County+Age+Weight+CarAge	13 934	14 049
offset+County+Age+Weight+CarAge+Make	13 933	14 087
offset+County+Age+Weight+CarAge+Make+EngPerfKW	13 936	14 112


V Tabuľke 5.3 máme zaznamenané hodnoty informačných kritérií v závislosti na tom, ako sme postupne budovali model pridávaním jednotlivých regresorov. Postupovali sme doprednou selekciou a v každom kroku sme vybrali regresor, ktorý najvýraznejšie prispel k zlepšeniu. Pre úplnosť treba dodať, že dopredná selekcia bola robená postupne a v každom kroku boli zvážené všetky porovnávacie kritéria. Pre prehľadnosť však do Tabuliek a grafov zahrnieme len modely, ktoré boli v každom kroku vyhodnotené ako tie najlepšie. Značenie offset v Tabuľke 5.3 zodpovedá výrazu $\ln(\text{Exposure})$. Vidíme, že minimálne AIC bolo dosiahnuté po pridaní 5 regresorov, zatiaľčo minimálne BIC sme dosiahli už po pridaní 2 regresorov. Vývoj hodnôt informačných kritérií v závislosti na počte regresorov môžeme vidieť aj v grafe na Obrázku 5.1, pričom výber regresorov zodpovedá Tabuľke 5.3. V grafe na Obrázku 5.2 môžeme vidieť vývoj strednej kvadratickej chyby v závislosti na počte regresorov modelu. Tu vidíme, že minimálna chybovosť bola dosiahnutá po postupnom pridaní 3 najlepších regresorov. Na základe uvedených informácií je zrejmé, že každé z porovnávacích kritérií indikuje výber iného modelu ako najvhodnejšiu voľbu. Poďme sa ešte pozrieť na analýzu deviácie.



Obr. 5.1: Informačné kritéria v závislosti na počte regresorov



Obr. 5.2: Vývoj strednej kvadratickej chyby v závislosti na počte regresorov



Obr. 5.3: Vývoj deviácie v závislosti na počte regresorov

Z grafu na Obrázku 5.3 je zrejmé, že deviácia klesá s postupným pridávaním regresorov. Toto správanie nie je prekvapivé, keďže pridávaním parametrov do modelu sa vysvetľuje stále viac a viac variancie, a teda aj deviácia klesá. Nižšia deviácia ale ešte nemusí znamenať, že model je lepší. Pri poklese deviácie a náraste počtu regresných parametrov musíme stále myslieť na potenciálnu hrozbu preučenia modelu. Oveľa zaujímavejšie ako skúmanie samotnej deviácie je skúmanie úbytku deviácie v závislosti na pridaní ďalšieho regresného parametru. V sekcii 3.4.3 sme si uviedli aj vzťah (3.12), ktorý nám dáva návod ako môžeme posúdiť vhodnosť modelu. Ukázali sme si, že zmena v deviácii medzi uvažovaným modelom a jeho submodelom má približne χ^2 rozdelenie s Δdf stupňami voľnosti, t. j. $\Delta D \approx \chi^2(\Delta df)$. Z toho plynie, že pre $\Delta D > \chi^2_{1-\alpha}(\Delta df)$ zamietame hypotézu o vhodnosti modelu na hladine významnosti α . V našej analýze budeme uvažovať hladinu významnosti $\alpha = 0,05$.

Tabuľka 5.4: Porovnanie modelov na základe analýzy deviácie

Popis modelu	ΔD	Δdf	$\chi^2_{0,95}(\Delta df)$
offset			
offset+County	117	3	7,81
offset+County+Age	102	5	11,07
offset+County+Age+Weight	18	3	7,81
offset+County+Age+Weight+CarAge	15	3	7,81
offset+County+Age+Weight+CarAge+Make	10	5	11,07
offset+County+Age+Weight+CarAge+Make+EngPerfKW	4	3	7,81

V Tabuľke 5.4 máme uvedené hodnoty zmeny deviácie, zmeny stupňov voľnosti a hodnoty testovacej štatistiky. Vidíme, že po pridaní regresoru Make už zamietame hypotézu o vhod-

nosti modelu. V tomto prípade sme do Tabuľky 5.4 opäť kvôli prehľadnosti zahrnuli len vybrané modely. Záverom analýzy deviácie je, že po pridaní regresných parametrov Make a EngPerfKW nedochádza k signifikantnému zlepšeniu modelu.

5.2.3 Výber vhodného modelu

V tejto časti práce sa pozrieme na najlepší model z nášho pohľadu. V Tabuľkách 5.3 a 5.4 máme zaznamenané porovnávacie kritéria vybraných modelov, ktoré v jednotlivých krokoch procesu doprednej selekcie regresných parametrov dopadli najlepšie v porovnaní s podobnými modelmi. Po porovnaní informácií z týchto tabuliek a príslušných grafov sme sa rozhodli vybrať model so 4 regresnými parametrami, a to konkrétne County, Age, Weight a CarAge. Na základe údajov o BIC z Tabuľky 5.3, Obrázku 5.1 a údajov o vývoji strednej štvorcovej chyby z Obrázku 5.2 sa môže zdať, že najlepší výkon dosahuje už model bez regresného parametru CarAge. Každopádne, AIC a výsledky analýzy deviácie indikujú, že pridanie tohto regresoru do modelu môže zlepšiť jeho výkon. Daný regresný parameter sme sa rozhodli zahrnúť aj z toho dôvodu, že údaje o veku vozidla by mali byť nejakým spôsobom zahrnuté v procese tvorby poistného. Poďme si ďalej viac priblížiť tento model.

Tabuľka 5.5: Odhad regresných parametrov vybraného Poissonovho modelu

Regresný parameter	Koeficient
(Intercept)	-2,601
County.B	0,396
County.C	0,692
County.D	0,950
Age.25-34	-0,595
Age.35-44	-0,719
Age.45-54	-0,743
Age.55-64	-0,782
Age.65+	-0,581
Weight.1201-1600	0,204
Weight.1601-2000	0,335
Weight.2001+	0,341
CarAge.4-10	0,087
CarAge.11-15	0,212
CarAge.16+	0,234

V Tabuľke 5.5 máme zaznamenané odhadnuté koeficienty nami vybraného modelu. Ako už bolo spomenuté, k odhadu týchto parametrov bol použitý softvér R a ukážka použitého kódu je dostupná v Prílohe B. K tvorbe modelu boli použité premenné County, Age, Weight a CarAge, ktorých kategorizáciu môžeme nájsť v Tabuľke 5.1. Do modelu bola takisto zahrnutá informácia o dĺžke trvania poistky obsiahnutá v premennej Exposure. Koeficienty zaznamenané v Tabuľke 5.5 sú uvedené vzhľadom k príslušným referenčným kategóriam,

t. j. County . A, Age . 18–24, Weight . 1200– a CarAge . 0–3. Použitím daného modelu vieme klientov rozdeliť do 384 rizikových skupín. Pomocou odvodeného vzťahu (5.5) vieme vypočítať očakávanú ročnú frekvenciu nehodovosti pre ľubovoľnú skupinu. Vďaka dobrej interpretovateľnosti zovšeobecneného lineárneho modelu takisto vieme, akým spôsobom prispievajú jednotlivé parametre do výpočtu tejto frekvencie, a tiež vieme transparentne porovnávať jednotlivé skupiny. Pre názornosť si môžeme interpretovať napríklad skupinu, pri ktorej sa očakáva najnižšia ročná frekvencia poistných nárokov. Ak spojíme informácie z Tabuliek 5.1, 5.5 a vzťah (5.5), tak môžeme povedať, že skupina s najnižšou ročnou frekvenciou nehodovosti je skupina zložená z klientov, ktorí prevádzkujú svoje vozidlo v oblasti A, patria do vekovej kategórie 55–64 rokov, ich vozidlo patrí do váhovej kategórie pod 1 200 kilogramov a vek tohto vozidla spadá do kategórie 0–3 roky. Zloženie tejto skupiny nie je príliš prekvapivé vzhľadom na uvedené parametre. Vzhľadom na vek by sa malo jednať o skúsených vodičov, ktorí prevádzkujú svoje vozidlo v najmenej rizikovej oblasti. Ich vozidlo spadá do kategórie ľahkých vozidiel, a takisto ide o pomerne nové vozidlo, ktoré by pravdepodobne malo byť ešte v záručnej dobe. Očakávanú ročnú frekvenciu poistných nárokov tejto rizikovej skupiny môžeme dostať nasledujúcim výpočtom

$$\exp\{-2,601 - 0,782\} = 0,034.$$

Môžeme teda očakávať, že klienti patriaci do tejto rizikovej skupiny nahlásia v priemere 0,034 nehody za rok, respektíve že si uplatnia poistný nárok v priemere raz za 29,41 roku. Naopak, ak sa pozrieme na rizikovú skupinu, pri ktorej sa odhaduje najvyššia ročná frekvencia nehodovosti, tak vidíme charakteristiky ako oblasť prevádzkovania vozidla D (t. j. najrizikovejšia oblasť), vek vodiča v rozmedzí 18–24, váhu vozidla vyše 2 001 kilogramov a vek vozidla v kategórii 16 a viac rokov. Očakávanú ročnú frekvenciu nehodovosti v tejto skupine vodičov vypočítame nasledujúcim spôsobom

$$\exp\{-2,601 + 0,950 + 0,341 + 0,234\} = 0,341.$$

Poistiteľ môže teda očakávať, že klienti z najrizikovejšej skupiny budú hlásiť poistnú udalosť v priemere jedenkrát za 2,93 roku. Je potrebné pripomenúť, že takáto priamočiara interpretácia je možná práve preto, že sme použili Poissonov regresný model. Podobným spôsobom by sme dokázali vypočítať očakávanú frekvenciu nehodovosti pre ľubovoľnú rizikovú skupinu.

Pri použití Poissonovho regresného modelu nemôžeme ale zabudnúť na prípadnú overdispériu. Ako sme si povedali už na strane 60, prítomnosť overdispézie porušuje podmienky použitia Poissonovho modelu, a teda je dobrým indikátorom, že by sme mali zvážiť iné možnosti. Dobrým indikátorom toho, či by sme mali zvážiť iný typ modelu sú práve deviácie a stupne voľnosti modelu, respektíve ich podiel. Túto skutočnosť takisto uvádzame v sekcii 3.4.3. Pri praktických výpočtoch by mala byť táto hodnota blízka 1, pričom hodnoty blízke 1 indikujú vhodné použitie uvažovaného modelu. Naopak, hodnoty značne prevyšujúce 1 znamenajú, že sme použili nevhodný model vzhľadom k dostupným dátam a mali by sme zvážiť použitie iného modelu, ktorý dokáže lepšie zvládnuť overdispériu, ako napríklad už viackrát spomenutý negatívne binomický model. Autor Hilbe [34, kapitola 3] spomína tento prístup vo svojej publikácii, kde podiel deviácie a stupňov voľnosti využíva

ako testovaciu štatistiku pre deviance GOF³⁸ test, ktorý vychádza z predpokladu, že deviacia sa riadi χ^2 so zodpovedajúcim počtom stupňov voľnosti. Pre úplnosť treba spomenúť, že autor takisto spomína Pearsonov GOF test, ktorý funguje na podobnom princípe, ale jeho výsledky sú považované za viac vychýlené. V našom prípade ale nie je použitie ani jedného z týchto prístupov vhodné. Dôvodom je, že v našom datasete sa nachádza nadmerné množstvo nulových pozorovaní (t. j. poistných zmlúv, pri ktorých nebol zaznamenaný žiaden poistný nárok), čo môže značne ovplyvniť výsledky týchto testov. Pre určenie vhodnosti použitia Poissonovho modelu použijeme test pomerom vierohodnosti (ozn. LR³⁹ test), pomocou ktorého porovnáme Poissonov a negatívne binomický model. Budeme k nemu využívať parametrizáciu predstavenú v Poznámke 2.4, podľa ktorej je zjavné že Poissonovo rozdelenie je špeciálnym prípadom negatívneho binomického rozdelenia pre overdispersný parameter $\kappa = 0$. Nulová hypotéza je v teda v tvare $H_0 : \kappa = 0$ a testujeme ju oproti alternatívnej $H_1 : \kappa > 0$. Testovacia štatistika je v tvare

$$LR = 2(\ell_{NB} - \ell_P),$$

kde ℓ_{NB} a ℓ_P zodpovedajú hodnotám logaritmickej vierohodnosti negatívneho binomického, respektíve Poissonovho modelu. Nulovú hypotézu o vhodnosti Poissonovho modelu zamietame na hladine významnosti α , ak $LR > \chi^2_{1-2\alpha}(1)$. Zamietací región zodpovedá hornému 2α kvantilu $\chi^2(1)$ rozdelenia, a to z toho dôvodu, že overdispersný parameter κ nemôže byť nikdy menší ako 0. Viac o LR teste a o overdispersii všeobecne sa môžeme dozvedieť od autorov Camerona a Trivediho [35, podkapitola 3.4] v ich publikácii, kde rozoberajú aj príčiny prípadnej overdispersie a spôsoby, ako sa s ňou pri modelovaní vysporiadať.

V sekcii 5.2.1 sme si uvideli počítacie náhodné procesy, aby sme si teoreticky podporili zahrnutie dĺžky poistenej doby do procesu tvorby zovšeobecneného lineárneho modelu. Konkrétne v definícii 5.2 sme zadefinovali Poissonov proces a predtým, ako sa pustíme do tvorby negatívneho binomického modelu je potrebné povedať, že negatívne binomický proces je v podstate zmiešaný Poissonov proces. V podkapitole 2.3 sme si ukázali, ako môžeme dostať negatívne binomické rozdelenie zmiešaním Poissonovho rozdelenia a gamma rozdelenia. Podobná analógia platí aj pri negatívnom binomickom procese, ktorý môžeme vytvoriť zmiešaním Poissonovho procesu a gamma rozdelenia. Autor Thomas Mikosch [11, podkapitola 2.3] odvodil tento prechod vo svojej publikácii. Pri tvorbe negatívneho binomického modelu budeme postupovať podobne, ako sme si ukázali v sekcii 5.2.2 pri Poissonovom regresnom modeli. Použijeme teda 10-násobnú krížovú validáciu, aby sme minimalizovali potenciálne preučené modelu a použijeme doprednú selekciu regresných parametrov s porovnávacími kritériami rovnakými ako v sekcii 5.2.2. Použité funkcie budú opäť dostupné v Prílohe B. Odvodenie odhad parametru λ metódou maximálnej vierohodnosti pre negatívne binomický proces môžeme nájsť napríklad u Denuita a kol.[5, podkapitola 1.5]. Tento odhad je rovnaký, ako tomu bolo v prípade Poissonovho procesu (5.8).

³⁸Z anglického výrazu *goodness-of-fit*.

³⁹Z anglického výrazu *likelihood ratio*.

Doprednou selekciou regresných parametrov boli opäť vybrané rovnaké parametre ako v prípade Poissonovho modelu, a teda negatívne binomický model môžeme popísať nasledujúcim spôsobom:

$$NClaims \sim \text{offset}(\log(\text{Exposure})) + \text{County} + \text{Age} + \text{Weight} + \text{CarAge}.$$

Podobne, ako tomu bolo pri vybranom Poissonovom modeli s rovnakým popisom, použitím tohto negatívneho binomického modelu vieme klientov rozdeliť do 384 rizikových skupín.

Tabuľka 5.6: Odhad regresných parametrov vybraného negatívneho binomického modelu

Regresný parameter	Koeficient
(Intercept)	−2,595
County.B	0,409
County.C	0,705
County.D	1,017
Age.25–34	−0,628
Age.35–44	−0,750
Age.45–54	−0,777
Age.55–64	−0,821
Age.65+	−0,611
Weight.1201–1600	0,213
Weight.1601–2000	0,335
Weight.2001+	0,326
CarAge.4–10	0,104
CarAge.11–15	0,246
CarAge.16+	0,268

V Tabuľke 5.6 máme zaznamenané odhady regresných koeficientov pre vybraný negatívne binomický model. Frekvenciu nehodovosti pre ľubovoľnú rizikovú skupinu vieme opäť vypočítať pomocou vzťahu (5.5), keďže sme si v Poznámke 2.4 ukázali, že po parametrizácii používanej pri negatívne binomických modeloch má stredná hodnota rovnaký tvar ako pri Poissonovom rozdelení a líši sa len tvar rozptylu. Skupina s najnižšou očakávanou ročnou frekvenciou nehodovosti je potom skupina zložená z klientov, ktorí prevádzkujú svoje vozidlo v oblasti A, patria do vekovej kategórie 55–64 rokov, ich vozidlo patrí do váhovej kategórie pod 1 200 kilogramov a vek tohto vozidla spadá do kategórie 0–3 roky. Očakávaná ročná frekvencia poistných nárokov tejto rizikovej skupiny by bola potom nasledujúca

$$\exp\{-2,595 - 0,821\} = 0,033.$$

Môžeme očakávať, že klienti patriaci do tejto rizikovej skupiny nahlásia poistnú udalosť v priemere raz za 30,3 roku. Naopak, riziková skupina s najvyššou očakávanou ročnou frekvenciou nehodovosti je zložená z klientov, ktorí prevádzkujú svoje vozidlo v oblasti D, vek vodiča je v rozmedzí 18–24, váha vozidla je 1 600–2 000 kilogramov a vek vozidla v kategórii 16 a viac rokov. Očakávanú ročnú frekvenciu nehodovosti v tejto skupine vodičov vypočítame nasledujúcim spôsobom

$$\exp\{-2,595 + 1,017 + 0,335 + 0,268\} = 0,377.$$

Poistiteľ môže potom očakávať, že klienti z najrizikovejšej skupiny budú hlásiť poistnú udalosť v priemere jedenkrát za 2,65 roku.

Tabuľka 5.7: Výsledné hodnoty vybraných modelov

Model	Deviácia	Log. vierohodnosť	AIC	BIC	MSE
Poissonov	9 612	−6 952	13 934	14 049	0,1812
Negatívne binomický	7 776	−6 879	13 790	13 913	0,1815

Overdisperný parameter κ bol odhadnutý na hodnotu 0,103. Poďme si teraz porovnať jednotlivé kritéria oboch vybraných modelov. V Tabuľke 5.7 vidíme, že až na MSE dopadol lepšie negatívne binomický model podľa všetkých uvažovaných kritérií. Aplikujme teraz ešte LR test. Podľa vzťahu (5.2.3) má testovacia štatistika hodnotu $LR = 73 > 2,7 = \chi^2_{0,9}(1)$, a teda na hladine významnosti 5 % zamietame hypotézu $H_0 : \kappa = 0$ a môžeme skonštatovať, že Poissonov model nie je vhodný na náš skúmaný problém. Vzhľadom na všetky uvedené skutočnosti je v našom prípade lepšie použiť negatívne binomický model.

5.2.4 Zhodnotenie GLM

V celej podkapitole 5.2 sme sa venovali aplikovaniu predtým predstavenej teórie na reálne dáta z poistnej praxe. Mohli sme vidieť, že pri spracovávaní reálnych dát je okrem teórie dôležitá znalosť domény, znalosť skúmaných dát a vzťahov medzi jednotlivými premennými. Ukázali sme si, ako sa vysporiadať s rozdielnou dĺžkou poistnej doby, k čomu sme si vybudovali aj teoretickú nadstavbu. Ukázali sme si, že pri reálnych dátach z poistnej praxe o počte poistných nárokov sa s veľkou pravdepodobnosťou stretneme s nadmerným počtom nulových pozorovaní, čo značne ovplyvní ďalšiu analýzu a túto skutočnosť treba mať stále na pamäti. Uviedli sme si jeden z postupov, ako je možné vybudovať zovšeobecnený lineárny model, ukázali sme si, ako vybrať ten najvhodnejší, a takisto sme si ukázali spôsob, akým je možné tento model jednoducho interpretovať. Ďalej sme si predstavili alternatívu k Poissonovmu modelu v podobe negatívneho binomického modelu, pomocou ktorého sa vieme vysporiadať aj s prítomnou overdispériou, ktorá je špecifickým javom pri dátach s nadmerným počtom nulových pozorovaní. Ukázali sme si doporučený spôsob, ako v tomto prípade modely porovnávať a vybrali sme z nášho pohľadu ten najvhodnejší model vzhľadom na naše dáta a na skúmaný problém.

Opäť si pripomeňme, že cieľom práce je apriórna segmentácia klientov v neživotnom poistení. V tejto práci sme sa zamerali na segmentáciu podľa počtu poistných nárokov, k čomu sme využili zovšeobecnený lineárny model, do ktorého vstupujú apriórne údaje o klientovi, ktoré má poistiteľ k dispozícii na začiatku poistenia. Pomocou nami vybraného modelu dokážeme klientov rozdeliť do 384 rizikových skupín a pre každú skupinu sme schopní jednoducho dopočítať očakávanú ročnú frekvenciu nehodovosti. Tento počet skupín sa môže zdať ako príliš vysoký a pre poistiteľa by to nemuselo byť vhodné. Existuje viacero spôsobov, pomocou ktorých by sa dal počet týchto skupín znížiť tak, aby to viac vyhovovalo poistiteľovi a zjednodušilo proces tvorby tarifnej štruktúry. Za zmienku stojí možnosť zlúčenia jednotlivých rizikových skupín už na základe vytvoreného modelu.

Pri pohľade na Tabuľku 5.6 s koeficientami nami vybraného modelu môžeme vidieť, ako sa líšia jednotlivé kategórie od referenčnej kategórie, a taktiež môžeme vidieť ako sa líšia jednotlivé kategórie medzi sebou. V prípade požiadavku na zníženie počtu rizikových skupín by sme teda mohli zlúčiť kategórie, ktoré sa od seba odlišujú čo najmenej. Ďalším možným spôsobom je napríklad zmena kategorizácie hneď na začiatku procesu tvorby modelu. Každopádne, účelom tejto práce je len predstaviť spôsob, akým je možné k segmentácii klientov pristúpiť. Treba však brať ohľad aj na početné zastúpenie jednotlivých rizikových skupín v rámci celého poistného kmeňa. V Prílohe A je dostupná Tabuľka 5.13, kde sú zaznamenané odhady frekvencie nehodovosti pre najviac a najmenej zastúpené rizikové skupiny v rámci trénovacích dát. Váhy skupín (stĺpec w) boli počítané ako podiel celkového súčtu trvania poistných zmlúv v danej rizikovej skupine a celkového súčtu doby trvania všetkých poistných zmlúv v trénovacom datasete. To, akým spôsobom bude táto segmentácia vykonaná závisí od požiadavkov samotného poistiteľa. Apriórna segmentácia klientov do čo najviac homogénnych skupín je len jednou časťou procesu tvorby tarifnej štruktúry poisťovne. Pri tomto procese musí byť vzatá do úvahy aj očakávaná výška poistných nárokov, tvorba rezerv poisťovne, náklady poisťovne, prípadné regulácie a podobne.

Existuje viacero spôsobov, ako je možné pristupovať k tvorbe zovšeobecneného lineárneho modelu s cieľom zlepšenia jeho kvality. V práci sme viackrát spomenuli kvázi-Poissonov model. Tento typ modelu je jednou z možností ako pristupovať k datasetom s veľkým počtom nulových pozorovaní. Ako viackrát spomína autor Hilbe [34], model s nadmerným počtom nulových pozorovaní bude takmer vždy vykazovať známky overdispérie. Kvázi-Poissonov model je zjednodušene povedané Poissonov model do ktorého je zakomponovaný overdisperný parameter, a teda ide v podstate o akýsi medzistupeň medzi Poissonovým modelom a negatívne binomickým modelom. Narozdiel od spomínaných modelov nefunguje ale kvázi-Poissonov model na princípe maximálnej vierohodnosti. Aby sme teoreticky podporili použitie kvázi-Poissonovho modelu, museli by sme rozšíriť teoretické informácie o vierohodnosti, ktoré sme si v práci predstavili. Kvázi-vierohodnosť a celkovo modely fungujúce na princípe kvázi-vierohodnosti presahujú ciele tejto práce, ale tieto modely môžu byť v praxi použité a dokonca môžu byť v určitých prípadoch vhodnejšou voľbou ako nami predstavené modely počtu poistných nárokov. Kvázi-vierohodnosť podrobne opisujú autori McCullagh a Nelder [36, kapitola 9] alebo o niečo stručnejšie autori Hardin a Hilbe [37, kapitola 17]. Porovnanie Poissonovho, kvázi-Poissonovho a negatívneho binomického modelu na praktickom príklade môžeme nájsť napríklad u autorov Friendlyho a Meyera [38, podkapitola 11.3], ktorí rozdiely medzi spomínanými modelmi demonštrujú dokonca graficky.

Ďalšími typmi modelov, ktorý sme v rámci práce spomínali, sú modely modifikované v 0. V podkapitole 2.4 sme si predstavili modifikované pravdepodobnostné rozdelenia, ktoré môžeme použiť pri modelovaní počtu poistných nárokov. Konkrétne v sekcii 2.4.3 sme si predstavili pravdepodobnostné rozdelenia modifikované v 0. Asi najznámejšími modifikovanými rozdeleniami sú ZIP⁴⁰ a ZINB⁴¹. Modely zodpovedajúce týmto pravdepodobnostným rozdeleniam môžu byť použité v prípade dát s nadmerným počtom nulových

⁴⁰Z anglického výrazu *Zero-Inflated Poisson*.

⁴¹Z anglického výrazu *Zero-Inflated Negative Binomial*.

pozorovaní. Interpretácia týchto modelov je o niečo zložitejšia, ako pri ich tradičných ekvivalentoch, ale stále patrí medzi pomerne jednoduché. Pri týchto modeloch si treba uvedomiť, že pravdepodobnostné funkcie zodpovedajúce týmto rozdeleniam síce nepatria do triedy exponenciálnych rozdelení, ale stále môžu byť použité pri zovšeobecnených lineárnych modeloch. V oboch prípadoch totižto ide o konečnú zmes dvoch pravdepodobnostných rozdelení, ktoré obe patria do triedy exponenciálnych rozdelení. Inak povedané, pravdepodobnostná funkcia sa skladá z dvoch komponent, pričom jedna komponenta je použitá na modelovanie nadmerného počtu núl pomocou Bernoulliho (t. j. alternatívneho) rozdelenia a druhá komponenta je použitá na modelovanie počtu pozorovaní väčších ako nula. Viac informácií o týchto modeloch poskytujú autori Cameron a Triverdi [35, podkapitola 4.6]. Praktickú aplikáciu a porovnanie týchto modelov popisuje vo svojej publikácii aj autor Hilbe [34, podkapitola 7.3]. Ako sme si uvideli vyššie, model s nadmerným počtom nulových pozorovaní bude takmer vždy vykazovať známky overdisperzie. Modely modifikované v 0 môžu byť práve z tohoto dôvodu vhodnou voľbou v poisťnej praxi. Ako ukazujú Denuit a kol. [5, sekcia 2.4.4], práve zmiešané modely môžu byť použité na zachytenie overdisperzie. Viacero príkladov a ukážok, ako sa vysporiadať s dátami obsahujúcimi nadmerné množstvo nulových pozorovaní ponúkajú vo svojej publikácii tiež autori Friendly a Meyer [38, podkapitola 11.4], kde sa môžeme stretnúť s ďalším typom modelov, a síce s takzvanými prekážkovými modelmi (angl. *hurdle models*). Autori taktiež popisujú rozdiel medzi spomínanými dvoma typmi modelov.

Posledným odporúčaním ako vylepšiť zovšeobecnený lineárny model budú regularizačné metódy, ktoré dobre popisuje skupina autorov James a kol. [14, podkapitola 6.2]. Tieto techniky môžu byť použité na dosiahnutie vyššej kvality a presnosti modelu. V podkapitole 3.4 sme si povedali, že pri výbere vhodného modlu si treba dať pozor na takzvaný bias-variance trade-off. Regularizačné techniky, menovite hrebeňová regresia a lasso regresia sú techniky, ktoré sa často používajú na vysporiadanie sa s prípadnou multikolinearitou a preučovaním modelu. V jednoduchosti povedané, pri oboch metódach je zavedený penalizačný parameter v cieľovej funkcii, čím sa úmyselne o niečo zvýši bias s cieľom značného zlepšenia variancie. Rozdiel medzi spomínanými dvoma metódami je v spôsobe penalizácie. Pri hrebeňovej regresii sa využíva L2 norma a pri lasso regresii je použitá L1 norma. Práve použitie L1 normy pri lasso regresii spôsobuje, že niektoré koeficienty budú nulové, takže lasso regresia môže byť použitá aj na určenie vhodných regresných parametrov modelu.

5.3 Tvorba GBM

V tejto podkapitole si v krátkosti predstavíme alternatívny postup ku zovšeobecneným lineárnym modelom, a to konkrétne gradient boosting modely. Už v Kapitole 4 sme si stručne uviedli modely strojového učenia, ktoré je možné použiť v poisťovníctve. V podkapitole refGLMvsGBM sme si porovnali výhody a nevýhody použitia zovšeobecnených lineárnych modelov a modelov strojového učenia a v podkapitole 4.5 sme si predstavili spomínaný gradient boosting model. Keďže zovšeobecnené lineárne modely stále zostávajú používaným štandardom v poisťnej praxi, tak aj táto diplomová práca je hlavne zameraná na tento typ modelov. V tejto časti sa ale predsa len pozrieme, ako by sa dalo pristupovať

k apriórnej segmentácii klientov na základe odhadovaného počtu poistných nárokov, ak by sme namiesto GLM použili GBM. Najskôr si vybudujeme čo najlepší GBM. Potom sa budeme snažiť tento model interpretovať pomocou vysvetľovacích techník predstavených v podkapitole 4.6. Nakoniec si porovnáme vytvorený model s negatívne binomickým modelom skonštruovaným v sekcii 5.2.3 a pozrieme sa, ako si tieto dva rozdielne modely poradia s testovacím datasetom. Pri procese tvorby modelu použijeme rovnakú tréningovú vzorku dát pozostávajúcu zo 17 438 pozorovaní, ktorú sme použili pre zostavenie oboch modelov v predchádzajúcej časti. Opäť použijeme krížovú validáciu, aby sme sa vyhli preučeniu modelu. Použité funkcie sú dostupné v Prílohe B.

Pri procese tvorby GBM je potrebné postupovať trochu inak, ako sme si ukázali v podkapitole 5.2. Pri GBM je potrebná vhodná optimalizácia vybraných hyper-parametrov modelu, ktorými sú napríklad počet stromov (ozn. `n.trees`), počet koncových uzlov určujúci úroveň interakcie medzi vstupnými parametrami (ozn. `interaction.depth`), rýchlosť učenia algoritmu (ozn. `shrinkage`), minimálny počet pozorovaní v koncovom uzle (ozn. `n.minobsinnode`), podiel tréningových dát použitých pri každej iterácii (ozn. `bag.fraction`) a podobne. V našej analýze budeme optimalizovať práve týchto päť spomenutých hyper-parametrov. V podkapitole 4.5 sme si uviedli pár odporúčaných hodnôt vybraných hyper-parametrov, ktoré v procese tvorby GBM budeme brať do úvahy. Detailnejší popis, ako postupovať pri tvorbe regresných stromov, poskytujú vo svojej publikácii napríklad autori Johnson a Kuhn [24, kapitola 8].

Regresné stromy patria medzi robustnejšie techniky modelovania v porovnaní so zovšeobecnenými lineárnymi modelmi. Regresné stromy si dokážu poradiť s chýbajúcimi pozorovaniami, so spojitými premennými, s kategorickými premennými, nie sú kladené požiadavky na pravdepodobnostné rozdelenie odozvy a podobne. Na druhej strane sa regresné stromy vyznačujú vyššou výpočtovou náročnosťou. Pri procese tvorby GBM budeme postupovať tak, že si zostavíme sieť hyper-parametrov, kde budú zahrnuté vybrané hodnoty pre zvolené hyper-parametre. Následne spustíme gradient boosting model pre každú kombináciu hyper-parametrov a pre každú kombináciu vypočítame strednú kvadratickú chybu. Na záver vyberieme model produkujúci najnižšiu chybovosť. V každom kroku bude taktiež použitá krížová validácia pre odhad optimálneho počtu stromov. Uvažovaná sieť hyper-parametrov a kód použitý pri tvorbe GBM sú dostupné v prehľade použitých funkcií v Prílohe B.

Tabuľka 5.8: Výsledné hodnoty hyper-parametrov GBM

n.trees	interaction.depth	shrinkage	n.minobsinnode	bag.fraction
73	4	0,05	10	0,5

Po vykonaní vyššie uvedeného procesu sme ako najlepší vybrali model s hyper-parametrami zaznamenanými v Tabuľke 5.8. Využili sme 10-násobnú krížovú validáciu a vzali sme do úvahy všetky dostupné atribúty z Tabuľky 5.1 okrem atribútu pohlavia (t. j. Gender). Pri tvorbe GBM bola opäť zohľadnená dĺžka trvania poistnej zmluvy, pričom bola táto informácia zahrnutá do modelu rovnakým spôsobom, ako sme si ukázali pri GLM. Zároveň sme špecifikovali, že odozva sa riadi Poissonovým rozdelením, aby bolo jasné, že

modelujeme počet poistných udalostí. Zostrojený model vykazoval priemernú chybovosť na tréningových dátach s hodnotou strednej kvadratickej chyby na úrovni 0,1793. Táto hodnota je nižšia ako všetky spočítané hodnoty strednej kvadratickej chyby pri GLM, čo ale ešte nemusí znamenať, že model je lepší. Chybovosť bola v oboch prípadoch meraná len na tréningovej vzorke dát. Neskôr výkon oboch typov modelov porovnáme aj na testovacích dátach.

V Kapitole 4 sme si viackrát zdôraznili, že metódy strojového učenia nie sú v poisťovníctve príliš využívané kvôli náročnej interpretovateľnosti. V podkapitole 4.6 sme si uviedli niektoré vysvetľovacie techniky, ktoré by nám mali pomôcť pri interpretovaní komplexnejších modelov strojového učenia. Poďme si teraz aplikovať tieto metódy na zostrojený GBM model. Je vhodné ešte poznamenať, že náš model nepatrí medzi príliš komplexné, keďže uvažujeme len šesť kategorických premenných. Uvedené vysvetľovacie techniky môžu byť aplikované aj na oveľa komplexnejšie modely, pričom by sa samozrejme zvýšila výpočtová náročnosť. Budeme využívať balíček DALEX od skupiny autorov Biecek, Maksymiuk a Baniecki [39].

Na začiatok sa pozrieme na Shapleyho hodnoty, ktoré sme si v krátkosti predstavili v sekcii 4.6.1. Pre lepšiu názornosť si najskôr zadefinujeme klienta, ktorého budeme uvažovať ako pozorovanie vstupujúce do modelu. Pozorovanie sme vybrali z tréningového datasetu, aby zodpovedalo reálnym dátam. V Tabuľke 5.9 môžeme vidieť hodnoty jednotlivých atribútov

Tabuľka 5.9: Vybraný klient z datasetu


County	Age	EngPerfKW	Weight	Make	CarAge
A	18-24	60-	1200-	Opel	16+

vybraného klienta. Ide o mladú osobu z najmenej rizikovej oblasti so starým vozidlom značky Opel s nízkym výkonom a zodpovedajúcou nízkou hmotnosťou. Zvolený príklad celkom vierohodne reflektuje situáciou, ktorá sa pri poistení motorových vozidiel môže vyskytnúť. Parametre modelu sme si definovali v Tabuľke 5.8, takže sa môžeme pozrieť, ako dopadne predikcia frekvencie ročnej nehodovosti pre tohto klienta.


Predikovaná ročná frekvencia nehodovosti pre daného klienta bola vypočítaná na hodnotu 0,093, čo znamená, že pri klientoch s rovnakými hodnotami atribútov môžeme očakávať ohlásenú nehodu v priemere raz za 10,8 roku.⁴² Poďme sa ale pozrieť, aký efekt majú hodnoty jednotlivých atribútov na túto predikciu.

Na Obrázku 5.4 môžeme vidieť vypočítané Shapleyho hodnoty pre klienta s atribútmi z Tabuľky 5.9. Shapleyho hodnoty sme vypočítali použitím funkcií z balíčka DALEX [39] a pomocou popisu fungovania jednotlivých funkcií dostupného v publikácii od Bieceka a Burzykowskiho [29]. Použité funkcie sú zobrazené v Prílohe B. Môžeme vidieť, aký efekt majú jednotlivé atribúty na výslednú predikciu modelu pre daného klienta. Je potrebné poznamenať, že sme pri tvorbe modelu zadali údaj o Poissonovom rozdelení odozvy, a teda,

⁴²Pre zaujímavosť, využitím regresných koeficientov z Tabuľky 5.6 by sme dostali hodnotu 0,098.



Obr. 5.4: Shapleyho hodnoty pre vybraného klienta



Obr. 5.5: Agregované Shapleyho hodnoty pre vybraného klienta

podobne ako tomu bolo pri koeficientoch GLM, všetky zobrazené hodnoty sú exponentami. Vidíme, že v tomto prípade má najväčší efekt na výslednú predikciu vek klienta a tento efekt je negatívny vzhľadom na očakávanú ročnú frekvenciu nehodovosti. Naopak, bydlisko klienta má pozitívny efekt na výslednú predikciu a znižuje očakávanú ročnú frekvenciu nehodovosti pri danom klientovi. Podobným spôsobom by sme mohli interpretovať vplyv všetkých atribútov. Ďalej je potrebné zdôrazniť, že sa jedná o priemerný vplyv jednotlivých


atribútov na výslednú predikciu modelu. Box-ploty zobrazené na Obrázku 5.4 sumarizujú vplyv jednotlivých atribútov pri rôznych poradiach.

Konkrétne hodnoty vypočítaných Shapleyho vysvetlení môžeme vidieť na Obrázku 5.5, kde sú zaznamenané agregované priemerné efekty. Na tomto obrázku vidíme, ako vplývajú jednotlivé hodnoty na predikciu modelu a máme tu zaznamenaný postupný prechod od interceptu až po výslednú predikciu pre uvažovaného klienta. V tomto prípade môžeme aplikovať analogický prístup, ako sme použili pri GLM a očakávanú ročnú frekvenciu nášho klienta dostaneme nasledujúcim spôsobom

$$\exp\{-2,472 + 0,542 - 0,359 - 0,097 + 0,038 - 0,029 - 0,002\} = 0,093.$$

Podobným spôsobom by mohol poisťiteľ interpretovať vytvorený model pre ľubovoľného klienta alebo dokonca pre ľubovoľnú skupinu klientov. Nami uvažovaný klient v podstate reprezentuje rizikovú skupinu klientov so zhodnými hodnotami atribútov. Bolo by teda možné spočítať Shapleyho hodnoty pre všetky rizikové skupiny a následne pomocou nich interpretovať priemerný vplyv jednotlivých atribútov na predikovanú očakávanú ročnú frekvenciu nehodovosti zodpovedajúcu danej rizikovej skupine.

Pozrime sa ďalej v krátkosti na zvyšné vysvetľovacie techniky, ktoré sme si predstavili v podkapitole 4.6. Začnime metódou LIME, ktorú sme si opísali v sekcii 4.6.2. Tentokrát použijeme balík DALEXtra [40], a tiež balík iml [41], v ktorom môžeme nájsť popis fungovania využitého algoritmu.



Obr. 5.6: Graf LIME pre vybraného klienta

Na Obrázku 5.6 máme graficky znázornené efekty jednotlivých atribútov. Komplexitu meta modelu sme obmedzili voľbou maximálne štyroch parametrov. Na tomto obrázku máme

Tabuľka 5.10: Vypočítané hodnoty LIME koeficientov pre vybraného klienta

(Intercept)	County=A	Age=18-24	Weight=1200-	CarAge=16+
-2,46	-0.371	0.628	-0.126	0.059


znázornený aj rozdiel v predikciách nášho GBM modelu a meta modelu. Opäť môžeme vidieť silný negatívny efekt nízkeho veku klienta a silný pozitívny efekt bydliska klienta. V Tabuľke 5.10 môžeme ďalej vidieť vypočítané koeficienty s príslušnými atribútmi. Zložitý GBM model môžeme potom pre daného klienta interpretovať pomocou jednoduchšieho GLM meta modelu rovnakým spôsobom, ako sme si ukázali pri tvorbe GLM v podkapitole 5.2. Porovnanie očakávaných ročných frekvencií nehodovosti pre daného klienta vypočítaných pomocou GBM a meta modelu GLM je potom nasledovné

$$\lambda_{\text{LIME}} = \exp\{-2,27\} = 0,103,$$

$$\lambda_{\text{GBM}} = \exp\{-2,38\} = 0,093.$$

Tento rozdiel je pomerne veľký v kontexte nášho problému. Každopádne, meta model neslúži na predikovanie, ale na vysvetlenie zložitejšieho modelu. Ak by sme opäť vzali nášho klienta ako reprezentanta rizikovej skupiny s rovnakými atribútmi, tak by sme dokázali pomocou LIME vysvetlení interpretovať správanie nášho GBM modelu pre danú rizikovú skupinu pomocou jednoduchšieho meta modelu GLM.

Nakoniec sa ešte pozrime na grafy PDP, ALE a ICE, ktoré sme si predstavili v sekcii 4.6.3. Tieto tri metódy si demonštrujeme na premennej Age. Na obrázku 5.7 môžeme vidieť



Obr. 5.7: Grafy PDP, ALE a ICE pre vybraného klienta

histogram relatívnej početnosti atribútu Age spolu s frekvenciami nehodovosti vypočítanými použitím všetkých troch vyššie spomínaných metód. Grafy PDP a ALE znázornené

červenou, respektíve modrou farbou vyjadrujú priemernú frekvenciu nehodovosti naprieč všetkými pozorovaniami z tréningového datasetu. Môžeme pozorovať, ako sa v priemere zmení očakávaná frekvencia nehodovosti, ak sa zmení veková kategória klienta za predpokladu, že všetky ostatné hodnoty atribútov zostanú nezmenené. Vidíme, že najvyššia očakávaná frekvencia nehodovosti je vo vekovej kategórii 18–24 rokov. Z histogramu ale vidíme, že v tejto vekovej kategórii máme aj najmenej dostupných pozorovaní, čo môže vplývať na spoľahlivosť predikcie modelu. Zobrazenie týchto grafov spolu s histogramom nám môže dať viac informácií o fungovaní modelu a umožní nám lepšie porozumieť, ako tento model funguje a či bol model tréňovaný na dostatočnom počte dát. Dokážeme si teda utvoriť lepšiu predstavu, ako veľmi vierohodné sú modelované závislosti. Nezvyčajné tvary kriviek môžu odhaliť aj rôzne závislosti medzi jednotlivými hodnotami atribútov. Zelenou farbou vidíme znázornený graf ICE. Opäť uvažujeme nášho klienta s hodnotami atribútov zaznamenanými v Tabuľke 5.9. Graf ICE v tomto prípade zobrazuje, ako by sa menila predikcia modelu, ak by sa menila veková kategória, a to za predpokladu, že by ostatné hodnoty atribútov zostali nezmenené. Pre lepšie porozumenie sa môžeme odvolať aj na graf Shapleyho hodnôt zobrazený na Obrázku 5.4, kde môžeme vidieť, že najväčší negatívny vplyv na predikciu modelu mala práve hodnota premennej Age, zatiaľčo ostatné atribúty mali naopak najmä pozitívny vplyv na výslednú predikciu nehodovosti. Práve vplyvom týchto ostatných hodnôt atribútov je krivka grafu ICE posunutá pod krivky grafov PDP a ALE. Tvar ICE krivky prevažne kopíruje tvary ALE a PDP, takže nepozorujeme žiadne nezvyčajné správanie.

5.3.1 Zhodnotenie GBM

Ukázali sme si, akým spôsobom môžeme interpretovať na prvý pohľad pomerne zložitý gradient boosting model. Pomocou predstavených vysvetľovacích techník sme dokázali lepšie pochopiť, ako tento model funguje. Zámerne sme sa rozhodli vybrať viac atribútov, aby sme lepšie demonštrovali, akým spôsobom si predstavené vysvetľovacie techniky dokážu poradiť s komplexnejšími modelmi. Z hľadiska chybovosti meranej strednou kvadratickou chybou nedopadol tento model na tréningovej vzorke dát zle v porovnaní s chybovosťou negatívne binomického modelu vytvoreného v predošlej podkapitole. Keďže sme na tvorbu modelu použili všetky dostupné atribúty z Tabuľky 5.1 okrem atribútu pohlavia (t. j. Gender), tak by sme takýmto spôsobom vytvorili až 9 216 rizikových skupín. Takýto vysoký počet rizikových skupín pri veľkosti tréningovej vzorky so 17 438 pozorovaniami môže spôsobiť, že veľkosti niektorých rizikových skupín môžeme merať doslova v jednotkách pozorovaní, iné budú dokonca bez akéhokoľvek zastúpenia. Predikcie pre takéto skupiny nemusia byť teda príliš vierohodné. Určite by bolo vhodné preskúmať správanie modelu práve v týchto riedko zastúpených skupinách, a to napríklad aj pomocou grafov PDP a ICE. Poistiteľa bude ale samozrejme zaujímať najmä presnosť predikcie v husto zastúpených rizikových skupinách. Treba vziať na vedomie aj skutočnosť, že niektoré kombinácie atribútov v reálnom svete dokonca nemusia dávať ani zmysel, a preto skúmanie presnosti modelu pre takéto skupiny nemá význam. Všetko závisí od množstva historických dát na ktorých je model tréňovaný a od aktuálneho zloženia poistného kmeňa. Každopádne, cieľom tejto kapitoly nebolo vytvoriť čo najlepší gradient boosting model, ale ukázať, akým spôsobom dokážeme modely tohto typu interpretovať. Výkon samotného gradient boosting modelu

je možné zlepšiť viacero spôsobmi. Za zmienku stoja už viackrát spomínané regularizačné techniky, technika one-hot encoding alebo hashing trik.

5.3.2 Porovnanie GLM a GBM

Na záver tejto kapitoly si ešte porovnajme vytvorené modely. Na začiatku sekcie 5.2.2 sme si uviedli, že pôvodný dataset sme rozdelili v pomere 80:20 na tréningovú a testovaciu vzorku dát. Všetky modely boli vytvorené pomocou tréningovej vzorky dát a prípadné preučenie týchto modelov bolo kontrolované použitím 10-násobnej krížovej validácie. Poďme sa teraz pozrieť, ako si nami vytvorené modely poradia s neznámymi dátami. Testovacia vzorka dát pozostáva celkovo z 4 359 pozorovaní. Na tejto vzorke neznámych dát si porovnáme chybovosť negatívne binomického modelu⁴³ a gradient boosting modelu⁴⁴. Chybovosť modelov bude meraná prostredníctvom strednej kvadratickej chyby.

Tabuľka 5.11: Porovnanie modelov na základe strednej kvadratickej chyby

Model	MSE
GLM _{NB}	0.1892
GBM	0.1887

V Tabuľke 5.11 vidíme spočítanú chybovosť na testovacej vzorke dát pre oba modely. Rozdiel v strednej kvadratickej chybe je len päť desiatich, čo sa javí ako zanedbateľný rozdiel. Na tomto mieste treba dodať, že dáta boli vopred spracované a upravené tak, aby najlepšie vyhovovali požiadavkom zovšeobecneného lineárneho modelu. Kategorizácia bola spravená tak, aby dávala zmysel v kontexte poistenia motorových vozidiel a zároveň, aby bolo možné zachytiť rozdiely vo frekvencii nehodovosti medzi jednotlivými rizikovými skupinami. Komplexnejší gradient boosting model si ale dokázal poradiť aj s takýmto dátami a v porovnaní s negatívne binomickým modelom obstál pomerne dobre. Každopádne, rozdiel nie je taký markantný, ako by sme možno očakávali. Ponúka sa teda otázka, či by sa použitie takéhoto modelu poisťovníci oplátilo aj za cenu sťaženej interpretovateľnosti a nie tak jasnej a priamočiarej štruktúry, akú má negatívne binomický model. Zároveň treba zdôrazniť, že porovnanie len stredných kvadratických chýb bez ďalšieho kontextu nie je dostatočné. Určite by bolo vhodné pozrieť sa, kde sa predikcie týchto modelov najviac odlišujú a snažiť sa zistiť prečo.

V Prílohe B je dostupná funkcia, ktorou je možné spočítať očakávané ročné frekvencie nehodovosti pre všetky rizikové skupiny. V Prílohe A je ďalej dostupná Tabuľka 5.13, v ktorej je možné vidieť porovnanie predikovaných frekvencií nehodovosti pre vybrané rizikové skupiny spočítané pomocou oboch modelov. Spolu s predikciami tu môžeme vidieť váhu príslušnej rizikovej skupiny reprezentovanú relatívnou dĺžkou trvania poistných zmlúv v danej skupine vzhľadom k celkovej dĺžke trvania poistných zmlúv v tréningovej vzorke (ozn. w). Taktiež tu máme zaznamenaný absolútny počet pozorovaní v jednotlivých

⁴³Popis a koeficienty modelu sú dostupné na strane 70.

⁴⁴Popis a hodnoty hyper-parametrov modelu sú dostupné na strane 74.

skupinách (ozn. n). Nakoniec tu môžeme nájsť aj skutočnú frekvenciu nehodovosti pre príslušnú rizikovú skupinu spočítanú ako podiel celkového počtu nehôd v danej skupine a súčtu celkovej poistnej doby pre všetkých klientov v danej rizikovej skupine. Tabuľka je zoradená zostupne podľa váh rizikových skupín a v prípade rovnosti váh sa bral do úvahy absolútny rozdiel predikcií modelov. Vzhľadom na veľký počet skupín je zobrazených len prvých desať a posledných desať skupín. Vidíme, že v prípade vyššieho počtu tréningových dát sa predikcie oboch modeloch príliš neodlišujú. Naopak, najväčšie rozdiely vidíme v skupinách, ktoré nie sú v tréningovom datasete zastúpené vôbec, pričom samotné hodnoty atribútov v týchto skupinách sú celkovo riedko zastúpené v tréningovej vzorke. Navyše môže byť tento rozdiel spôsobený aj skutočnosťou, že negatívne binomický model neberie do úvahy premenné CarAge a EngPerfKW, zatiaľ čo gradient boosting model áno. Takže sa nám vlastne spojili dva negatívne faktory v podobe nedostatočného počtu tréningových dát a rôznej komplexnosti modelov, ktoré môžu mať zásadný vplyv na rozdielnosť ich predikcií. V Prílohe A je ďalej dostupná Tabuľka 5.14, kde sú pre lepšie pochopenie zobrazené frekvencie výskytu jednotlivých hodnôt atribútov v tréningovej vzorke dát. Ako sme ale už spomínali, z hľadiska poisťteľa je dôležitá presnosť predikcie v husto zastúpených skupinách, kde je k dispozícii dostatočne veľký počet tréningových dát. Dôležité je minimalizovať chybovosť práve v týchto skupinách, aby bolo možné minimalizovať náklady a zaistiť správny chod poisťovne. Samozrejme, opäť hrá dôležitú úlohu veľkosť tréningovej vzorky. Ak vezmeme do úvahy všetkých šesť premenných, tak môžeme vytvoriť až 9 216 rizikových skupín. Tréningový dataset pozostáva len zo 17 438 pozorovaní, pričom len v 2 326 rizikových skupinách máme nejaké zastúpenie. Zvyšných 6 890 rizikových skupín je v našom prípade bez svojho reprezentanta. Pre poisťteľa s podobným zložením portfólia klientov by bolo potom dôležité fungovanie modelu hlavne pre týchto 2 326 rizikových skupín.

Vysvetľovacie techniky predstavené v podkapitole 4.6 dávajú v každom prípade poisťným matematikom viac možností, ako pristupovať k problému segmentácie klientov v neživotnom poistení. Pomocou týchto metód dokážeme interpretovať aj pomerne zložité modely strojového učenia, ako napríklad gradient boosting modely. Interpretovať dokážeme ale aj iné modely strojového učenia, ktoré v praktických aplikáciách vykazujú ešte lepšiu schopnosť predikcie, ako sú napríklad extreme gradient boosting modely alebo neurónové siete. Zložité modely strojového učenia nemusia byť priamo použité na segmentáciu klientov z hľadiska očakávanej nehodovosti klienta, ale môžu byť použité napríklad na identifikovanie vplyvných atribútov, ťažko oddeliteľných závislostí medzi jednotlivými atribútmi a podobne. V kombinácii s vysvetľovacími technikami môžu byť zložité modely strojového učenia nápomocné poisťným matematikom hlavne pri procesovaní dát a exploračnej analýze. V dnešnej dobe, keď majú poisťovne k dispozícii obrovský počet historických dát, rôzne apriórne informácie o klientovi a značný výpočtový výkon, dokážu zložité modely strojového učenia ušetriť poisťným matematikom veľa času a dokážu im pomôcť odhaliť súvislosti, ktoré by boli len ťažko odhaliteľné štandardným spôsobom pri takom veľkom objeme dát. Úplný prechod od klasických lineárnych modelov k zložitým modelom strojového učenia môže trvať ešte pomerne dlhý čas, čo ale neznamená, že tieto modely nemôžu byť použité v procese segmentácie klientov iným spôsobom. Zovšeobecnené lineárne modely majú nesporne stále veľa výhod, a preto ostávajú štandardom v neživotnom poistení. Ich

jednoduchá interpretácia, jasná štruktúra a stále dostatočne kvalitná predikčná schopnosť poskytujú poisťiteľom veľa výhod a umožňujú im tieto modely implementovať v praxi, aj napriek značne regulovanému poisťnému trhu.

Záver

Cieľom tejto diplomovej práce bolo predstaviť rôzne prístupy, ktoré môžu byť použité pri segmentácii klientov v neživotnom poistení. Segmentácia klientov na základe ich rizikovosti je dôležitou súčasťou procesu tvorby tarifnej štruktúry poisťovne. Úlohou poistných matematikov je nastaviť túto tarifnú štruktúru tak, aby klienti platili spravodlivú výšku poistného zodpovedajúcu riziku, ktoré na seba poisťiteľ preberá. V tejto diplomovej práci sme sa zamerali na modelovanie očakávanej ročnej frekvencie nehodovosti klientov, ktorú sme odhadli použitím apriórnych charakteristík týchto klientov. Na základe odhadnutej ročnej frekvencie nehodovosti sme potom rozdelili klientov do rizikových skupín.

Prvý prístup, ktorý sme v práci využili, bolo modelovanie pomocou zovšeobecnených lineárnych modelov. Tento prístup patrí medzi štandard v poistnej sfére vďaka veľkému počtu výhod. Poisťovníctvo je značne regulovaná oblasť, a preto je nevyhnutné, aby bol poisťiteľ schopný jednoznačne vysvetliť, ako prebieha proces segmentácie klientov. Zovšeobecnené lineárne modely majú jasnú štruktúru, sú jednoducho interpretovateľné a stále dosahujú pomerne uspokojivú predikčnú silu. Na začiatku sme si predstavili pravdepodobnostné rozdelenia používané pri modelovaní počtu poistných udalostí. Ďalej sme si stručne uviedli teóriu potrebnú pre pochopenie fungovania zovšeobecnených lineárnych modelov. Následne sme túto predstavenú teóriu aplikovali na reálne dáta z poistenia zodpovednosti za škodu spôsobenú prevádzkou vozidla. Doprednou selekciou regresných parametrov sme vybrali najviac relevantné regresory a pomocou tréningových dát sme zostavili postupne Poissonov model a negatívne binomický model. Dáta z poistnej praxe sú charakteristické tým, že obsahujú nadmerný počet nulových pozorovaní. Pri našich dátach sa tento jav potvrdil. Pri nadmernom množstve nulových pozorovaní nesmieme zabudnúť na možnú overdispériu, s ktorou je potrebné sa vysporiadať. V našom prípade sme porovnali vytvorený Poissonov model a negatívne binomický model pomocou testu pomerom vierohodnosti. Odhalili sme, že efekt overdispérie je v našich dátach prítomný, na základe čoho sme zhodnotili, že je vhodnejšie použiť negatívne binomický model. Oba vytvorené modely sme interpretovali, a takisto sme ilustrovali výpočet očakávanej ročnej frekvencie nehodovosti pre najmenej rizikovú a najviac rizikovú skupinu klientov.

Druhý prístup segmentácie klientov, ktorý sme si v tejto diplomovej práci predstavili, bolo použitie sofistikovanejších modelov strojového učenia. Pokrok vo vývoji modelov strojového učenia je v posledných rokoch značný a je len otázkou času, kedy sa tento fenomén premietne aj do poistnej praxe. Modely strojového učenia sú väčšinou komplexnejšie ako zovšeobecnené lineárne modely a sme pomocou nich schopní zahrnúť do procesu segmentácie väčšie množstvo apriórnych informácií, a takisto dokážeme odhaliť na prvý

pohľad skryté súvislosti medzi vstupnými premennými. Problémom sofistikovaných modelov strojového učenia zostáva ich otázna interpretovateľnosť. Naším cieľom bolo predstaviť techniky, pomocou ktorých dokážeme pochopiť a interpretovať aj zložité modely. V tejto diplomovej práci sme si postupne predstavili fungovanie gradient boosting modelov, potom sme si uviedli viaceré vysvetľovacie techniky, ktoré sme následne použili na reálnych dátach. Zámerom bolo ukázať, že aj pomerne zložitý model, akým gradient boosting model určite je, sa dá celkom jednoducho a vierohodne interpretovať. Pomocou trénovacej vzorky dát sme vybudovali model, na ktorý sme neskôr aplikovali vysvetľovacie techniky. Začali sme Shapleyho vysvetleniami, ukázali sme si techniku lokálne interpretovateľných modelovo-agnostických vysvetlení, a nakoniec sme sa zamerali na grafy parciálnej závislosti a individuálnych podmienených očakávaní. V závere diplomovej práce sme sa upriamili ešte na porovnanie oboch prístupov. Pozreli sme sa, ako si vytvorené modely poradia s neznámami testovacími dátami. Vytvorili sme predikcie očakávanej ročnej frekvencie nehodovosti pre všetky rizikové skupiny a pozreli sme sa, kde sa predikcie vytvorených modelov najviac odlišujú.

Sofistikovanejšie modely strojového učenia, pravdepodobne, v blízkej budúcnosti úplne nenahradia zaužívané zovšeobecnené lineárne modely. Modely strojového učenia môžu byť aplikované už vo fáze prípravy dát, kde by sa analytikom mohlo podariť efektívnejšie spracovať dostupné dáta a na základe informácií a súvislostí získaných v tejto fáze procesu, by potom mohli vytvoriť presnejší zovšeobecnený lineárny model. Použitie zložitejších modelov strojového učenia by mohlo poisťiteľom ušetriť veľa času, a tiež finančných prostriedkov. V tejto diplomovej práci sa nám nepodarilo preukázať výrazne lepšiu predikčnú silu gradient boosting modelu oproti zovšeobecneným lineárnym modelom. Určite by bolo zaujímavé skúmať správanie modelov pri väčšom počte trénovacích dát, aby sme mohli vierohodne posúdiť predikcie pre riedko zastúpené rizikové skupiny. Ďalej by bolo vhodné zamerať sa na kolektívny model rizika, a teda skúmať aj očakávanú výšku poistných plnení v jednotlivých rizikových skupinách. Opäť by bolo zaujímavé porovnanie klasických prístupov a moderných prístupov strojového učenia. V dnešnej dobe rýchleho napredovania technológií a obrovského počtu dostupných dát budú sofistikované modely strojového učenia čoraz viac populárne aj v poisťnej sfére a bude určite pútavé sledovať, akým spôsobom bude poisťiteľom umožnená ich implementácia.

Príloha A

Tabuľka 5.12: Ukážka dát

N	Exposure	County	Age	EngPerfKW	Weight	Make	CarAge
0	0.82	D	18–24	101–150	1201–1600	Audi	4–10
0	0.15	B	35–44	61–100	1601–2000	Renault	4–10
0	2.84	C	25–34	101–150	1201–1600	VW	0–3
0	1.69	D	25–34	61–100	1201–1600	Opel	4–10
0	3.00	C	65+	60-	1200-	Opel	4–10
0	0.41	C	45–54	61–100	1201–1600	Audi	16+
0	1.01	B	25–34	61–100	1201–1600	BMW	11–15
0	1.56	B	45–54	150+	1601–2000	BMW	11–15
1	0.77	B	35–44	61–100	1200-	VW	16+
0	0.71	B	25–34	61–100	1201–1600	Audi	16+
1	0.47	C	35–44	61–100	1201–1600	Audi	16+
0	0.51	C	18–24	61–100	1201–1600	Opel	4–10
0	2.50	B	45–54	61–100	1201–1600	Opel	0–3
1	1.00	B	25–34	61–100	1201–1600	Audi	16+
0	2.00	A	55–64	60-	1201–1600	VW	16+
0	0.46	A	35–44	61–100	1201–1600	VW	11–15
0	0.41	A	55–64	61–100	1200-	Audi	16+
0	3.00	A	45–54	60-	1200-	VW	4–10
0	1.66	B	18–24	61–100	1201–1600	Audi	16+
1	0.47	C	35–44	60-	1201–1600	VW	4–10
0	0.25	D	35–44	60-	1201–1600	Opel	16+
0	1.00	B	45–54	61–100	1201–1600	Audi	16+
0	0.75	B	25–34	61–100	1601–2000	VW	16+
0	2.13	C	35–44	61–100	1201–1600	Opel	4–10
1	0.41	B	35–44	61–100	1201–1600	Audi	4–10
0	3.00	B	35–44	60-	1200-	VW	11–15
0	0.35	C	25–34	61–100	1201–1600	VW	11–15
0	0.12	B	25–34	61–100	1200-	VW	16+
0	2.21	A	35–44	101–150	1201–1600	VW	11–15
0	0.13	B	25–34	61–100	1201–1600	Mazda	11–15

Tabulka 5.13: Ukážka vypočítaných ročných frekvencií nehodovosti pre všetky rizikové skupiny

County	Age	EngPerfKW	Weight	Make	CarAge	n	w	λ	λ_{GLM}	λ_{GBM}	$ \lambda_{\text{GLM}} - \lambda_{\text{GBM}} $
B	45-54	61-100	1201-1600	VW	4-10	144	0,010	0,050	0,071	0,070	0,001
B	45-54	61-100	1201-1600	VW	11-15	149	0,009	0,079	0,082	0,077	0,005
B	35-44	61-100	1201-1600	VW	4-10	127	0,009	0,083	0,073	0,071	0,002
B	35-44	61-100	1201-1600	VW	11-15	114	0,008	0,064	0,084	0,074	0,010
B	25-34	61-100	1201-1600	VW	4-10	104	0,006	0,079	0,082	0,079	0,003
B	25-34	61-100	1201-1600	VW	11-15	113	0,006	0,079	0,095	0,088	0,006
C	35-44	61-100	1201-1600	VW	4-10	95	0,006	0,148	0,098	0,092	0,006
C	45-54	61-100	1201-1600	VW	4-10	79	0,005	0,067	0,095	0,089	0,007
B	45-54	60-	1200-	VW	4-10	66	0,005	0,071	0,057	0,063	0,006
B	45-54	61-100	1201-1600	Opel	4-10	77	0,005	0,078	0,071	0,068	0,003
.	.	.	.	.	.	.	.	.	.	.	.
.	.	.	.	.	.	.	.	.	.	.	.
.	.	.	.	.	.	.	.	.	.	.	.
D	18-24	150+	1601-2000	VW	16+	0	0	0	0,378	0,078	0,300
D	18-24	61-100	1601-2000	Renault	16+	0	0	0	0,378	0,078	0,300
D	18-24	61-100	2001+	Audi	11-15	0	0	0	0,367	0,065	0,302
D	18-24	150+	1601-2000	VW	11-15	0	0	0	0,370	0,067	0,303
D	18-24	150+	1601-2000	Renault	11-15	0	0	0	0,370	0,065	0,305
D	18-24	150+	1601-2000	Renault	16+	0	0	0	0,378	0,072	0,306
D	18-24	150+	2001+	Audi	11-15	0	0	0	0,367	0,056	0,311
D	18-24	150+	2001+	VW	11-15	0	0	0	0,367	0,026	0,341
D	18-24	61-100	2001+	VW	11-15	0	0	0	0,367	0,030	0,337
D	18-24	150+	2001+	VW	11-15	0	0	0	0,367	0,026	0,341

Tabuľka 5.14: Frekvencia výskytu jednotlivých hodnôt premenných v tréningovom datasete

Premenná	Hodnota	Počet
Age	18–24	271
	25–34	396
	35–44	441
	45–54	478
	55–64	390
	65 a viac	350
County	A	572
	B	826
	C	812
	D	116
CarAge	3 a menej	497
	4–10	719
	11–15	619
	16 a viac	491
Weight	1 200 a menej	595
	1 201–1 600	1 176
	1 601–2 000	444
	2 001 a viac	111
EngPerfKW	60 a menej	563
	61–100	923
	101–150	589
	151 a viac	251
Make	Audi	374
	BMW	345
	Mazda	323
	Opel	401
	Renault	358
	Volkswagen	525

Príloha B

Funkcia použitá na K -násobnú krížovú validáciu:

```
##### GLM: Cross-validation #####
GLM_cv <- function(data, formula, response, type = "Poisson",
  k=10, seed=1) {
  # -----
  # data . . . datovy subor (typ: data.frame alebo tibble)
  # formula . . . formula pouzita pri fitovani GLM
  # (typ: char alebo formula)
  # response . . . nazov zavislej premennej (typ: character)
  # type . . . typ GLM (typ: char; moznosti: "Poisson", "NB")
  # k . . . pocet nasobkov krizovej validacie
  # seed . . . inicializacia pre reprodukovatelne vysledky
  # -----
  # Set up training control
  set.seed(seed = seed)

  # Define formula for the model
  formula <- stats::formula(formula)

  # Set up cross-validation folds
  folds <- caret::createFolds(
    dplyr::pull(data, response),
    k = k,
    list = TRUE,
    returnTrain = TRUE
  )

  # Initialize lists to store results
  deviance_list <- list()
  loglik_list <- list()
  aic_list <- list()
  aicc_list <- list()
  bic_list <- list()
  mse_list <- list()
  df_list <- list()
  coef_list <- list()
}
```

```
# Loop over the folds
for (i in 1:length(folds)) {

  # Get the current fold
  fold <- folds[[i]]

  # Split data into train and test sets
  data_train <- data[fold,]
  data_test <- data[-fold,]

  if (type == "Poisson") {
    # Fit the Poisson model using the training set
    model <- stats::glm(
      formula = formula,
      data = data_train,
      family = poisson(link = "log")
    )
  } else if (type == "NB") {
    # Fit the negative binomial model using the training set
    model <- MASS::glm.nb(
      formula = formula,
      data = data_train,
      link = "log"
    )
  } else{
    return(cat("Nespravne zadany typ GLM. Moznosti su: '
      Poisson' alebo 'NB'."))
  }

  # Get the predicted values and calculate MSE
  preds <- stats::predict(
    model,
    newdata = data_test,
    type = "response",
    se.fit = FALSE
  )

  # MSE
  mse <- mean((dplyr::pull(data_test, response) - preds)^2)

  # Store results
  deviance_list[[i]] <- stats::deviance(model)
  loglik_list[[i]] <- stats::logLik(model)
  aic_list[[i]] <- stats::AIC(model)
  aicc_list[[i]] <- AICcmodavg::AICc(model)
  bic_list[[i]] <- stats::BIC(model)
  mse_list[[i]] <- mse
  df_list[[i]] <- stats::df.residual(model)
```

```

    coef_list[[i]] <- stats::coef(model)
  }

  # Calculate average results across all folds
  deviance <- mean(unlist(deviance_list))
  loglik <- mean(unlist(loglik_list))
  aic <- mean(unlist(aic_list))
  aicc <- mean(unlist(aicc_list))
  bic <- mean(unlist(bic_list))
  mse <- mean(unlist(mse_list))
  df <- mean(unlist(df_list))
  coef_avg <- Reduce("+", coef_list) / length(coef_list)

  results <- list(
    Deviance = deviance,
    LogLik = loglik,
    AIC = aic,
    AICc = aicc,
    BIC = bic,
    MSE = mse,
    df = df,
    Coefficients = coef_avg
  )

  return(results)
}

```

Funkcie použité pri tvorbe GBM:

```

##### Parameter GRID #####
# Define the parameter grid
param_grid <- expand.grid(
  n.trees = c(50, 70, 100),
  interaction.depth = c(2, 3, 4, 5),
  shrinkage = c(0.1, 0.05, 0.01),
  bag.fraction = c(0.3, 0.5, 0.7),
  n.minobsinnode = c(10, 20, 50)
)

# Set random seed for reproducibility
set.seed(1)
# Fit and evaluate models using the parameter grid
results <- apply(param_grid, 1, function(params) {
  gbm_model <- gbm::gbm(
    formula = NClaims ~ offset(log(Exposure)) + County + Age +
      Weight + CarAge,
    data = train_data,
    distribution = "poisson",
    n.trees = params[1],
    interaction.depth = params[2],

```

```
    shrinkage = params[3],
    bag.fraction = params[4],
    n.minobsinnode = params[5],
    cv.folds = 10,
    verbose = FALSE
  )
  n <- gbm::gbm.perf(gbm_model, plot.it = F, method = "cv")
  err <- gbm_model$cv.error[n]
  # Prediction
  pred <- gbm::predict.gbm(
    object = gbm_model,
    newdata = train_data,
    n.trees = n,
    type = "response"
  )
  # Adjusting for offset
  pred_adj <- train_data$Exposure*pred
  # MSE
  mse <- mean((train_data$NClaims - pred_adj)^2)
  # Return
  return(c(params, n, err, mse))
})

# Convert results to a data frame
results_df <- data.frame(t(results))
colnames(results_df) <- c(
  "n.trees",
  "interaction.depth",
  "shrinkage",
  "bag.fraction",
  "n.minobsinnode",
  "n",
  "err",
  "mse"
)

# Results
View(results_df)

##### GBM #####
# Set random seed for reproducibility
set.seed(1)
# Model
gbm_model <- gbm::gbm(
  formula = NClaims ~ offset(log(Exposure)) + County + Age +
    Weight + CarAge + Make + EngPerfKW,
  data = train_data,
  distribution = "poisson",
```

```

n.trees = 100,
interaction.depth = 4,
shrinkage = 0.05,
bag.fraction = 0.5,
n.minobsinnode = 10,
cv.folds = 10,
verbose = F
)

# Check performance using cross-validation
best.iter <- gbm::gbm.perf(gbm_model, method = "cv")

# Prediction
pred <- gbm::predict.gbm(
  object = gbm_model,
  newdata = train_data[, -c(1,2)],
  n.trees = best.iter,
  type = "response"
)

# Adjusting for offset
pred_adj <- train_data$Exposure*pred
# MSE
mean(((train_data$NClaims) - pred_adj)^2)

```

Funkcie použité pri vysvetľovacích technikách:

```

# Defining a client
client <- data.frame(
  County = factor("A", levels = c("A", "B", "C", "D")),
  Age = factor("18-24", levels = c("18-24", "25-34", "35-44",
    "45-54", "55-64", "65+")),
  EngPerfKW = factor("60-", levels = c("60-", "61-100", "
    101-150", "150+")),
  Weight = factor("1200-", levels = c("1200-", "1201-1600", "
    1601-2000", "2001+")),
  Make = factor("Opel", levels = c("Audi", "BMW", "Mazda", "
    Opel", "Renault", "VW")),
  CarAge = factor("16+", levels = c("0-3", "4-10", "11-15", "
    16+"))
)

##### SHAP #####
# Explainer
explainer_gbm <- DALEX::explain(
  model = gbm_model,
  data = train_data[, -c(1, 2)],
  y = train_data$NClaims,
  predict_function = predict.gbm,
  label = "GBM Model"
)

```

```

# Tree SHAP
set.seed(1)
shap_values_gbm <- DALEX::predict_parts(
  explainer = explainer_gbm,
  new_observation = client,
  type = "shap",
  B = 100
)

# Plot - Tree SHAP
plot(shap_values_gbm, vcolors = c("#7EEDB9", "#FC7168"))
plot(shap_values_gbm, vcolors = c("#7EEDB9", "#FC7168"), show_
  boxplots=FALSE)

# Tree SHAP + Break Down
set.seed(1)
shap_valuesAgg_gbm <- DALEX::predict_parts(
  explainer = explainer_gbm,
  new_observation = client,
  type = "shap_aggregated",
  B = 100
)

# Plot - Tree SHAP + BD
plot(shap_valuesAgg_gbm, vcolors = c("#7EEDB9", "#FC7168", "
  #150070"))

##### LIME #####
# LIME
lime_gbm <- DALEXtra::predict_surrogate(
  explainer = explainer_gbm,
  new_observation = client,
  k = 4, # number of explanatory variables included
  type = "iml",
  seed = 1
)

# Results - LIME
lime_gbm$results

# Plot - LIME
plot(lime_gbm)

##### PDP, ALE, ICE #####
# PDP - Age
pdp_gbm <- DALEX::model_profile(
  explainer = explainer_gbm,

```

```

    variables = "Age",
    type = "partial"
)

# ALE - Age
ale_gbm <- DALEX::model_profile(
  explainer = explainer_gbm,
  variables = "Age",
  type = "accumulated"
)

# ICE - Age
ice_gbm <- DALEX::predict_profile(
  explainer = explainer_gbm,
  new_observation = client,
  variables = c("Age")
)

```

Funkcie použité na vypočítanie očakávanej ročnej frekvencie nehodovosti pre všetky rizikové skupiny:

```

##### PREDICTIONS for all RISK CLASSES #####
# Define the GROUPS
groups <- expand.grid(
  Exposure = 1,
  County = factor(c("A", "B", "C", "D")),
  Age = factor(c("18-24", "25-34", "35-44", "45-54", "55-64",
    "65+")),
  EngPerfKW = factor( c("60-", "61-100", "101-150", "150+")),
  Weight = factor(c("1200-", "1201-1600", "1601-2000", "2001+"
  )),
  Make = factor(c("Audi", "BMW", "Mazda", "Opel", "Renault", "
    VW")),
  CarAge = factor(c("0-3", "4-10", "11-15", "16+"))
) |> as.data.frame()

# Adding real data from training dataset - 6890 NA groups
groups <- dplyr::left_join(
  x = groups,
  y = train_data,
  by = c("County", "Age", "EngPerfKW", "Weight", "Make", "
    CarAge")
) |>
mutate(
  n = dplyr::if_else(is.na(n), 0, n),
  w = dplyr::if_else(is.na(w), 0, w),
  freq = dplyr::if_else(is.na(freq), 0, freq)
)

```

```
# Predict
for (i in 1:nrow(groups)) {
  groups$freq_glm[i] <- stats::predict.glm(model_glmNB,
    newdata = groups[i,], type = "response", se.fit = FALSE)
  groups$freq_gbm[i] <- gbm::predict.gbm(model_gbm, newdata =
    groups[i,-1], n.trees = best.iter, type = "response")
}

# Adding absolute differences
groups <- groups |> dplyr::mutate(
  abs_diff = abs(freq_glm - freq_gbm)
)
```

Zoznam použitej literatúry

- [1] Zákon č. 277/2009 Sb., o pojišťovníctví.
- [2] Zákon č. 89/2012 Sb., občanský zákoník.
- [3] Česká asociace pojišťoven, 2020. *Vývoj pojistného trhu* [online]. ze dne 27.01.2023 [cit. 2023-05-01]. Dostupné z: <http://www.cap.cz/>.
- [4] Zákon č. 168/1999 Sb., o pojištění odpovědnosti za újmu způsobenou provozem vozidla a o změně některých souvisejících zákonů (zákon o pojištění odpovědnosti z provozu vozidla).
- [5] DENUIT, Michel a kol. *Actuarial modelling of claim counts: risk classification, credibility and bonus-malus systems*. Hoboken N.J.: John Wiley & Sons, 2007. ISBN 978-0-470-02677-9.
- [6] JURÍK, Karol. *Bonus malus systémy v pojištění*. Brno, 2020. Bakalářská práce. Masarykova univerzita, Přírodovědecká fakulta.
- [7] KLUGMAN, Stuart A., Harry H. PANJER a Gordon E. WILLMOT. *Loss models: from data to decisions*. 4th ed. Hoboken, N.J.: John Wiley & Sons, 2012. ISBN 978-1-118-31532-3.
- [8] DE JONG, Piet a Gillian Z. HELLER. *Generalized Linear Models for Insurance Data*. New York: Cambridge University Press, 2008. ISBN 978-0-511-38677-0.
- [9] ZVÁRA, Karel a Josef ŠTĚPÁN. *Pravděpodobnost a matematická statistika*. Vyd. 3. Praha: Matfyzpress, 2002. ISBN 80-85863-93-6.
- [10] KAAS, Rob. *Modern Actuarial Risk Theory: Using R*. 2nd ed. Berlin/Heidelberg: Springer Verlag, 2009. ISBN 978-3-642-03407-7.
- [11] MIKOSCH, Thomas. *Non-Life Insurance Mathematics*. Berlin/Heidelberg: Springer Verlag, 2009. ISBN 978-3-540-88232-9.
- [12] OHLSON, Esbjörn a Björn JOHANSSON. *Non-Life Insurance Pricing with Generalized Linear Models*. Berlin/Heidelberg: Springer Verlag, 2010. ISBN 978-3-642-10790-0.
- [13] DOBSON, Annette J. *An introduction to generalized linear models*. 2nd ed. Boca Raton: Chapman & Hall/CRC, 2002. ISBN 1-58488-165-8.

- [14] JAMES, Gareth a kol. *An introduction to statistical learning: with applications in R*. 1st ed. New York: Springer, 2013. Springer texts in statistics. ISBN 978-1-4614-7137-0.
- [15] SHALEV-SHWARTZ, Shai a Shai BEN-DAVID. *Understanding Machine learning*. Cambridge: University Press, 2014. ISBN 978-1-107-05713-5.
- [16] PROKSCH, Michael. From GLM to GBM – Part 1. In *H2O.ai Blog*, 2020. [cit. 2020-12-12]. Dostupné z: <https://h2o.ai/blog/>
- [17] PROKSCH, Michael. From GLM to GBM – Part 2. In *H2O.ai Blog*, 2020. [cit. 2020-12-12]. Dostupné z: <https://h2o.ai/blog/>
- [18] HALL, Patrik. On the Art and Science of Explainable Machine Learning. In *ResearchGate*, 2018. Dostupné z: https://www.researchgate.net/publication/328160693_On_the_Art_and_Science_of_Machine_Learning_Explanations
- [19] KUO, Kevin a Daniel LUPTON. *Towards Explainability of Machine Learning Models in Insurance Pricing*. In *Cornell University*, 2020. Dostupné z: <https://arxiv.org/abs/2003.10674>
- [20] HASTIE, Trevor, Robert TIBSHIRANI a Jerome FRIEDMAN. *The Elements of Statistical Learning*. New York: Springer, 2001. ISBN 0-387-95284-5.
- [21] TAN, Pang-Ning a kol. *Introduction to Data Mining*. 2nd ed. London: Pearson, 2019. ISBN 978-0-133-12890-1.
- [22] BREIMAN, Leo a kol. *Classification and regression trees*. Boca Raton: Chapman & Hall/CRC, 1984. ISBN 978-0-412-04841-8.
- [23] KASS, G. V. An Exploratory Technique for Investigating Large Quantities of Categorical Data. In *Journal of the Royal Statistical Society. Series C (Applied Statistics)*, 29, No. 2, 1979. Dostupné z: <https://www.jstor.org/stable/2986296>
- [24] KUHN, Max a Kjell JOHNSON. *Applied Predictive Modeling*. 5th ed. New York: Springer, 2016. ISBN 978-1-4614-6848-6.
- [25] FRIEDMAN H., Jerome. Greedy Function Approximation: A Gradient Boosting Machine. In *The Annals of Statistics*, 29, No. 5, 2021. Dostupné z: <https://jerryfriedman.su.domains/ftp/trebst.pdf>
- [26] LUNDBERG M., Scott a Su-In LEE. A Unified Approach to Interpreting Model Predictions. In *Cornell University*, 2017. Dostupné z: <https://arxiv.org/abs/1705.07874>
- [27] MOLNAR, Christoph. *Interpretable Machine Learning*. Victoria: Leanpub, 2019. ISBN 978-0-244-76852-2.
- [28] LUNDBERG M., Scott, Gabriel G. ERION a Su-In LEE. Consistent Individualized Feature Attribution for Tree Ensembles. In *Cornell University*, 2018. Dostupné z: <https://arxiv.org/abs/1802.03888>

- [29] BIECEK, Przemyslaw a Tomasz BURZYKOWSKI. *Explanatory Model Analysis*. Boca Raton: CRC Press, 2021. ISBN 978-0-367-13559-1.
- [30] ŠTRUMBELJ, Erik a Igor KONONENKO. Explaining prediction models and individual predictions with feature contributions. *Knowledge and Information Systems*. *Knowl Inf Syst*, 41, 647–665, 2014.
- [31] RIBEIRO, Marco Tulio, Sameer SINGH a Carlos GUESTRIN. “Why Should I Trust You?” Explaining the Predictions of Any Classifier. In *Cornell University*, 2016. Dostupné z: <https://arxiv.org/abs/1602.04938>
- [32] APLEY W., Daniel a Jingyu ZHU. Visualizing the Effects of Predictor Variables in Black Box Supervised Learning Models. In *Cornell University*, 2019. Dostupné z: <https://arxiv.org/pdf/1612.08468.pdf>
- [33] GOLDSTEIN, Alex a kol. Peeking Inside the Black Box: Visualizing Statistical Learning with Plots of Individual Conditional Expectation. In *Cornell University*, 2014. Dostupné z: <https://arxiv.org/pdf/1309.6392.pdf>
- [34] HILBE M., Joseph. *Modeling Count Data*. Cambridge: University Press, 2014. ISBN 978-1-107-02833-3.
- [35] CAMERON A. Colin a Pravin K. TRIVEDI. *Regression Analysis of Count Data*. 2nd ed. Cambridge: University Press, 2013. ISBN 978-1-107-01416-9.
- [36] MCCULLAGH, Peter a J. A. NELDER. *Generalized linear models*. 2nd ed. Boca Raton: Chapman & Hall/CRC, 1989. ISBN 978-0-412-31760-6.
- [37] HARDIN W., James a Joseph M. HILBE. *Generalized Linear Models and Extensions*. 2nd ed. Texas: A Stata Press Publication, 2007. ISBN 978-1-59718-014-6.
- [38] FRIENDLY, Michael a David Meyer. *Discrete Data Analysis with R*. Boca Raton: CRC Press, 2016. ISBN 978-1-4987-2585-9.
- [39] BIECEK, Przemyslaw, MAKSYMIUK Szymon a Hubert BANIECKI. *Package ‘DALEX’*. 2023. Dostupné z: <https://cran.r-project.org/web/packages/DALEX/index.html>
- [40] MAKSYMIUK, Szymon a kol. *Package ‘DALEXtra’*. 2022. Dostupné z: <https://cran.r-project.org/web/packages/DALEXtra/DALEXtra.pdf>
- [41] MOLNAR, Christoph, Giuseppe CASALICCHIO a Bernd BISCHI. iml: An R package for Interpretable Machine Learning In *Journal of Open Source Software*, 3(26), 786, 2018. Dostupné z: <https://joss.theoj.org/papers/10.21105/joss.00786>

